
Trabajo Fin de Máster: Title!!!

Decidir Título



Trabajo Fin de Máster

David García Curbelo

Trabajo de investigación para el
Máster en Lenguajes y Sistemas Informáticos
Universidad Nacional de Educación a Distancia

Dirigido por la

Prof. Dra. D. Laura Plaza Morales

14 de noviembre de 2025

Agradecimientos

Equipo de TalentCLEF por facilitar el acceso a los datos y el desarrollo de una plataforma para la evaluación a posteriori de la tarea.

Resumen

Resumen.

Abstract

Resumen en inglés.

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Definición del problema	2
1.3. Propuesta y objetivos	4
1.4. Estructura del documento	5
2. Estado del arte	7
2.1. Historia del problema	7
2.1.1. Métodos tradicionales y enfoques económicos	7
2.1.2. Transición hacia técnicas de aprendizaje automático	8
2.1.3. Del problema de clasificación a la tarea de <i>matching</i> en entornos reales	9
2.2. Enfoques abordados en TalentCLEF	9
2.2.1. Estrategias Dominantes	9
2.2.2. El Rol Crítico de Recursos Externos	10
2.2.3. Gestión de Escenarios Multilingües y Cross-Lingües	11
2.2.4. Consideraciones Específicas: Chino y Sesgo de Género	11
2.3. Transformers para Semejanza Semántica	12
2.3.1. Definición y características	12
2.3.2. Su utilización en la tarea	13
2.3.3. Técnicas de entrenamiento específicas para mejorar la calidad del ranking	14
3. Sistema/Método/Caso de Estudio propuesto	17
3.1. Ejemplo sección	17
3.1.1. Ejemplo subsección	17

4. Evaluación	19
4.1. Metodología de evaluación	19
4.2. Métricas de evaluación	19
4.3. Colecciones de evaluación	19
4.4. Resultados	19
5. Discusión	21
5.1. Ejemplo sección	21
5.1.1. Ejemplo subsección	21
6. Conclusiones y trabajo futuro	23
6.1. Conclusiones	23
6.2. Trabajo futuro	23
Bibliografía	25
Glosario	30

Índice de Figuras

Índice de Tablas

Capítulo 1

Introducción

1.1. Motivación

El panorama del mercado laboral actual está experimentando una gran transformación impulsada principalmente por la rápida evolución tecnológica y la incorporación de la [Inteligencia Artificial \(AI\)](#) en nuestras vidas. Estudios recientes indicaban que para finales de 2025, aproximadamente 90 millones de puestos de trabajo habrán sido automatizados, y una cantidad similar de ocupaciones que no existían a principios de siglo aparecerán en escena ([Maslej et al., 2025](#)). Esta dinámica de cambio constante, lejos de ser un fenómeno aislado, es consecuencia directa del desarrollo tecnológico, el cual no solo ha automatizado tareas rutinarias y creado roles completamente nuevos, sino que también ha redefinido la naturaleza misma de los puestos de trabajo existentes.

En este contexto de transición, la adaptabilidad se convierte en un factor clave tanto para los profesionales, que enfrentan una incertidumbre creciente sobre las competencias que serán relevantes a corto plazo, como para las organizaciones, que se ven obligadas a identificar talento con estas capacidades emergentes ([Ordóñez de Pablos y Lytras, 2008](#)). Esta necesidad ha fomentado la adopción de tecnologías de [Procesamiento del Lenguaje Natural \(NLP\)](#) en la [Gestión del Capital Humano \(HCM\)](#), con el objetivo de optimizar procesos de adquisición de talento, crear programas de formación personalizados y permitir una planificación estratégica basada en competencias.

Sin embargo, el desarrollo de estos sistemas inteligentes se enfrenta a importantes desafíos que limitan su eficacia, equidad y generalización. Es

No se si hay que referenciar así. Preguntar a Laura.

precisamente en este punto donde se sitúa la motivación principal de este trabajo, centrado en la Tarea A del TalentCLEF 2025, la cual pretende abordar el problema del emparejamiento de titulaciones profesionales (Gasco et al., 2025a). Además, si bien el desafío original presenta un escenario multilingüe, existe una necesidad palpable de desarrollar y evaluar soluciones específicamente optimizadas para el español, un idioma con una gran relevancia geográfica y demográfica a nivel global que, no obstante, a menudo no recibe una atención adecuada en el desarrollo de modelos.

Muchos de los modelos multilingües de propósito general, aunque incluyen el español en su entrenamiento, suelen estar optimizados primordialmente para el inglés¹, lo que suele resultar en un rendimiento menor para otras lenguas menos predominantes. Este proyecto se centra en una aproximación especializada, que contemple las particularidades del español y busque mejorar su rendimiento en la tarea en cuestión. Sin embargo, la complejidad añadida de los marcadores de género en los títulos profesionales (e.g., “director”-“directora”, “abogado”-“abogada”) representa un desafío técnico particular que no será abordado en profundidad en este trabajo, aunque sí se estudiarán las propuestas existentes por parte del resto de competidores de la tarea.

Además, la disponibilidad del benchmark público de TalentCLEF, que incluye un corpus en español anotado a partir de datos reales (Gasco et al., 2025b), ofrece una oportunidad única para investigar este problema de forma rigurosa y reproducible. Así, este trabajo no solo busca contribuir al avance de la tecnología en el ámbito de la HCM, sino también ofrecer soluciones prácticas que puedan ser implementadas en entornos reales, facilitando así la adaptación de profesionales y organizaciones a un mercado laboral en constante evolución.

1.2. Definición del problema

Este trabajo se centra en la resolución de la primera tarea de la campaña de evaluación TalentCLEF 2025. TalentCLEF es la primera campaña de evaluación enfocada en la gestión de titulaciones profesionales y habilidades (*Skill*

¹Cabe destacar que, en cuanto a presencia en la web, el inglés es el que más presencia tiene, con un 49%, y el segundo es el español, con un 6% (W3Techs, 2023). Como consecuencia, la mayoría de los modelos de NLP están optimizados para el inglés (Guo et al., 2025).

and Job Title Intelligence), diseñada para abordar la escasez de benchmarks públicos y abiertos en el dominio de la HCM (Gasco et al., 2024).

El problema específico que se aborda es la **Tarea A: Emparejamiento Multilingüe de Titulaciones Profesionales (Multilingual Job Title Matching)**. El objetivo de esta tarea es desarrollar sistemas que, dada una titulación profesional (*query*), identifiquen y generen una lista ordenada (*ranking*) de las titulaciones más similares extraídas de una base de conocimiento (*corpus elements*). Esta capacidad es fundamental para los sistemas de recomendación de candidatos y la adquisición de talento en entornos reales.

El desafío propuesto por TalentCLEF 2025 es multilingüe y cubre cuatro idiomas: inglés, español, alemán y chino, donde los conjuntos de datos proporcionados se componen de tres particiones (entrenamiento, validación y test) con orígenes marcadamente distintos. El conjunto de validación y testeo de la tarea se construyeron a partir de datos reales de solicitudes de empleo, que fueron cuidadosamente anonimizados y anotados manualmente. Las *queries* de la tarea se definen como los títulos de las ofertas de trabajo, mientras que los *corpus elements* a clasificar se han extraído de los títulos de los últimos puestos de trabajo de los candidatos que aplicaron a dichas ofertas. Por otro lado, el conjunto de entrenamiento, disponible únicamente para inglés, español y alemán, se generó de forma automática extrayendo pares de titulaciones profesionales relacionadas de la taxonomía ESCO (Habilidades, Competencias, Cualificaciones y Ocupaciones Europeas).

La evaluación oficial de la **Tarea A** se estructura en cuatro escenarios distintos:

- Una evaluación monolingüe para inglés, español y alemán.
- Una evaluación multilingüe, con consultas en inglés contra corpus en español y alemán.
- Una sub-tarea voluntaria para el idioma chino, para el cual no se proporcionaron datos de entrenamiento.
- Una evaluación específica del sesgo de género para español y alemán, también voluntaria.

La métrica de evaluación principal para la clasificación es el **Precisión Media Promedio (MAP)**, mientras que para la evaluación del sesgo se utiliza el **Superposición Sgada por Rango (RBO)**.

Esto se hace así?
Para dejar nombrada la nomenclatura que usare en el resto del documento.

Debería extenderme más? Entrar en detalle sobre los metodos de evaluación especificos de la tarea, los pipelines de construcción de los datos... O quizás hablar mas del enfoque en español?

Si bien el desafío abarca múltiples idiomas, este trabajo se enfoca particularmente en el desarrollo y evaluación de soluciones optimizadas para el español, aprovechando la disponibilidad del corpus anotado y el benchmark público que ofrece la competición.

1.3. Propuesta y objetivos

Este trabajo de fin de máster se centra en el desarrollo y evaluación de un sistema optimizado para el emparejamiento de titulaciones profesionales en español dentro del marco establecido por la Tarea A de TalentCLEF 2025. La propuesta principal consiste en la búsqueda, adaptación y evaluación exhaustiva de modelos transformer que maximicen el rendimiento en la tarea de recuperación de información definida, con especial énfasis en el escenario monolingüe español.

Los objetivos específicos que se persiguen son los siguientes:

- **Análisis del estado del arte:** Investigar en profundidad las aproximaciones y arquitecturas que han demostrado mayor efectividad en tareas de similitud semántica y recuperación de información multilingüe, prestando especial atención a los modelos encoder-based que mostraron mejores resultados en la competición original.
- **Selección y adaptación de modelos:** Identificar y seleccionar modelos transformer pre-entrenados multilingües con demostrada eficacia en español, para su posterior adaptación mediante técnicas de fine-tuning específicas para la tarea de emparejamiento de titulaciones profesionales.
- **Diseño de estrategias de entrenamiento:** Implementar y comparar diferentes estrategias de aprendizaje, con especial atención a las técnicas de [CL \(aprendizaje contrastivo\)](#) y funciones de pérdida como InfoNCE o GIST, que han demostrado ser particularmente efectivas en tareas de similitud semántica según los resultados reportados en TalentCLEF 2025.
- **Evaluación exhaustiva:** Realizar una evaluación rigurosa tanto en el conjunto de desarrollo local como en la plataforma Codabench, empleando la métrica MAP como indicador principal de rendimiento, y

estableciendo comparativas con los sistemas participantes en la competición original.

- **Análisis de especialización para español:** Evaluar específicamente la efectividad de las soluciones desarrolladas en el contexto del idioma español, analizando si un enfoque especializado permite superar el rendimiento de aproximaciones multilingües generalistas.

Resumen de resultados. _____

Pendiente de completar una vez tenga los resultados finales.

1.4. Estructura del documento

Breve descripción de los capítulos del trabajo. _____

Creo que toda esta sección no hace falta. Preguntar a Laura.

Capítulo 1. Introducción. Este capítulo introduce los principales motivos que han llevado a la realización de este trabajo, así como la problemática y el estado actual de la disciplina. Por último, se presentan las diferentes contribuciones del trabajo realizado.

Capítulo 2. Estado del arte. Este capítulo describe en mayor detalle la disciplina que nos ocupa, presentando su origen y su historia hasta el presente. Se muestran las técnicas actuales más utilizadas para resolver las tareas más relevantes del tema abordado, así como sus debilidades.

Capítulo 3. Sistema/Método/Caso de Estudio propuesto. En este capítulo se describe en profundidad el sistema/método o caso de estudio propuesto.

Capítulo 4. Evaluación. Este capítulo describe la metodología utilizada para evaluar la propuesta realizada, a la vez que presenta los resultados obtenidos al evaluar el método propuesto en diferentes tareas y sobre colecciones de evaluación de distintos dominios.

Capítulo 5. Discusión. Este capítulo analiza y discute en profundidad los resultados obtenidos en la evaluación presentada en el capítulo anterior.

Capítulo 6. Conclusiones y trabajo futuro. Este capítulo recopila las diferentes conclusiones extraídas del trabajo realizado, y propone algunas líneas de trabajo futuro.

Capítulo 2

Estado del arte

2.1. Historia del problema

El [Emparejamiento de Titulaciones Profesionales \(JTM\)](#) constituye una tarea central dentro del campo más amplio de la gestión del talento y la [HCM](#). En su forma básica, el problema consiste en determinar la equivalencia o el grado de compatibilidad entre títulos de puestos, a pesar de la enorme variabilidad léxica, la polisemia y las convenciones internas de las organizaciones. Esta variabilidad hace que una misma ocupación pueda aparecer bajo campos muy distintos y, a su vez, que títulos idénticos traduzcan responsabilidades distintas según el contexto organizativo, sectorial o geográfico.

2.1.1. Métodos tradicionales y enfoques económicos

Históricamente, los trabajos sobre emparejamiento laboral han adoptado perspectivas tanto técnicas como económicas. En economía laboral española existe una persistencia en el proceso de emparejamiento que muestra cómo las fricciones de mercado y la heterogeneidad ocupacional condicionan los resultados del matching laboral ([De Toledo, Núñez, y Usabiaga, 2008](#)). Esos estudios clásicos proporcionan un marco para interpretar por qué la normalización de titulaciones no es sólo un problema lingüístico, sino también institucional y estructural: la misma denominación puede implicar distintas funciones y niveles de especialización en diferentes segmentos del mercado laboral ([de Toledo Saavedr, Hernández, y Ibáñez, 2017](#)).

Desde el punto de vista computacional, los primeros abordajes aplicados

al dominio laboral siguieron estructuras generales de recuperación de información y clasificación de texto: normalización de cadenas, reglas heurísticas y distintas métricas de similitud. Aunque estas técnicas (y los sistemas basados en reglas) pueden ser útiles en entornos controlados, su coste de mantenimiento y su fragilidad frente a sinónimos, abreviaturas y errores hacen que resulten insuficientes para datos del mundo real y escalas grandes (Jirjees et al., 2025).

2.1.2. Transición hacia técnicas de aprendizaje automático

La llegada y consolidación del [Aprendizaje Automático \(ML\)](#) transformó la investigación y la práctica en [JTM](#). Durante los últimos años, la literatura documenta un amplio abanico de técnicas: desde modelos supervisados clásicos hasta arquitecturas neuronales que aprenden representaciones textuales más ricas y robustas frente al ruido y la variabilidad (Jirjees et al., 2025). Han comenzado a surgir soluciones no supervisadas y semi-supervisadas para detectar patrones, agrupar titulaciones y reducir la dependencia de grandes volúmenes de anotación manual (Mamani Rodriguez, 2022b; Mamani Rodriguez, 2022a).

Específicamente en entornos hispanohablantes, trabajos recientes han explorado procesos de clustering y pipelines de [ML](#) no supervisado para identificar la demanda social de puestos y determinar similitudes entre títulos de profesionales de sectores específicos. Estas contribuciones muestran que, aunque las técnicas de clustering capturan agrupaciones útiles, su sensibilidad a la representación textual y su capacidad de generalización condiciona fuertemente la calidad del emparejamiento.

En cuanto a los análisis bibliométricos sobre investigación en esta tarea revelan un crecimiento sostenido del interés científico en la intersección entre [AI](#) y reclutamiento por parte de la [Gestión de Recursos Humanos \(HRM\)](#), con aplicaciones que abarcan desde selección automatizada hasta orientación profesional y análisis de brechas de competencias (Rojas-Galeano, Posada, y Ordoñez, 2022). Dichos trabajos también evidencian que, aunque existen esfuerzos notables en sectores como la salud o la tecnología, persiste una desproporción entre la disponibilidad de recursos en inglés y en otras lenguas, lo que limita la comparabilidad y la replicabilidad de soluciones en contextos locales.

2.1.3. Del problema de clasificación a la tarea de *matching* en entornos reales

Una distinción clave que ha emergido en la literatura reciente es la diferencia entre (i) la clasificación contra una taxonomía canónica y (ii) el matching o ranking entre pares de textos libres (oferta vs. perfil solicitante). Mientras la clasificación se beneficia de puntos de referencia estables, el matching real debe lidiar con ruido, abreviaturas, títulos internos y asimetrías informativas que no aparecen en taxonomías limpias. En consecuencia, las soluciones más robustas tienden a combinar representaciones semánticas aprendidas con estrategias de evaluación y depuración específicas del dominio, integrando tanto medidas globales de similitud como señales estructurales extraídas del mercado laboral (Gasco et al., 2025a).

2.2. Enfoques abordados en TalentCLEF

La Tarea A de TalentCLEF 2025, centrada en el Multilingual JTM, atrajo una variedad de enfoques que buscaron resolver el desafío de alinear semánticamente títulos de trabajo en inglés, español, alemán y, opcionalmente, chino. El análisis de las soluciones presentadas por los participantes revela una fuerte tendencia hacia el uso de modelos de lenguaje basados en Transformers, aunque las estrategias de implementación, entrenamiento y uso de recursos externos variaron significativamente.

2.2.1. Estrategias Dominantes

La mayoría de las soluciones giraron en torno a modelos de *Sentence Transformers* multilingües preentrenados, como MPNet (Brikman, Sana, y Ruegger, 2025), JobBERT (Decorte, De Lange, y Van Haute, 2025) o variantes de SBERT (Nizami et al., 2025; Bhangale, Gabhane, y Kumar, 2025). El objetivo común fue la generación de embeddings en un espacio semántico compartido, donde títulos de trabajo equivalentes en diferentes idiomas tuvieran una alta similitud¹.

Un hallazgo clave, destacado por el equipo NLPnorth (Zhang y van der Goot, 2025), fue la comparación directa de tres métodos de ajuste fino:

¹La similitud medida en los espacios vectoriales generados fue la similitud coseno, elegida de forma unánime entre todas las propuestas de solución al problema.

- **Discriminativo (Clasificación):** Reformular la tarea como una clasificación binaria (si dos títulos coinciden o no), generando para ello pares negativos.
- **Contrastivo:** Entrenar el modelo para acercar las representaciones de pares positivos y alejar las de pares negativos.
- **Basado en Prompts:** Utilizar LLMs para evaluar la similitud.

Los resultados de NLPnorth sugirieron que el aprendizaje contrastivo fue su estrategia más efectiva.

Otros equipos, como UDII-UPM ([Rodríguez-Vidal et al., 2025](#)), exploraron el rendimiento de modelos preentrenados sin ajuste fino, aplicando un enfoque *zero-shot*, proponiendo una fusión de representaciones semánticas de diferentes modelos para robustecer el matching. Por el contrario, el equipo Pjmathematician utilizó embeddings GIST e incorporó datos generados mediante LLMs ([Vachharajani, 2025](#)).

2.2.2. El Rol Crítico de Recursos Externos

El uso de la taxonomía [ESCO](#) fue un diferenciador clave para varias de las soluciones de mayor rendimiento.

Uso de ESCO

La taxonomía [ESCO](#) no solo sirvió como base de conocimiento, sino también como fuente de datos de entrenamiento. El equipo VerbaNex ([Novoa et al., 2025](#)) utilizó las relaciones jerárquicas de ESCO para generar automáticamente pares adicionales positivos y negativos, ajustando su modelo para crear un espacio semántico alineado con la taxonomía. De manera similar, NLPnorth ([Zhang y van der Goot, 2025](#)) también extrajo datos adicionales de ESCO para su entrenamiento².

Otros equipos adoptaron un enfoque híbrido. El sistema de dos etapas de Rodríguez et al. ([Rodríguez, Perez-de Viñaspre, y Perez, 2025](#)) utilizó [ESCO](#) como un primer filtro o sistema de recuperación de candidatos, para luego refinar la lista de candidatos mediante un LLM en una etapa de *re-ranking*.

²Cabe destacar que el conjunto de datos de entrenamiento ya habían sido generado por la organización y se encontraba a disposición de los participantes. Sin embargo, conociendo la procedencia y método de producción de este set de datos, algunos participantes decidieron aumentar dicho set para una mejor generalización de los modelos en el aprendizaje.

Uso de LLMs

Además del *re-ranking* mencionado, varios equipos utilizaron algún [Modelo de Lenguaje Grande \(LLM\)](#) para la generación de datos. El equipo NT ([Nga, Tuyen, y Van Thin, 2025](#)) propuso un sistema basado en la generación de descripciones de trabajo mediante LLMs, seguida de una recuperación de información. Sin embargo, su rendimiento fue bastante limitado en comparación con otros enfoques basados en Transformers.

2.2.3. Gestión de Escenarios Multilingües y Cross-Lingües

El desafío principal de la tarea era la correcta alineación semántica entre idiomas.

- **Espacio Semántico Compartido:** La estrategia dominante fue el uso de codificadores multilingües (SBERT, MPNet) ajustados para proyectar todos los idiomas en un único espacio vectorial ([Brikman, Sana, y Ruegger, 2025](#); [Nizami et al., 2025](#); [Novoa et al., 2025](#)).
- **Inglés como Lengua Pivote:** El equipo de Rodríguez et al. ([Rodríguez, Perez-de Viñaspre, y Perez, 2025](#)) investigó explícitamente el uso del inglés como idioma pivote, traduciendo los títulos de otros idiomas al inglés antes de la comparación, una estrategia que demostró mejorar el rendimiento en algunos escenarios cross-lingües.
- **Recuperación Híbrida:** El equipo AlexU-NLP ([Barakat et al., 2025](#)) propuso un sistema de recuperación híbrido con un enfoque de *curriculum learning*, diseñado para gestionar la dificultad progresiva de los pares multilingües.

2.2.4. Consideraciones Específicas: Chino y Sesgo de Género

Aunque la mayoría de los participantes se centraron en inglés, español y alemán, la tarea incluía dos consideraciones importantes: el idioma chino y la evaluación del sesgo de género.

El Caso del Chino

El idioma chino (en pares *zh-zh* y *en-zh*) fue una pista opcional dentro de la Tarea A. Sin embargo, la mayoría de los trabajos centraron sus esfuerzos

en los idiomas europeos, debido a que el chino no se encontraba dentro de los datos de entrenamiento, sino únicamente en validación y testeo, con la intención de evaluar la capacidad multilingue de las distintas propuestas.

Evaluación del Sesgo de Género

Una componente evaluativa clave de la tarea fue la medición del sesgo de género. En idiomas como el español y el alemán, donde los títulos de trabajo pueden tener marcas explícitas de género, se evaluó cómo las distintas soluciones manejaban estas diferencias, para evaluar si los sistemas perpetuaban o mitigaban sesgos de género en sus predicciones. Los datos de la competición incluían anotaciones ocultas de género y expresiones con marcas de género para permitir este análisis. La organización proponía buscar un sistema que minimizara las diferencias de rendimiento entre títulos de trabajo asociados a diferentes grupos de género.

A pesar de que esta evaluación fue central, pocos trabajos de los participantes detallaron explícitamente las técnicas de mitigación del sesgo que aplicaron. La mayoría de los sistemas se centraron en la precisión del matching semántico. Los trabajos de NLPnorth y de Ixa evaluaron este tema con detenimiento, consiguiendo una puntuación perfecta en la métrica de sesgo de género.

2.3. Transformers para Semejanza Semántica

Los transformers han sido la palanca tecnológica dominante en las tareas de comprensión y comparación semántica de textos desde su aparición. En el contexto de la tarea, su adopción no sólo ha permitido avances significativos en calidad de ranking, sino que ha generado un conjunto diverso de arquitecturas y estrategias de uso que conviene desglosar.

2.3.1. Definición y características

Un transformer es una arquitectura de red neuronal basada principalmente en mecanismos de atención que procesan secuencias sin recurrir a operaciones recurrentes o convolucionales. La atención permite que cada posición de entrada sintetice información de todas las demás posiciones mediante pesos aprendidos; esto facilita la captura de relaciones de largo

Revisar nombre de equipos y de autores, para que haya unificación en la forma en la que los llamo.

No se si todas las palabras del inglés deben ponerse en cursiva o no hace falta.

alcance, la paralelización durante el entrenamiento y la construcción de representaciones contextualizadas de tokens y oraciones (Vaswani et al., 2017). Aunque el diseño original incluye bloques de encoder y decoder, la práctica moderna para tareas de recuperación y matching usa variantes sólo-encoder (para embeddings), encoder-decoder y modelos sólo-decoder (para LLM) según el uso concreto.

2.3.2. Su utilización en la tarea

En la práctica aparecen tres patrones arquitectónicos generales, con variantes e intermedios frecuentes:

Bi-encoders (sentence-transformers / dual encoders)

Cada query se codifica por separado con el mismo encoder para producir vectores en un espacio semántico compartido, y usa la similitud entre vectores para ordenar candidatos. Este esquema es ideal cuando se requiere recuperar a escala porque la indexación de vectores y la búsqueda aproximada permiten latencias bajas. Su principal fortaleza es la eficiencia en la fase de inferencia; su principal limitación es que la interacción entre consulta y candidato es sólo implícita en el espacio vectorial, por lo que puede fallar a la hora de resolver matices finos que requerirían un cotejo token-a-token.

Cross-encoders (re-rankers y matchers de interacción)

Un cross-encoder toma la pareja (consulta, candidato) y las procesa juntas, produciendo una puntuación que refleja la compatibilidad tras un proceso de atención en ambas direcciones. Proporciona decisiones más precisas porque permite interacciones finas entre las dos secuencias, capturando coincidencias léxicas localizadas, supresiones y dependencias sintácticas que un bi-encoder puede pasar por alto. Sin embargo, el coste computacional es mucho más alto. Con esta técnica no es viable aplicar cross-encoders exhaustivamente sobre grandes conjuntos sin una fase previa de filtrado. Por ello se emplean habitualmente como re-rankers sobre un conjunto reducido (top-k) obtenido con otros métodos menos costosos. La práctica de combinar un retrieval rápido y re-ranking posterior ha quedado consolidada como patrón de diseño en sistemas de [Recuperación de Información \(IR\)](#) modernos (Inc., 2024; Xu et al., 2025).

Modelos autoregresivos y LLMs para generación y scoring

Los modelos autoregresivos se han usado de forma complementaria: para generar descripciones adicionales de un título, traducir o normalizar textos, crear negativos/positivos sintéticos, o para puntuar directamente parejas mediante prompting. Ofrecen flexibilidad y poder de razonamiento, pero también son muy propensos a la generación de ruido. Requieren de un control cuidadoso y suelen tener costes computacionales y de infraestructura elevados.

2.3.3. Técnicas de entrenamiento específicas para mejorar la calidad del ranking

El rendimiento de los transformers depende tanto de la arquitectura como de la estrategia de entrenamiento y de la calidad de los datos usados. En la tarea se observan varias técnicas que marcan la diferencia:

- **Entrenamiento contrastivo:** las técnicas contrastivas, como por ejemplo [Estimación de Contraste de Ruido de Información \(InfoNCE\)](#), acercan los pares positivos de vectores y separan los negativos. Una selección inteligente de negativos mejora la discriminación del espacio semántico y reduce falsos positivos en los rankings. Técnicas recientes que centran su foco en la selección de negativos han mostrado ganancias notables en el fine-tuning de embeddings ([Solatorio, 2024](#)).
- **Variantes de las técnicas contrastivas:** existen algunas modificaciones, como focal-[InfoNCE](#), que tratan de penalizar más los errores en ejemplos difíciles y estabilizan el aprendizaje cuando existe un desbalance fuerte entre positivos y negativos. Con ello consiguen mejorar la capacidad de priorizar los verdaderos positivos en los primeros puestos del ranking ([Hou y Li, 2023](#)).
- **Curriculum learning:** comenzar con negativos fáciles y evolucionar hacia negativos más difíciles (o introducir negativos guiados por similitud léxica/semántica) puede estabilizar el entrenamiento y evitar que el modelo colapse ante una distribución “long-tail” de títulos.
- **Fine-tuning multilingüe:** ajustar modelos multilingües con datos balanceados por idioma puede ayudar a alinear representaciones cross-

lingües y a reducir la fragmentación de la representación del embedding. Algunos métodos modernos de entrenamiento masivo multilingüe han demostrado que el aprendizaje dirigido para varios idiomas simultáneamente mejora la transferencia entre pares idiomáticos (Mao, Chu, y Kurohashi, 2024).

No se si debo entrar más en detalle sobre InfoNCE o técnicas concretas que vaya a usar en el modelo, o si las debo explicar luego en otra sección.

Capítulo 3

Sistema/Método/Caso de Estudio propuesto

En este capítulo se describe en profundidad el sistema/método o caso de estudio propuesto. La organización de este capítulo dependerá sustancialmente del trabajo abordado.

3.1. Ejemplo sección

3.1.1. Ejemplo subsección

Capítulo 4

Evaluación

Este capítulo describe la metodología utilizada para evaluar el sistema/método o caso de estudio propuesto, a la vez que presenta los resultados obtenidos en la evaluación de las diferentes tareas y sobre colecciones de evaluación de distintos dominios. Algunos ejemplos de secciones pueden ser estos:

4.1. Metodología de evaluación

4.2. Métricas de evaluación

4.3. Colecciones de evaluación

4.4. Resultados

Capítulo 5

Discusión

Este capítulo analiza y discute en profundidad los resultados obtenidos en la evaluación presentada en el capítulo anterior. La estructura de este capítulo dependerá del tema del trabajo y de la estructura del capítulo anterior.

5.1. Ejemplo sección

5.1.1. Ejemplo subsección

Capítulo 6

Conclusiones y trabajo futuro

Este capítulo recopila las diferentes conclusiones extraídas del trabajo realizado, y propone algunas líneas de trabajo futuro. Las siguientes secciones son las que suelen contener este tipo de capítulos, aunque pueden variar dependiendo del tema del trabajo.

6.1. Conclusiones

6.2. Trabajo futuro

No exceder las
75-80 páginas.

Bibliografía

Bibliografía

- [Barakat et al.2025] Barakat, Rana, Omar Mokhtar, Marwan Torki, y Nagwa Elmakky. 2025. Alexu-nlp at talentclef 2025: curriculum-driven hybrid retrieval for multilingual job title matching. *CLEF (Working Notes)*.
- [Bhangale, Gabhane, y Kumar2025] Bhangale, C, P Gabhane, y MA Kumar. 2025. Fine-tuned sentence transformer for multilingual job title matching. *CLEF (Working Notes)*.
- [Brikman, Sana, y Ruegger2025] Brikman, Adam, Michael Sana, y Holden Ruegger. 2025. Multilingual job title matching with mpnet-based sentence transformers. *CLEF (Working Notes)*.
- [De Toledo, Núñez, y Usabiaga2008] De Toledo, Pablo Álvarez, Fernando Núñez, y Carlos Usabiaga. 2008. La función de emparejamiento en el mercado de trabajo español. *Revista de economía aplicada*, 16(48):5–35.
- [de Toledo Saavedr, Hernández, y Ibáñez2017] de Toledo Saavedr, Pablo Álvarez, Fernando Núñez Hernández, y Carlos Usabiaga Ibáñez. 2017. ¿quién se empareja con quién en el mercado laboral español? un análisis cluster basado en la muestra continua de vidas laborales. *Investigación económica*, 76(299):87–124.
- [Decorte, De Lange, y Van Haute2025] Decorte, Jens-Joris, Matthias De Lange, y Jeroen Van Haute. 2025. Multilingual jobbert for cross-lingual job title matching. *arXiv preprint arXiv:2507.21609*.
- [Gasco et al.2024] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2024. Motivation — talentclef.github.io. <https://talentclef>.

- github.io/talentclef/docs/talentclef-2025/motivation/. [Accessed 10-11-2025].
- [Gasco et al.2025a] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2025a. Brief overview of talentclef 2025. *Journal of knowledge management*.
- [Gasco et al.2025b] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2025b. Overview of the talentclef 2025: Skill and job title intelligence for human capital management. En *International Conference of the Cross-Language Evaluation Forum for European Languages*, páginas 464–485. Springer.
- [Guo et al.2025] Guo, Yanzhu, Simone Conia, Zelin Zhou, Min Li, Saloni Potdar, y Henry Xiao. 2025. Do large language models have an english accent? evaluating and improving the naturalness of multilingual llms. En *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, páginas 3823–3838.
- [Hou y Li2023] Hou, Pengyue y Xingyu Li. 2023. Improving contrastive learning of sentence embeddings with focal-infonce. *arXiv preprint arXiv:2310.06918*.
- [Inc.2024] Inc., Hugging Face. 2024. Retrieve & Re-Rank; Sentence Transformers documentation — sbert.net. https://sbert.net/examples/sentence_transformer/applications/retrieve_rerank/README.html. [Accessed 13-11-2025].
- [Jirjees et al.2025] Jirjees, Aram Khasro, Aram M Ahmed, Abdulhady Abas Abdulla, Joan Lu, Ekhlas Mohammed Noori, Rozhgar Nasradeen Kareem, Bryar A Hassan, Hadi Veisi, y Tarik A Rashid. 2025. Machine learning for recruitment: Analyzing job-matching algorithms. *Machine Learning*, 27:1.
- [Mamani Rodriguez2022a] Mamani Rodriguez, Zoraida. 2022a. Proceso de machine learning para determinar la demanda social de puestos de empleo de profesionales de ti. *Industrial Data*, 25(2):275–300.

- [Mamani Rodriguez2022b] Mamani Rodriguez, Zoraida Emperatriz. 2022b. Machine learning no supervisado en la detección de similitud de puestos de empleo de profesionales de ti. *Industrial Data*.
- [Mao, Chu, y Kurohashi2024] Mao, Zhuoyuan, Chenhui Chu, y Sadao Kurohashi. 2024. Ems: Efficient and effective massively multilingual sentence embedding learning. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 32:2841–2856.
- [Maslej et al.2025] Maslej, Nestor, Loredana Fattorini, Raymond Perrault, Yolanda Gil, Vanessa Parli, Njenga Kariuki, Emily Capstick, Anka Reuel, Erik Brynjolfsson, John Etchemendy, y others. 2025. Artificial intelligence index report 2025. *arXiv preprint arXiv:2504.07139*.
- [Nga, Tuyen, y Van Thin2025] Nga, Ho Thuy, Ho Thi Thanh Tuyen, y Dang Van Thin. 2025. Nt team at multilingual job title matching task a: job matching via large language model-based description generation and retrieval. *CLEF (Working Notes)*.
- [Nizami et al.2025] Nizami, Muhammad Hasan, Ahtisham Uddin, Muhammad Talha Salani, Ayesha Saeed, Faisal Alvi, y Abdul Samad. 2025. Enhancing human capital management: Ai techniques for candidate matching and skill extraction. *CLEF (Working Notes)*.
- [Novoa et al.2025] Novoa, Melissa Moreno, Juan Carlos Martinez-Santos, Jairo Serrano, y Edwin Puertas. 2025. Verbanex at talentclef2025: Semantic matching of multilingual job titles through a framework integrating esco taxonomy. *CLEF (Working Notes)*.
- [Ordóñez de Pablos y Lytras2008] Ordóñez de Pablos, Patricia y Miltiadis D Lytras. 2008. Competencies and human resource management: implications for organizational competitive advantage. *Journal of knowledge management*, 12(6):48–55.
- [Rodriguez, Perez-de Viñaspre, y Perez2025] Rodriguez, Mar, Olatz Perez-de Viñaspre, y Naiara Perez. 2025. A two-stage multilingual job title matching system: combining expert knowledge and llm-based ranking. *CLEF (Working Notes)*.

- [Rodríguez-Vidal et al.2025] Rodríguez-Vidal, Javier, Ascensión López-Vargas, PM Vigara Gallego, Francisco Javier Del Álamo, y A García-Beltrán. 2025. Udi-upm at talentclef 2025: task a-multilingual job title matching. *CLEF (Working Notes)*.
- [Rojas-Galeano, Posada, y Ordoñez2022] Rojas-Galeano, Sergio, Jorge Posada, y Esteban Ordoñez. 2022. A bibliometric perspective on ai research for job-résumé matching. *The Scientific World Journal*, 2022(1):8002363.
- [Solatorio2024] Solatorio, Aivin V. 2024. Gistembed: Guided in-sample selection of training negatives for text embedding fine-tuning. *arXiv preprint arXiv:2402.16829*.
- [Vachharajani2025] Vachharajani, Poojan. 2025. Pjmathematician at talentclef 2025: enhancing job title and skill matching with gistembed and llm-augmented data. *CLEF (Working Notes)*.
- [Vaswani et al.2017] Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, y Illia Polosukhin. 2017. Attention is all you need. *Advances in neural information processing systems*, 30.
- [W3Techs2023] W3Techs, A. 2023. Usage statistics of content languages for websites.
- [Xu et al.2025] Xu, Zhichao, Fengran Mo, Zhiqi Huang, Crystina Zhang, Puxuan Yu, Bei Wang, Jimmy Lin, y Vivek Srikumar. 2025. A survey of model architectures in information retrieval. *arXiv preprint arXiv:2502.14822*.
- [Zhang y van der Goot2025] Zhang, Mike y Rob van der Goot. 2025. Nl-pnorth@ talentclef 2025: Comparing discriminative, contrastive, and prompt-based methods for job title and skill matching. *arXiv preprint arXiv:2506.19058*.

Glosario

AI Artificial Intelligence (Inteligencia Artificial). [1](#), [8](#)

CL aprendizaje contrastivo (contrastive learning). [4](#)

ESCO European Skills, Competences, Qualifications and Occupations (Habilidades, Competencias, Cualificaciones y Ocupaciones Europeas). [3](#), [10](#)

HCM Human Capital Management (Gestión del Capital Humano). [1–3](#), [7](#)

HRM Human Resource Management (Gestión de Recursos Humanos). [8](#)

InfoNCE Information Noise-Contrastive Estimation (Estimación de Contraste de Ruido de Información). [14](#)

IR Information Retrieval (Recuperación de Información). [13](#)

JTM Job Title Matching (Emparejamiento de Titulaciones Profesionales). [7–9](#)

LLM Large Language Model (Modelo de Lenguaje Grande). [11](#), [13](#)

MAP Mean Average Precision (Precisión Media Promedio). [3](#)

ML Machine Learning (Aprendizaje Automático). [8](#)

NLP Natural Language Processing (Procesamiento del Lenguaje Natural). [1](#), [2](#)

RBO Rank Biased Overlap (Superposición Sesgada por Rango). [3](#)

Tarea A Tarea A: Emparejamiento Multilingüe de Titulaciones Profesionales (Multilingual Job Title Matching) de la campaña de evaluación TalentCLEF 2025. [3](#)

To-do list

I, Decidir Título

1, No se si hay que referenciar así. Preguntar a Laura.

3, Esto se hace asi? Para dejar nombrada la nomenclatura que usare en el resto del documento.

4, Debería extenderme más? Entrar en detalle sobre los metodos de evaluación especificos de la tarea, los pipelines de construcción de los datos... O quizás hablar mas del enfoque en español?

5, Pendiente de completar una vez tenga los resultados finales.

5, Creo que toda esta sección no hace falta. Preguntar a Laura.

12, Revisar nombre de equipos y de autores, para que haya unificación en la forma en la que los llamo.

12, No se si todas las palabras del inglés deben ponerse en cursiva o no hace falta.

15, No se si debo entrar más en detalle sobre InfoNCE o técnicas concretas que vaya a usar en el modelo, o si las debo explicar luego en otra sección.

23, No exceder las 75-80 páginas.