
Emparejamiento inteligente de titulaciones
profesionales: una propuesta basada en
Transformers optimizada para el español



Trabajo Fin de Máster

David García Curbelo

Trabajo de investigación para el

Máster en Lenguajes y Sistemas Informáticos

Universidad Nacional de Educación a Distancia

Dirigido por la

Prof. Dra. D. Laura Plaza Morales

24 de enero de 2026

Agradecimientos

A todo aquellos que me han apoyado en este pedregoso camino.

Resumen

Resumen.

Abstract

Resumen en inglés.

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Definición del problema	2
1.3. Propuesta y objetivos	4
1.4. Estructura del documento	5
2. Estado del arte	7
2.1. Fundamentos y Evolución de la Recuperación de Información	7
2.2. Estrategias de Refinamiento	10
2.3. Historia y Evolución del Emparejamiento de Titulaciones . .	12
2.4. Enfoques y Metodologías en TalentCLEF	14
2.4.1. Arquitecturas y Espacios Semánticos Compartidos . .	14
2.4.2. Paradigmas de Entrenamiento y Ajuste Fino	15
2.4.3. Ingeniería de Datos y Recursos Externos	15
2.4.4. Desafíos del Multilingüismo	16
2.4.5. Ética y Mitigación del Sesgo de Género	17
2.5. Transformers para Semejanza Semántica	17
2.5.1. Fundamentos de la Arquitectura Transformer	18
2.5.2. Paradigmas Arquitectónicos en la Recuperación de In- formación	18
2.5.3. Estrategias Avanzadas de Entrenamiento	19
3. Arquitectura del sistema	21
3.1. Visión general del flujo de trabajo	21
3.2. Descripción detallada de los módulos	22
3.2.1. Retrieval	22
3.2.2. Ranking Fusion	23
3.2.3. Re-ranking	25

3.3. Tecnologías y Estrategias de Aprendizaje	26
3.3.1. Librerías y Entorno	26
3.3.2. Funciones de Pérdida (Loss Functions)	26
3.3.3. Función de evaluación	27
3.4. Flujo de Trabajo Experimental	27
3.4.1. Fase 1: Zero-shot	27
3.4.2. Fase 2: Entrenamiento de Bi-encoders	28
3.4.3. Fase 3: Optimización de la Fusión	28
3.4.4. Fase 4: Implementación del Re-ranking	28
4. Evaluación	29
4.1. Entorno de desarrollo y especificaciones	29
4.2. Fase 1: Evaluación Zero-Shot	29
4.2.1. Selección y filtrado de modelos base	30
4.2.2. Resultados preliminares	31
4.3. Fase 2: Fine-Tuning	32
4.3.1. Configuración del entrenamiento	32
4.3.2. Resultados tras el entrenamiento	32
4.4. Fase 3: Ranking Fusion	34
4.4.1. Análisis comparativo de técnicas de fusión	34
4.4.2. Selección final de arquitectura	35
4.5. Re-Ranking	36
4.6. Evaluación sobre Test	36
5. Discusión	37
5.1. Ejemplo sección	37
5.1.1. Ejemplo subsección	37
6. Conclusiones y trabajo futuro	39
6.1. Conclusiones	39
6.2. Trabajo futuro	39
Bibliografía	41
Glosario	48
A. Tablas	49

Índice de Figuras

3.1. Esquema de la arquitectura en cascada del sistema propuesto: Recuperación multi-modelo, Fusión de rankings y Re-ranking semántico.	22
4.1. Dispersión del rendimiento (Precisión Media Promedio (MAP)) en evaluación Zero-Shot. El eje horizontal representa el tamaño del modelo (número de parámetros) en escala logarítmica.	31
4.2. Evolución de la función de pérdida para <i>medical_embedded_v4</i> (izq.) y <i>multilingual-e5-large-instruct</i> (der.). El incremento de la pérdida de validación tras la primera época justifica la decisión de realizar una parada temprana en la primera época.	32
4.3. Comparativa del rendimiento (MAP) de los 10 mejores modelos antes y después del ajuste fino.	33
4.4. Optimización del parámetro k en la técnica Fusión Recíproca de Rangos (RRF). El máximo local se sitúa en $k = 5$	34
4.5. Comparativa de las técnicas de fusión evaluadas en términos de MAP con respecto al valor máximo individual alcanzado por los modelos.	35

Índice de Tablas

4.1. Especificaciones técnicas del entorno de evaluación	30
4.2. Top 10 modelos preentrenados en evaluación Zero-Shot ordenados por MAP.	31
4.3. Resultados comparativos tras el entrenamiento de los 10 mejores modelos.	33
A.2. Muestra de los 75 mejores modelos extraídos del repositorio MTEB, ordenados por media de resultados obtenidos en los benchmarks asociados a la tarea de Retrieval.	50
A.1. Resultados completos de los 75 mejores modelos evaluados sobre la métrica MAP monolingüe en español en la evaluación zero-shot.	51

Capítulo 1

Introducción

1.1. Motivación

El panorama del mercado laboral actual está experimentando una gran transformación impulsada principalmente por la rápida evolución tecnológica y la incorporación de la [Inteligencia Artificial \(AI\)](#) en nuestras vidas. Estudios recientes indicaban que para finales de 2025, aproximadamente 90 millones de puestos de trabajo habrían sido automatizados, y una cantidad similar de ocupaciones que no existían a principios de siglo aparecerían en escena ([Maslej et al., 2025](#)). Esta dinámica de cambio constante, lejos de ser un fenómeno aislado, es consecuencia directa del desarrollo tecnológico, el cual no solo ha automatizado tareas rutinarias y creado roles completamente nuevos, sino que también ha redefinido la naturaleza misma de los puestos de trabajo existentes.

En este contexto de transición, la adaptabilidad se convierte en un factor clave tanto para los profesionales, que enfrentan una incertidumbre creciente sobre las competencias que serán relevantes a corto plazo, como para las organizaciones, que se ven obligadas a identificar talento con estas capacidades emergentes ([Ordóñez de Pablos y Lytras, 2008](#)). Esta necesidad ha fomentado la adopción de tecnologías de [Procesamiento del Lenguaje Natural \(NLP\)](#) en la [Gestión del Capital Humano \(HCM\)](#), con el objetivo de optimizar procesos de adquisición de talento, crear programas de formación personalizados y permitir una planificación estratégica basada en competencias.

Sin embargo, el desarrollo de estos sistemas inteligentes se enfrenta a limitaciones en su eficacia, equidad y generalización. Es precisamente en este

punto donde se sitúa la motivación principal de este trabajo, centrado en la Tarea A del TalentCLEF 2025, la cual pretende abordar el problema del emparejamiento de titulaciones profesionales (Gasco et al., 2025a). Además, si bien el desafío original presenta un escenario multilingüe, existe una necesidad palpable de desarrollar y evaluar soluciones específicamente optimizadas para el español, un idioma con una gran relevancia geográfica y demográfica a nivel global que, no obstante, a menudo no recibe una atención adecuada en el desarrollo de modelos de vanguardia.

Muchos de los modelos multilingües de propósito general, aunque incluyen el español en su entrenamiento, suelen estar optimizados primordialmente para el inglés, lo que suele resultar en un rendimiento menor para otras lenguas menos predominantes¹. Este proyecto se centra en una aproximación especializada, que contemple las particularidades del español y busque mejorar su rendimiento en la tarea en cuestión. Sin embargo, la complejidad añadida de los marcadores de género en las titulaciones profesionales representa un desafío técnico particular que, aunque no será abordado en profundidad en este trabajo, sí se estudiarán las propuestas existentes por parte del resto de participantes de la tarea en la sección 2.4.

Además, la disponibilidad del benchmark público de TalentCLEF, que incluye un corpus en español anotado a partir de datos reales (Gasco et al., 2025b), ofrece una oportunidad única para investigar este problema de forma rigurosa y reproducible. Así, este trabajo no solo busca contribuir al avance de la tecnología en el ámbito de la HCM, sino también ofrecer soluciones prácticas que puedan ser implementadas en entornos reales, facilitando así la adaptación de profesionales y organizaciones a un mercado laboral en constante evolución.

1.2. Definición del problema

Este trabajo se centra en la resolución de la primera tarea de la campaña de evaluación TalentCLEF 2025. TalentCLEF es la primera campaña de evaluación enfocada en la gestión de titulaciones profesionales y habilidades (*Skill and Job Title Intelligence*), diseñada para abordar la escasez de benchmarks

¹Cabe destacar que, en cuanto a presencia en la web, el inglés es el que más presencia tiene con un 49 %. El segundo puesto lo ocupa el español, con un 6 % (W3Techs, 2023). Como consecuencia, la mayoría de los modelos de NLP acaban estando optimizados para el inglés (Guo et al., 2025).

públicos y abiertos en el dominio de la HCM (Gasco et al., 2024).

El problema específico que se aborda es la **Tarea A: Emparejamiento Multilingüe de Titulaciones Profesionales** (Multilingual Job Title Matching). El objetivo de esta tarea es desarrollar sistemas que, dada una titulación profesional (*query*), identifiquen y generen una lista ordenada (*ranking*) de las titulaciones más similares extraídas de una base de conocimiento (*corpus elements*).

El desafío propuesto por TalentCLEF 2025 es multilingüe y cubre cuatro idiomas: inglés, español, alemán y chino, donde los conjuntos de datos proporcionados se componen de tres particiones: entrenamiento, validación y test, con orígenes marcadamente distintos. Los conjuntos de validación y testeo de la tarea se construyeron a partir de datos reales de solicitudes de empleo, que fueron cuidadosamente anonimizadas y anotadas manualmente. Las *queries* de la tarea se definen como los títulos de las ofertas de trabajo, mientras que los *corpus elements* a clasificar se han extraído de los títulos de los últimos puestos de trabajo de los candidatos que aplicaron a dichas ofertas. Por otro lado, el conjunto de entrenamiento (disponible únicamente para inglés, español y alemán) se generó de forma automática extrayendo pares de titulaciones profesionales relacionadas de la taxonomía ESCO (Habilidades, Competencias, Cualificaciones y Ocupaciones Europeas).

La evaluación oficial de la **Tarea A** se estructura en cuatro escenarios distintos:

- Una evaluación monolingüe para inglés, español y alemán.
- Una evaluación croslingüe, con queries en inglés contra corpus en español y alemán.
- Una sub-tarea voluntaria para el idioma chino, para el cual no se proporcionaron datos de entrenamiento.
- Una evaluación específica del sesgo de género para español y alemán, también voluntaria.

La métrica de evaluación principal para la clasificación es la **Precisión Media Promedio (MAP)**, mientras que para la evaluación del sesgo se utiliza la **Superposición Sesgada por Rango (RBO)**. La organización de la campaña proporciona una plataforma en Codabench² para la presentación y evalua-

²<https://www.codabench.org/competitions/5842/>

ción automática de las soluciones desarrolladas por los participantes. En ella, los sistemas son evaluados en el conjunto de testeo oculto, y los resultados se publican en un ranking público basado en la métrica [MAP](#), incluyendo desgloses por idioma y escenario.

Si bien el desafío abarca múltiples idiomas, este trabajo se enfoca particularmente en el desarrollo y evaluación de soluciones optimizadas para el español, aprovechando la disponibilidad del corpus anotado y el benchmark público que ofrece la competición.

1.3. Propuesta y objetivos

Este trabajo está centrado en el desarrollo y evaluación de un sistema optimizado para el emparejamiento de titulaciones profesionales en español dentro del marco establecido por la [Tarea A](#) de TalentCLEF 2025. Este desarrollo estará centrado en la búsqueda, adaptación y evaluación exhaustiva de modelos con arquitectura Transformer que maximicen el rendimiento en la tarea de recuperación de información definida, con especial énfasis en el escenario monolingüe del español.

Los objetivos específicos que se persiguen son los siguientes:

- **Análisis del estado del arte:** Investigar en profundidad las aproximaciones y arquitecturas que han demostrado mayor efectividad en tareas de similitud semántica y recuperación de información multilingüe, prestando especial atención a los modelos que mostraron mejores resultados en la competición original.
- **Selección y adaptación de modelos:** Identificar y seleccionar modelos transformer pre-entrenados multilingües con demostrada eficacia en español, para su posterior adaptación mediante técnicas de fine-tuning específicas para la tarea de ranking definida.
- **Diseño de estrategias de entrenamiento:** Implementar y comparar diferentes estrategias de aprendizaje, con especial atención a las técnicas de [CL \(aprendizaje contrastivo\)](#), que ha demostrado ser particularmente efectivo en tareas de similitud semántica según los resultados reportados en TalentCLEF 2025.
- **Evaluación exhaustiva:** Realizar una evaluación rigurosa tanto en el conjunto de desarrollo local como en la plataforma Codabench, em-

pleando la métrica MAP como indicador principal de rendimiento, y estableciendo comparativas con los sistemas participantes en la competición original.

- **Análisis de especialización para español:** Evaluar específicamente la efectividad de las soluciones desarrolladas en el contexto del idioma español, analizando si un enfoque especializado permite superar el rendimiento de aproximaciones multilingües generalistas.

1.4. Estructura del documento

Capítulo 1. Introducción. Este capítulo introduce los principales motivos que han llevado a la realización de este trabajo, así como la problemática y los objetivos planteados para abordar el problema en cuestión.

Capítulo 2. Estado del arte. Este capítulo describe en mayor detalle la disciplina que nos ocupa, presentando su origen y su historia hasta el presente. Se muestran las técnicas actuales más utilizadas para resolver las tareas más relevantes del tema abordado.

Capítulo 3. Arquitectura del sistema propuesto. En este capítulo se detalla la arquitectura del sistema desarrollado, describiendo las decisiones tomadas en cuanto a modelos, técnicas de entrenamiento y demás aspectos relevantes para la implementación del sistema.

Capítulo 4. Evaluación. Este capítulo presenta los resultados obtenidos tras la evaluación del sistema propuesto, incluyendo análisis detallados del rendimiento alcanzado.

Capítulo 5. Discusión. En este capítulo se discuten los resultados obtenidos en el capítulo anterior, comparándolos con los de otros sistemas y analizando las fortalezas y debilidades del enfoque propuesto.

Capítulo 6. Conclusiones y trabajo futuro. Finalmente, este capítulo resume las principales conclusiones extraídas del trabajo realizado y propone posibles líneas de investigación futura que podrían derivarse de este proyecto.

Capítulo 2

Estado del arte

2.1. Fundamentos y Evolución de la Recuperación de Información

La disciplina de la [Recuperación de Información \(IR\)](#) constituye uno de los pilares angulares de las ciencias de la computación modernas, respondiendo a la necesidad crítica de acceder, filtrar y organizar datos relevantes dentro de corpus documentales en constante expansión.

Antes de profundizar en las particularidades del dominio que nos ocupa, resulta necesario establecer un marco teórico que analice la trayectoria histórica de la disciplina. Esta evolución no es lineal, sino que representa una transformación de paradigmas: desde los primeros sistemas basados en reglas deterministas y coincidencias exactas, hacia arquitecturas híbridas contemporáneas que integran inferencia estadística y aprendizaje profundo. Comprender este tránsito es fundamental para contextualizar las limitaciones de los enfoques tradicionales y justificar la necesidad de modelos de ranking avanzados.

Del Determinismo a la Similitud Estadística

El origen de los sistemas de [IR](#) se encuentra en los modelos booleanos, predominantes durante las primeras décadas de la computación comercial. Estos sistemas operaban bajo una lógica de conjuntos estricta, fundamentada en el álgebra booleana, donde la satisfacción de una consulta dependía exclusivamente de la presencia o ausencia binaria de términos indexados. En este esquema, un documento era considerado relevante si, y solo si, cumplía

con las condiciones exactas de la consulta. Aunque este enfoque ofrecía una alta predictibilidad y una eficiencia computacional presentaba una incapacidad para establecer una jerarquía de relevancia, además de ser vulnerable a la ambigüedad propia del lenguaje natural.

La verdadera revolución en la IR llegó con la introducción del concepto de “ordenación por relevancia”. Esta se materializó a través del Modelo de Espacio Vectorial, el cual transformó la representación de documentos y consultas en vectores dentro de un espacio multidimensional (Salton, Wong, y Yang, 1975). Esta abstracción algebraica permitió, por primera vez, calcular el grado de similitud entre una consulta y un documento mediante operaciones geométricas, como el coseno del ángulo entre vectores.

Posteriormente, la comunidad científica avanzó hacia marcos teóricos más robustos, dando lugar a los modelos probabilísticos. Estos enfoques se basan en el Principio de Ranking de Probabilidad, que postula que un sistema de recuperación es óptimo si ordena los documentos de manera decreciente según su probabilidad de ser relevantes para el usuario. La culminación de esta familia de modelos es el algoritmo BM25, una función de ranking que refina la ponderación clásica introduciendo normalización por longitud de documento y saturación de frecuencia de términos (Robertson, Zaragoza, y others, 2009). A día de hoy, BM25 permanece como un estándar industrial de facto y una línea base difícil de superar en escenarios de recuperación léxica pura.

Sin embargo, a pesar de la solidez matemática de estos métodos tradicionales, todos comparten una limitación intrínseca: la dependencia exclusiva de la coincidencia léxica exacta. Estos modelos sufren del denominado *vocabulary mismatch*, un fenómeno donde documentos semánticamente relevantes son descartados simplemente porque no contienen los mismos términos que la consulta, fallando en capturar fenómenos lingüísticos complejos como la sinonimia y la polisemia. Esta incapacidad para interpretar el contexto semántico motivó la búsqueda de nuevas aproximaciones que pudieran superar estas barreras, dando lugar a la siguiente gran revolución en la IR.

El Papel del Aprendizaje Automático

La evolución de la IR alcanzó un punto de inflexión con la integración de técnicas de Aprendizaje Automático (ML), dando lugar al marco de trabajo conocido como Aprendizaje para Ordenación (LTR) (Liu y others, 2009).

Esta transición marcó el abandono de las funciones de relevancia estáticas y predefinidas en favor de modelos supervisados capaces de aprender funciones de ranking óptimas a partir de datos de entrenamiento.

La literatura académica clasifica tradicionalmente las aproximaciones de [LTR](#) en tres categorías fundamentales, diferenciadas por su función de pérdida y la estructura de sus datos de entrada:

- **Pointwise:** Trata el problema de la ordenación como una tarea de regresión o clasificación individual. Cada documento se evalúa de forma aislada frente a la consulta, asignándole una puntuación de relevancia absoluta.
- **Pairwise:** Transforma el problema en una clasificación binaria de pares de documentos. El objetivo es predecir, dado un par, cuál de los dos es más relevante para una consulta determinada.
- **Listwise:** Representa la aproximación más sofisticada, abordando la lista completa de documentos como la unidad de optimización. Estas funciones de pérdida intentan optimizar directamente métricas de evaluación de ranking, capturando de manera integral la estructura de la lista recuperada.

A pesar de que el [LTR](#) supuso un avance sustancial en la precisión de los sistemas de búsqueda, estos modelos dependían en gran medida de un ajuste de características manual y costoso. Esta dependencia limitaba su capacidad de generalización, especialmente en dominios caracterizados por una alta variabilidad lingüística o una semántica ambigua, donde las señales léxicas superficiales resultaban insuficientes para capturar la verdadera intención del usuario.

Recuperación Neuronal y Representaciones Densas

La reciente irrupción del [Aprendizaje Profundo \(DL\)](#) y, de manera más específica, la consolidación de las arquitecturas basadas en Transformers, han redefinido por completo los cimientos de la [IR](#) contemporánea. Este nuevo paradigma, denominado Recuperación Neuronal, propone una transición fundamental: el paso de la recuperación dispersa hacia la recuperación densa ([Karpukhin et al., 2020](#)). Mientras que los métodos tradicionales representan documentos como vectores de alta dimensionalidad pero escasamente

poblados (basados en términos exactos), los modelos neuronales proyectan tanto consultas como documentos en un espacio vectorial continuo de baja dimensionalidad, denominado espacio de embeddings.

En este espacio latente, la relevancia se mide por la proximidad geométrica entre vectores en un espacio denso. Esta capacidad de representación se apoya en modelos de lenguaje pre-entrenados que, mediante mecanismos de atención, logran capturar el contexto bidireccional de las palabras.

2.2. Estrategias de Refinamiento

El crecimiento exponencial en la escala de los corpus de texto ha acentuado una confrontación técnica fundamental en los sistemas de IR: el compromiso entre exhaustividad y precisión. Si bien los modelos neuronales profundos ofrecen una capacidad superior para capturar matices semánticos, su aplicación directa sobre colecciones de millones de documentos conlleva un coste computacional prohibitivo.

Esta limitación ha motivado la adopción generalizada de arquitecturas en cascada o de múltiples etapas. En este esquema, el objetivo de la fase inicial se desplaza hacia la maximización de la exhaustividad mediante métodos eficientes, delegando la optimización de la precisión a etapas posteriores. A continuación, se detallan las principales estrategias de refinamiento que operan sobre los resultados preliminares para depurar y reordenar el ranking final.

Re-ranking: Precisión mediante una interacción profunda

La técnica de re-ranking se fundamenta en la premisa de aplicar modelos de alta intensidad computacional exclusivamente sobre un subconjunto acotado de candidatos prometedores. En una arquitectura típica de *retrieve-and-rerank*, una primera etapa recupera una ventana de documentos candidatos (top- N). Posteriormente, esta selección es procesada por un modelo de re-ranking que, al operar sobre un volumen de datos drásticamente menor, puede emplear arquitecturas mucho más complejas.

La ventaja crítica de esta fase reside en la capacidad de evaluar interacciones semánticas profundas. A diferencia de los modelos de recuperación densa de tipo bi-encoders, que codifican consulta y documento de forma independiente, los modelos de re-ranking suelen ser modelos con arquitecturas

cross-encoders. Esto permite modelar la interacción término a término entre la consulta y el documento, capturando dependencias contextuales sutiles que son computacionalmente inviables durante la búsqueda masiva.¹

Fusión de Rankings: Robustez y Diversidad de Señales

De forma complementaria al re-ranking, la Fusión de Rankings aborda la varianza intrínseca y los sesgos particulares de los distintos paradigmas de recuperación. La literatura científica evidencia que diferentes familias de algoritmos tienden a recuperar subconjuntos disjuntos de documentos relevantes; por ejemplo, los métodos léxicos (como BM25) son robustos ante coincidencias exactas de palabras clave, mientras que los métodos semánticos destacan en la captura de similitudes conceptuales y sinonimias.

La motivación subyacente a la fusión es el principio de robustez: la agregación de múltiples listas de resultados provenientes de señales distintas tiende a mitigar los errores individuales y reforzar los aciertos comunes. Existen multitud de enfoques para la fusión de rankings, que van desde métodos simples como la suma o el promedio de posiciones, hasta algoritmos más sofisticados que ponderan las listas según su calidad histórica o su diversidad.

El Paradigma de las Arquitecturas Híbridas

En el panorama actual del estado del arte, la excelencia en tareas de recuperación no se define por la capacidad individual de una única técnica aislada, sino por la organización inteligente de múltiples capas de procesamiento. Se ha producido una transición clara hacia sistemas que integran la recuperación inicial híbrida (léxica y semántica) con fases posteriores de refinamiento mediante re-ranking y consolidación a través de fusión de listas.

Este enfoque modular ha demostrado ser la estrategia más eficaz para abordar la complejidad de las necesidades de información modernas². Históricamente se ha observado que la unión de diversas metodologías ge-

¹Trabajos como el de (Nogueira y Cho, 2019) son un ejemplo de ello, demostrando empíricamente que la incorporación de cross-encoders basados en BERT en la etapa de re-ranking mejora sustancialmente la calidad del ranking final, superando las limitaciones de los métodos puramente léxicos o con arquitecturas bi-encoders.

²Este hecho se ve reflejado en las propuestas de solución planteadas por los distintos participantes en la competición de TalentCLEF, como se detallará más en detalle en la sección 2.4.

nera sistemas significativamente más resilientes que sus componentes individuales. Este marco de trabajo híbrido constituye el fundamento sobre el que se construyen las soluciones de alta precisión actuales, permitiendo una adaptación flexible y robusta a dominios específicos, tal y como se requiere para la resolución de la tarea que nos ocupa.

2.3. Historia y Evolución del Emparejamiento de Titulaciones

Dentro de este marco, el [Emparejamiento de Titulaciones Profesionales \(JTM\)](#) se presenta como una aplicación especializada de estos principios dentro del ámbito de la gestión del talento y la [HCM](#). En su forma básica, el problema consiste en determinar la equivalencia o el grado de compatibilidad entre títulos de puestos de trabajo, a pesar de la enorme variabilidad léxica, la polisemia y las convenciones internas de las organizaciones. Esta variabilidad hace que una misma ocupación pueda aparecer bajo campos muy distintos y, a su vez, que títulos idénticos traduzcan responsabilidades distintas según el contexto organizativo, sectorial o geográfico.

Métodos tradicionales y enfoques económicos

Las investigaciones sobre [JTM](#) han adoptado perspectivas tanto técnicas como económicas. En el campo de la economía laboral española, por ejemplo, existe una persistencia en el proceso de emparejamiento que muestra cómo las fricciones de mercado y la heterogeneidad ocupacional condicionan los resultados del matching laboral ([De Toledo, Núñez, y Usabiaga, 2008](#)). Estos estudios proporcionan un marco para interpretar por qué la normalización de titulaciones no es sólo un problema lingüístico, sino también institucional y estructural: la misma denominación puede implicar distintas funciones y niveles de especialización en diferentes segmentos del mercado laboral ([de Toledo Saavedr, Hernández, y Ibáñez, 2017](#)).

Desde el punto de vista computacional, los primeros abordajes aplicados al dominio laboral siguieron estructuras generales de recuperación de información y clasificación de texto, basadas principalmente en normalización de cadenas y reglas heurísticas. Aunque estas técnicas (y los sistemas basados en reglas) pueden ser útiles en entornos controlados, su coste de mantenimiento y su fragilidad frente a variaciones léxicas, abreviaturas y errores

hacen que resulten insuficientes para datos del mundo real (Jirjees et al., 2025).

Transición hacia técnicas de aprendizaje automático

La llegada y consolidación del ML transformó la investigación y la práctica en JTM. Durante los últimos años, la literatura documenta un amplio abanico de técnicas: desde modelos supervisados clásicos hasta arquitecturas neuronales que aprenden representaciones textuales más ricas y robustas frente al ruido y la variabilidad (Jirjees et al., 2025). Han comenzado a surgir soluciones no supervisadas y semi-supervisadas para detectar patrones, agrupar titulaciones y reducir la dependencia de grandes volúmenes de anotación manual (Mamani Rodriguez, 2022b; Mamani Rodriguez, 2022a).

Específicamente en entornos hispanohablantes, trabajos recientes han explorado procesos de clustering y pipelines de ML no supervisado para identificar la demanda social de puestos y determinar similitudes entre títulos profesionales de sectores específicos. Estas contribuciones muestran que, aunque las técnicas de clustering capturan agrupaciones útiles, su sensibilidad a la representación textual y su capacidad de generalización condiciona fuertemente la calidad del emparejamiento.

En cuanto a los análisis bibliométricos sobre investigación en esta tarea, estos revelan un crecimiento sostenido del interés científico en la intersección entre AI y reclutamiento por parte de la HCM, con aplicaciones que abarcan desde selección automatizada hasta orientación profesional y análisis de brechas de competencias (Rojas-Galeano, Posada, y Ordoñez, 2022). Estas investigaciones también evidencian que, aunque existen esfuerzos notables en sectores como la salud o la tecnología, persiste una desproporción entre la disponibilidad de recursos en inglés y en otras lenguas, lo que limita la comparabilidad y la replicabilidad de soluciones en contextos locales.

Del problema de clasificación a la tarea de *matching* en entornos reales

Una distinción clave que ha emergido en la literatura reciente es la diferencia entre (i) la clasificación contra una taxonomía canónica y (ii) el matching o ranking entre pares de textos libres. Mientras la clasificación se beneficia de puntos de referencia estables, el matching real debe lidiar con ruido, abreviaturas, títulos internos y asimetrías informativas que no

aparecen en las taxonomías que se encuentran disponibles. En consecuencia, las soluciones más robustas tienden a combinar representaciones semánticas aprendidas con estrategias de evaluación y depuración específicas del dominio, integrando tanto medidas globales de similitud como señales estructurales extraídas del mercado laboral (Gasco et al., 2025a).

2.4. Enfoques y Metodologías en TalentCLEF

La [Tarea A](#) propuesta en TalentCLEF 2025 surge como una respuesta necesaria ante la compleja evolución del JTM en ecosistemas globales y multilingües. Este escenario atrajo la atención de numerosos equipos de investigación, cuyo objetivo común fue resolver el desafío de la alineación semántica de títulos profesionales entre inglés, español, alemán y, como reto adicional, chino. Si bien la diversidad de enfoques fue notable, el análisis transversal de las memorias presentadas evidencia una hegemonía tecnológica clara: el uso de modelos de lenguaje basados en la arquitectura Transformer. No obstante, la diferenciación entre las propuestas ganadoras radicó en las sutilezas de sus estrategias de implementación, los regímenes de entrenamiento y la integración inteligente de recursos externos.

2.4.1. Arquitecturas y Espacios Semánticos Compartidos

La mayoría de las soluciones giraron en torno a modelos de *Sentence Transformers* multilingües preentrenados, como MPNet (Brikman, Sana, y Ruegger, 2025), JobBERT (Decorte, De Lange, y Van Haute, 2025) o variantes de SBERT (Nizami et al., 2025; Bhangale, Gabhane, y Kumar, 2025). El objetivo común fue la generación de embeddings en un espacio semántico compartido, donde títulos de trabajo equivalentes en diferentes idiomas tuvieran una alta similitud³.

Frente a la tendencia del fine-tuning, algunos equipos optaron por evaluar la capacidad de generalización innata de los modelos. En este sentido, UDII-UPM (Rodríguez-Vidal et al., 2025) exploró un enfoque zero-shot, proponiendo una arquitectura que fusionaba representaciones semánticas provenientes de distintos modelos preentrenados para aumentar la robustez del matching sin necesidad de reentrenamiento específico. Por su parte, el equi-

³La similitud medida en los espacios vectoriales generados fue la similitud coseno, elegida de forma unánime entre todas las propuestas de solución al problema.

po Pjmathematician innovó al incorporar embeddings GIST combinados con datos sintéticos (Vachharajani, 2025).

2.4.2. Paradigmas de Entrenamiento y Ajuste Fino

Más allá de la elección del modelo base, la metodología de entrenamiento resultó ser un factor determinante en el rendimiento. El equipo NLPnorth (Zhang y van der Goot, 2025) aportó uno de los análisis comparativos más valiosos de la competición al contrastar tres paradigmas de entrenamiento:

- **Enfoque Discriminativo:** Reformulación del problema como una tarea de clasificación binaria, determinando si dos títulos coinciden o no mediante la generación de pares negativos estrictos.
- **Aprendizaje Contrastivo:** Entrenamiento orientado a optimizar la estructura del espacio latente, minimizando la distancia entre pares positivos (sinónimos) y maximizándola entre pares negativos.
- **Evaluación basada en Prompts:** Utilización de LLM para inferir la similitud directamente mediante instrucciones en lenguaje natural.

Los resultados empíricos presentados por NLPnorth sugirieron que el aprendizaje contrastivo ofrece la mayor eficacia para este tipo de tareas, superando a los enfoques de clasificación pura y a los métodos basados en prompts directos.

2.4.3. Ingeniería de Datos y Recursos Externos

La calidad y cantidad de los datos de entrenamiento jugaron un rol crítico, llevando a muchos participantes a mirar más allá del set de datos proporcionado por la organización.

Explotación de Taxonomías

La taxonomía ESCO trascendió su función habitual de base de conocimiento para convertirse en un motor de generación de datos. El equipo VerbaNex (Novoa et al., 2025) aprovechó la estructura jerárquica de ESCO para inferir relaciones y generar automáticamente pares positivos y negativos adicionales, refinando así el espacio semántico del modelo. Paralelamente,

NLPnorth (Zhang y van der Goot, 2025) también integró datos extraídos de ESCO para enriquecer el entrenamiento⁴.

Una estrategia alternativa fue la propuesta híbrida de TechWolf (Rodríguez, Perez-de Viñaspre, y Perez, 2025), quienes implementaron un sistema de dos etapas retrieve-and-rerank. En la primera fase, utilizaron tanto ESCO como ISCO (Clasificación Internacional Uniforme de Ocupaciones) para una recuperación amplia de candidatos, refinando posteriormente la selección mediante el uso de LLMs.

Generación Sintética con LLMs

El uso de LLMs no se limitó al re-ranking. Varios equipos emplearon estos modelos para la generación de datos sintéticos que enriquecieran el contexto de los títulos cortos. El equipo NT (Nga, Tuyen, y Van Thin, 2025) diseñó un sistema que generaba descripciones detalladas de trabajo a partir de los títulos utilizando LLMs, para luego aplicar técnicas de IR. Sin embargo, los resultados indicaron que este enfoque, aunque interesante, ofreció un rendimiento limitado en comparación con los modelos de embeddings densos optimizados.

2.4.4. Desafíos del Multilingüismo

La gestión de la barrera idiomática presentó retos específicos, abordados mediante distintas tácticas:

- **Proyección Directa:** La mayoría de los trabajos confiaron en la capacidad de los codificadores multilingües (SBERT, MPNet) para alinear idiomas implícitamente en el espacio vectorial (Brikman, Sana, y Ruegger, 2025; Nizami et al., 2025; Novoa et al., 2025).
- **Estrategia de Pivote:** TechWolf (Rodríguez, Perez-de Viñaspre, y Perez, 2025) investigó explícitamente el uso del inglés como lengua franca, traduciendo los títulos de origen antes de realizar el emparejamiento. Esta técnica demostró ser beneficiosa en ciertos escenarios donde la alineación directa entre idiomas con pocos recursos (o distantes entre sí) era deficiente.

⁴Aunque la organización puso a disposición de los participantes un conjunto de datos de entrenamiento completo, la naturaleza sintética y limitada de este motivó a los participantes a aumentar el corpus para mejorar la capacidad de generalización de los modelos ante ejemplos no vistos.

- **Curriculum Learning:** El equipo AlexU-NLP ([Barakat et al., 2025](#)) introdujo un sistema de recuperación híbrido basado en *curriculum learning*, entrenando al modelo con pares de dificultad progresiva para mejorar su adaptación a las complejidades multilingües.

Mención aparte merece el caso del idioma chino. Al tratarse de una sub-tarea voluntaria y ciega (sin datos de entrenamiento en chino, solo presentes en validación y test), se configuró como una prueba de fuego para la capacidad zero-shot multilingüe de los sistemas. La mayoría de los equipos centraron sus esfuerzos en las lenguas europeas, dejando el chino como un indicador de la robustez arquitectónica frente a idiomas no vistos durante el ajuste fino.

2.4.5. Ética y Mitigación del Sesgo de Género

Finalmente, la [Tarea A](#) incorporó una dimensión ética crucial: la evaluación del sesgo de género. En idiomas con marca gramatical de género (como español y alemán), existía el riesgo de que los modelos perpetuaran estereotipos o fallaran en la alineación de títulos equivalentes con distinto género gramatical.

Para medir esto, la organización incluyó anotaciones ocultas y pares diseñados específicamente para testear la neutralidad de las predicciones. El objetivo era minimizar la disparidad de rendimiento entre grupos de género. A pesar de la importancia de esta métrica, pocos participantes detallaron técnicas explícitas de mitigación de sesgos, priorizando la precisión semántica pura. No obstante, los trabajos de NLPnorth y del grupo Ixa destacaron en este apartado, logrando puntuaciones perfectas en la métrica de [RBO](#), demostrando que es posible alcanzar un alto rendimiento técnico sin sacrificar la igualdad de género.

2.5. Transformers para Semejanza Semántica

Desde su irrupción, los Transformers se han consolidado como el estándar indiscutible para tareas de comprensión del lenguaje natural, y en el contexto de TalentCLEF 2025, su adopción ha sido universal. Su capacidad para modelar dependencias complejas ha permitido no solo mejoras cuantitativas en la calidad del ranking, sino también el florecimiento de una diversidad

de arquitecturas y estrategias de alineación semántica que se detallan a continuación.

2.5.1. Fundamentos de la Arquitectura Transformer

En esencia, un Transformer es una arquitectura de red neuronal que rompe con la tradición secuencial de las redes recurrentes y la localidad de las convolucionales, fundamentándose íntegramente en mecanismos de atención. Esta innovación permite que cada token de una secuencia procese información del resto de la secuencia simultáneamente, ponderando la relevancia de cada elemento mediante pesos aprendidos (Vaswani et al., 2017). Esto facilita la captura de relaciones de largo alcance y dependencias contextuales profundas, que son características fundamentales para desambiguar y comparar textos en tareas de IR.

Aunque el diseño original propuesto por Vaswani et al. consiste en una estructura de *encoder-decoder*, la práctica moderna en tareas de matching y recuperación ha derivado en la especialización de la arquitectura: modelos *encoder-only* (como BERT) para la generación de representaciones vectoriales densas, y modelos *decoder-only* (como la familia GPT) para tareas generativas asociadas a los LLM.

2.5.2. Paradigmas Arquitectónicos en la Recuperación de Información

El análisis de las soluciones presentadas en la tarea revela tres patrones de diseño predominantes, cada uno con un compromiso distinto entre precisión semántica y eficiencia computacional:

Bi-encoders y Espacios Vectoriales

Conocidos también como redes siamesas, esta arquitectura procesa la consulta y el candidato de forma independiente a través del mismo codificador. El objetivo es proyectar ambos textos en un espacio semántico compartido donde la similitud se calcula mediante una métrica de distancia vectorial.

Su principal fortaleza reside en la escalabilidad. Al pre-calcular e indexar los vectores de los candidatos, la recuperación se reduce a una búsqueda de vecinos cercanos, permitiendo latencias extremadamente bajas en infe-

rencia. Sin embargo, la interacción entre los textos es meramente implícita. Esto puede ocasionar una pérdida de matices al intentar comprimir toda la información semántica en un único vector de tamaño fijo.

Cross-encoders y Modelado de Interacción

A diferencia de los anteriores, un cross-encoder recibe como entrada el par concatenado (*consulta*, *candidato*), permitiendo que el mecanismo de auto-atención cruce información entre ambas secuencias en todas las capas de la red. Esto habilita una comprensión profunda de la relación entre los términos, capturando negaciones, sinónimos contextuales y matices sintácticos que un bi-encoder podría ignorar.

Dado su elevado coste computacional (es necesario procesar cada par posible), es inviable utilizarlos para la búsqueda sobre grandes colecciones. Por ello, se ha consolidado el patrón de diseño *Retrieve-and-Rerank* (Inc., 2024; Xu et al., 2025): utilizar un bi-encoder para recuperar un conjunto candidato y refinar el ordenamiento final mediante un cross-encoder de alta precisión.

Modelos Autoregresivos y Generativos

Los LLMs han introducido el paradigma de usar la capacidad de razonamiento para puntuar pares mediante *prompting* o para tareas auxiliares como la generación de descripciones sintéticas, traducción o normalización de títulos. Aunque ofrecen una alta flexibilidad, su uso introduce múltiples desafíos, que se han visto reflejados en los resultados de la competición.

2.5.3. Estrategias Avanzadas de Entrenamiento

La arquitectura por sí sola no garantiza el éxito; la estrategia de fine-tuning y la elección de la función de pérdida son determinantes para la calidad del ranking final. En TalentCLEF se identificaron varias técnicas clave para optimizar estos modelos:

- **Aprendizaje Contrastivo y Selección de Negativos:** El uso de funciones de pérdida contrastivas, como [Estimación de Contraste de Ruido de Información \(InfoNCE\)](#), busca estructurar el espacio vectorial acercando los pares positivos y alejando los negativos. La literatura

reciente (Solatorio, 2024) demuestra que la clave del éxito en este enfoque no es solo la función de pérdida, sino la minería de “negativos difíciles” (ejemplos semánticamente cercanos pero no equivalentes) para forzar al modelo a discriminar matices finos.

- **Funciones de Pérdida Robustas:** Para mitigar problemas de convergencia en datasets desbalanceados, variantes como focal-InfoNCE (Hou y Li, 2023) parecen tener un mejor funcionamiento. Estas funciones penalizan dinámicamente los errores en ejemplos difíciles, permitiendo que el modelo priorice el aprendizaje de los casos complejos y mejore la posición de los verdaderos positivos en la parte alta del ranking.
- **Curriculum Learning:** Ante la distribución de “long-tail” típica de los títulos de trabajo, estrategias de aprendizaje curricular, donde se comienza el entrenamiento con ejemplos sencillos y se va aumentando progresivamente la dificultad de los pares negativos, demostraron ser eficaces para estabilizar el entrenamiento y evitar el colapso del modelo.
- **Alineación Multilingüe:** Finalmente, para abordar la naturaleza multilingüe de la tarea, se aplicaron técnicas de entrenamiento que balancean la carga por idioma o que utilizan objetivos de CL. Investigaciones recientes (Mao, Chu, y Kurohashi, 2024) sugieren que el entrenamiento simultáneo masivo mejora la transferencia de conocimiento entre pares de idiomas, reduciendo la fragmentación del espacio de embeddings.

Capítulo 3

Arquitectura del sistema

En el presente capítulo se detalla la propuesta metodológica y técnica diseñada para abordar la resolución de la [Tarea A](#). Basándonos en la literatura reciente sobre sistemas de recuperación de información, se propone una arquitectura modular en cascada.

Este diseño arquitectónico busca equilibrar el compromiso entre eficiencia computacional y precisión semántica. Para ello, combina la velocidad de los modelos de recuperación densa en una primera etapa, con la capacidad de generalización de las técnicas de fusión de rankings, y finaliza con la alta precisión de los modelos de cross-encoders en la etapa de re-ranking.

3.1. Visión general del flujo de trabajo

El flujo de procesamiento, desde la recepción de la query hasta la generación del ranking final de candidatos, se estructura en tres etapas secuenciales claramente diferenciadas:

1. **Fase de Retrieval:** Etapa de generación de candidatos. Se emplean tres modelos bi-encoder independientes, previamente ajustados al dominio de la tarea. Su función es proyectar tanto las consultas como los candidatos en un espacio vectorial común y recuperar eficientemente los candidatos más similares para cada modelo y para cada consulta.
2. **Fase de Fusión:** Los rankings preliminares generados por los tres modelos de recuperación se combinan mediante algoritmos de fusión. El objetivo es mitigar los sesgos inductivos individuales de cada modelo y generar una lista unificada de candidatos con mayor exhaustividad.

3. **Fase de Re-ranking:** La lista fusionada es procesada por un modelo cross-encoder, el cual evalúa la interacción semántica profunda entre la consulta y cada candidato seleccionado, produciendo la puntuación y el ordenamiento definitivo.

La Figura 3.1 ilustra el diagrama de bloques de la arquitectura propuesta y el flujo de datos a través de los distintos módulos.




Figura 3.1: Esquema de la arquitectura en cascada del sistema propuesto: Recuperación multi-modelo, Fusión de rankings y Re-ranking semántico.

3.2. Descripción detallada de los módulos

A continuación, se describen las especificaciones técnicas y los fundamentos teóricos de cada uno de los componentes que integran el sistema.

3.2.1. Retrieval

El objetivo de esta fase inicial es recuperar un subconjunto relevante de documentos del corpus total con una alta eficiencia computacional. Para maximizar la robustez del sistema y reducir la varianza asociada a una única arquitectura, se ha optado por una estrategia de *ensemble* basada en modelos de Sentence Transformers (Reimers y Gurevych, 2019).

Fundamento teórico: Bi-Encoders

La arquitectura base empleada es la red siamesa de bi-encoders. En este esquema, dada una consulta q y un documento candidato d , se utilizan dos instancias del mismo modelo preentrenado (con pesos compartidos) para procesar cada entrada de forma independiente y generar sus representaciones vectoriales densas, denotadas como u y v respectivamente.

La similitud semántica $\text{sim}(q, d)$ se calcula mediante la función de similitud coseno entre ambos vectores, lo que permite una recuperación eficiente mediante búsqueda por proximidad:

$$\text{sim}(q, d) = \cos(u, v) = \frac{u \cdot v}{\|u\| \|v\|} \quad (3.1)$$

Estrategia de selección de modelos

Para dotar de diversidad al sistema de recuperación, la arquitectura integra tres modelos bi-encoder distintos. La selección de estos tres modelos se realiza mediante un proceso riguroso de evaluación en dos etapas:

- **Evaluación Zero-Shot:** Selección preliminar sobre modelos del estado del arte disponibles en repositorios abiertos como Hugging Face¹, priorizando aquellos con alto desempeño en benchmarks multilingües.
- **Evaluación Post-Training:** Validación tras el ajuste fino con datos de validación.

Los modelos finales son seleccionados basándose en la maximización de la métrica [MAP](#), detallada en la Sección 3.3.3, sobre el conjunto de validación.

3.2.2. Ranking Fusion

La recuperación de información basada en un único modelo bi-encoder puede presentar limitaciones propias de la arquitectura o de los datos de entrenamiento específicos de dicho modelo. La hipótesis subyacente en la arquitectura propuesta es que diferentes modelos capturan matices semánticos distintos, y que la combinación de sus resultados puede conducir a una mejora significativa en la calidad del ranking final.

¹<https://huggingface.co/>

Para mitigar estas limitaciones y mejorar la robustez del sistema, se implementa un módulo de fusión de rankings. Este módulo agrega las listas de documentos candidatos generadas por los 3 mejores modelos sobre nuestra tarea para producir un ranking unificado y reordenado. Se describen a continuación las tres estrategias de fusión consideradas.

Reciprocal Rank Fusion (RRF)

El algoritmo RRF (Cormack, Clarke, y Buettcher, 2009) es una técnica de fusión basada exclusivamente en la posición de los candidatos en el ranking, ignorando las puntuaciones de similitud originales. Esto lo hace especialmente robusto frente a modelos que devuelven puntuaciones en escalas no calibradas o dispares.

Este algoritmo asigna una puntuación a cada candidato d basándose en la inversa de su rango en cada una de las listas recuperadas. La fórmula de agregación es la siguiente:

$$Score_{RRF}(d) = \sum_{r \in R} \frac{1}{k_{rrf} + r(d)} \quad (3.2)$$

Donde:

- R es el conjunto de rankings provenientes de los distintos modelos.
- $r(d)$ es la posición ordinal del candidato d en el ranking r (siendo 1 la mejor posición).
- k_{rrf} es una constante de suavizado que evita que los candidatos en las primeras posiciones dominen excesivamente la puntuación final, mitigando el impacto de los outliers.

Mean Normalized Z-score (MNZ)

A diferencia de RRF, las técnicas basadas en puntuación intentan preservar la información sobre la intensidad de la similitud que el modelo ha asignado a cada documento. Sin embargo, dado que distintos modelos de embedding pueden operar en espacios vectoriales con distribuciones de similitud diferentes, es necesaria una normalización previa.

La estrategia en el cálculo de la Métrica de Normalización Z-Score (MNZ)²

²Una implementación interesante de esta técnica se puede leer en (Wu, Crestani, y Bi, 2006).

estandariza las puntuaciones de cada ranking individual antes de la fusión. Para cada candidato d en un ranking i , la puntuación original $S_i(d)$ se transforma:

$$Z_i(d) = \frac{S_i(d) - \mu_i}{\sigma_i} \quad (3.3)$$

Donde μ_i y σ_i son la media y la desviación estándar de las puntuaciones del ranking i . La puntuación final de fusión se calcula como el promedio de las puntuaciones normalizadas, premiando aquellos candidatos que destacan estadísticamente en sus respectivas listas:

$$Score_{MNZ}(d) = \frac{1}{|R|} \sum_{i=1}^{|R|} Z_i(d) \quad (3.4)$$

Weighted Sum (WSum)

Mientras que [RRF](#) y [MNZ](#) tratan a todos los modelos que participan de forma igualitaria (asumiendo una fiabilidad similar), la técnica de [Suma Ponderada \(WSum\)](#) introduce un sesgo explícito basado en la confianza que se tiene en cada modelo. Esta técnica es ideal cuando se conoce a priori que ciertos modelos puedan tener un desempeño distinto en la tarea objetivo.

La puntuación final se obtiene mediante una combinación lineal de las similitudes normalizadas, donde cada modelo i tiene asociado un peso w_i :

$$Score_{WSum}(d) = \sum_{i=1}^{|R|} w_i \cdot S'_i(d) \quad (3.5)$$

Sujeto a la restricción $\sum w_i = 1$. La determinación de los pesos óptimos w_i se realizará mediante búsqueda en rejilla sobre el conjunto de validación, permitiendo potenciar la influencia de los modelos más precisos en la decisión final.

3.2.3. Re-ranking

La lista unificada resultante de la fusión pasa a una etapa final de reordenamiento. A diferencia de los bi-encoders, el cross-encoder recibe como entrada el par concatenado (q, d) y utiliza un mecanismo de autoatención sobre la secuencia conjunta.

Esto permite que el modelo capture interacciones no lineales y dependencias sintácticas entre la consulta y el candidato que son imposibles de representar mediante estructuras computacionales más simples. Debido a su alto coste computacional, este proceso se aplica únicamente a los candidatos más prometedores resultantes de la etapa anterior.

3.3. Tecnologías y Estrategias de Aprendizaje

La implementación del sistema se apoya en un conjunto de tecnologías y funciones de pérdida seleccionadas específicamente para maximizar el aprendizaje de similitud semántica.

3.3.1. Librerías y Entorno

El desarrollo se llevará a cabo utilizando el lenguaje Python, apoyándose en el ecosistema de Hugging Face y la librería **SentenceTransformers** (Reimers y Gurevych, 2019), que facilita el entrenamiento de los modelos bi-encoders que necesitamos. Para la gestión de tensores y el entrenamiento en GPU, se utilizará **PyTorch**. El entorno de desarrollo será Google Colab, aprovechando sus capacidades de cómputo en la nube y acceso a GPUs.

3.3.2. Funciones de Pérdida (Loss Functions)

El entrenamiento de los modelos de recuperación es crítico. Se utilizarán estrategias de [CL](#) para optimizar el espacio vectorial:

- **Retrieval:** [Pérdida de Clasificación con Múltiples Negativos \(MNRL\)](#) será la función de pérdida principal utilizada para el entrenamiento de los modelos bi-encoder. [MNRL](#) trata cada par (query, candidato) como un ejemplo positivo y considera todos los demás candidatos del lote como negativos. Esto permite un entrenamiento altamente eficiente sin necesidad de definir negativos explícitos, aprovechando una gran cantidad de negativos en cada iteración y mejorando la discriminación en el espacio de representación.
- **Re-Ranking:** Para la etapa de re-ranking, se empleará una [Pérdida de Entropía Cruzada Binaria con Logits \(BCEWithLogitsLoss\)](#), tratando el problema como uno de decisión sobre pares (relacionado / no relacionado).

3.3.3. Función de evaluación

Para monitorizar el rendimiento durante el entrenamiento y la validación, se utilizará la métrica **Precisión Media Promedio (MAP)**, la cual fue propuesta por la organización para la evaluación de la **Tarea A**. A diferencia de métricas que solo contabilizan el volumen de aciertos, **MAP** penaliza que los candidatos relevantes aparezcan en posiciones inferiores de la lista de resultados, otorgando mayor peso a los aciertos en las primeras posiciones.

Sea una consulta q asociada a un conjunto de candidatos relevantes conocidos C_q . La **Precisión Promedio (AP)** se define formalmente como:

$$\text{AP}(q) = \frac{1}{|C_q|} \sum_{k=1}^N P(k) \cdot \mathbb{I}(\text{doc}_k \in C_q),$$

donde:

- $|C_q|$ es el número total de documentos relevantes para la consulta q .
- N es el número de documentos recuperados.
- $P(k)$ es la precisión calculada hasta la posición de corte k .
- $\mathbb{I}(\cdot)$ es una función indicadora que toma el valor 1 si el documento en la posición k es relevante ($\text{doc}_k \in C_q$) y 0 en caso contrario.

Finalmente, el valor de **MAP** se obtiene promediando la **AP** sobre la totalidad del conjunto de consultas Q :

$$\text{MAP} = \frac{1}{|Q|} \sum_{q \in Q} \text{AP}(q).$$

3.4. Flujo de Trabajo Experimental

Para validar la arquitectura propuesta y alcanzar los objetivos definidos, se plantea un flujo de trabajo iterativo dividido en cuatro fases principales:

3.4.1. Fase 1: Zero-shot

Inicialmente, se evaluará el rendimiento de un conjunto de modelos pre-entrenados seleccionados (multilingües y monolingües) sin realizar ningún tipo de entrenamiento. Esto establecerá una línea base de rendimiento y

permitirá cuantificar la ganancia obtenida posteriormente mediante el entrenamiento con los datos proporcionados.

3.4.2. Fase 2: Entrenamiento de Bi-encoders

Se procederá al fine-tuning de los 10 mejores modelos de recuperación utilizando los datos de entrenamiento proporcionados por la organización de TalentCLEF, consistentes en pares extraídos de [ESCO](#).

En esta fase, se aplicará un Early Stopping basado en la función de pérdida [MNRL](#) y se monitorizará el rendimiento en el conjunto de validación utilizando la métrica [MAP](#). Se experimentará con diferentes configuraciones de tasas de aprendizaje y de tamaños del lote, tratando de optimizar la convergencia y la generalización del modelo.

3.4.3. Fase 3: Optimización de la Fusión

Una vez entrenados los modelos individuales, se experimentará con la estrategia de fusión. Se evaluará el impacto de diferentes combinaciones de modelos y se ajustará el parámetro k del algoritmo [RRF](#) para maximizar la métrica [MAP](#) en el conjunto de validación, así como la búsqueda de pesos óptimos en la técnica de [WSum](#).

3.4.4. Fase 4: Implementación del Re-ranking

Finalmente, se integrará el cross-encoder. Se analizará el compromiso entre rendimiento y tiempo de cómputo variando la profundidad del re-ranking. El resultado de esta fase constituirá el sistema final a evaluar en la competición.

Capítulo 4

Evaluación

En el presente capítulo se detalla la metodología empleada para la validación de la propuesta, así como los resultados obtenidos en las distintas fases del experimento. El proceso de evaluación se ha estructurado en tres etapas consecutivas: una selección inicial de modelos mediante evaluación *Zero-Shot*, un refinamiento mediante aprendizaje supervisado y, finalmente, la aplicación de técnicas de fusión de rankings y re-ranking para maximizar el rendimiento del sistema.

4.1. Entorno de desarrollo y especificaciones

La totalidad de los experimentos presentados se han ejecutado en un entorno virtualizado proporcionado por Google Colab¹. Las características técnicas del hardware empleado se detallan en la Tabla 4.1.

Es importante destacar que las restricciones de memoria y los límites de tiempo de ejecución impuestas por la plataforma condicionaron la selección de los modelos. Se priorizaron aquellas arquitecturas capaces de realizar inferencia y entrenamiento dentro de estos márgenes, descartando modelos con un número de parámetros excesivo que comprometieran la ejecución del sistema propuesto.

4.2. Fase 1: Evaluación Zero-Shot

El objetivo de esta primera fase fue identificar, dentro del vasto estado del arte, aquellos modelos preentrenados con mayor potencial para la tarea

¹<https://colab.research.google.com/>

Componente	Especificación
Memoria RAM	12 GB
GPU	NVIDIA Tesla T4 (15 GB VRAM)
Sistema operativo	Ubuntu 22.04.4 LTS
Intérprete	Python 3.12.12

Tabla 4.1: Especificaciones técnicas del entorno de evaluación

sin haber sido sometidos aún a un ajuste específico con los datos de la [Tarea A](#).

4.2.1. Selección y filtrado de modelos base

Para la conformación del conjunto de candidatos, se evaluaron modelos obtenidos a través de la librería `SentenceTransformers` de Hugging Face², provenientes de dos fuentes de selección principales:

1. **MTEB Leaderboard** ([Enevoldsen et al., 2025](#)): Se seleccionaron los 100 mejores modelos con licencia pública basándose en su desempeño medio en un total de 13 benchmarks de recuperación de información (Retrieval) y similitud semántica³. Entre las tareas de referencia se incluyen *BELEBELE*, *MIRACL Retrieval Hard Negatives*, *TREC CO-VID* y *Wikipedia Retrieval Multilingual*, entre otras⁴.
2. **Hugging Face**: Se complementó la lista anterior mediante una búsqueda automatizada filtrando por arquitecturas Transformer diseñadas para *Sentence Similarity* y que incluyeran explícitamente el idioma español en su entrenamiento.

Tras un proceso de limpieza para descartar configuraciones erróneas y modelos incompatibles con las restricciones de hardware mencionadas en la Sección 4.1, se obtuvo un conjunto final de 190 modelos.

²<https://huggingface.co/>

³Datos tomados a fecha 1 de diciembre de 2025. Los valores medios de referencia se detallan en la Tabla A.2.

⁴El conjunto total de benchmarks asociados a la tarea de recuperación de información pueden ser consultados directamente en su repositorio: <https://huggingface.co/spaces/mteb/leaderboard>.

4.2.2. Resultados preliminares

La Figura 4.1 ilustra el desempeño de los 190 modelos evaluados sobre el conjunto de validación utilizando la métrica [MAP](#).




Figura 4.1: Dispersión del rendimiento ([MAP](#)) en evaluación Zero-Shot. El eje horizontal representa el tamaño del modelo (número de parámetros) en escala logarítmica.

La Tabla 4.2 presenta los 10 modelos con mejor rendimiento en esta fase. Cabe mencionar que en la totalidad de esta lista no se encuentra ningún modelo monolingüe español, lo que subraya la eficacia de los modelos multilingües en la tarea planteada.

Modelo	MAP
Lajavaness/bilingual-embedding-large	0.4493
jinaai/jina-embeddings-v3	0.4453
chienpham/sts-multilingual-mpnet-base-v2	0.4436
intfloat/multilingual-e5-large-instruct	0.4426
AIDA-UPM/mstsb-paraphrase-multilingual-mpnet-base-v2	0.4287
shtilev/medical_embedded_v4	0.4265
sentence-transformers/paraphrase-multilingual-mpnet-base-v2	0.4169
Alibaba-NLP/gte-multilingual-base	0.4155
shtilev/medical_embedded_v5	0.4117

Tabla 4.2: Top 10 modelos preentrenados en evaluación Zero-Shot ordenados por [MAP](#).

4.3. Fase 2: Fine-Tuning

Tomando como base los 10 modelos más prometedores identificados en la fase anterior, se procedió a su ajuste fino supervisado. Para simplificar la notación, en adelante se omitirá el prefijo del autor en el nombre de los modelos (ej. *bilingual-embedding-large* en lugar de *Lajavaness/bilingual-embedding-large*).

4.3.1. Configuración del entrenamiento

El entrenamiento se realizó utilizando el conjunto de datos de entrenamiento descrito en la Sección 1.2, empleando la función de pérdida MNRL descrita en la Sección 3.3.2. Para mitigar el riesgo de sobreajuste, dada la naturaleza de los datos y el tamaño de los modelos, se limitó el entrenamiento a una única época, con una tasa de aprendizaje de 5×10^{-6} y un tamaño de lote de 16.

Como evidencia del rápido sobreajuste observado al extender el entrenamiento, la Figura 4.2 muestra las curvas de pérdida de validación para dos de los modelos, donde se aprecia una degradación del rendimiento a partir de la primera época.




Figura 4.2: Evolución de la función de pérdida para *medical_embedded.v4* (izq.) y *multilingual-e5-large-instruct* (der.). El incremento de la pérdida de validación tras la primera época justifica la decisión de realizar una parada temprana en la primera época.

4.3.2. Resultados tras el entrenamiento

La Tabla 4.3 compara el desempeño de los modelos antes y después del proceso de ajuste fino, ordenados de mayor a menor MAP tras el entrena-

miento. Se observa una mejora media aproximada de 3 puntos porcentuales en la métrica **MAP** para la mayoría de los candidatos, validando la eficacia del entrenamiento supervisado en el dominio específico de la tarea. En la Figura 4.3 se ilustra gráficamente esta mejora.




Figura 4.3: Comparativa del rendimiento (**MAP**) de los 10 mejores modelos antes y después del ajuste fino.

Es necesario puntualizar el caso de los modelos *jina-embeddings-v3* y *Linq-Embed-Mistral*, cuyos valores permanecen inalterados. Esto se debe a que dichas arquitecturas están optimizadas para inferencia y encapsuladas de tal forma que no permiten un reentrenamiento directo bajo las condiciones experimentales establecidas.

	Modelo	MAP Previo	MAP Ajustado
1	bilingual-embedding-large	0.4493	0.4902
2	multilingual-e5-large-instruct	0.4426	0.4902
3	gte-multilingual-base	0.4155	0.4693
4	paraphrase-multilingual-mpnet-base-v2	0.4169	0.4602
5	mstsb-paraphrase-multilingual-mpnet-base-v2	0.4287	0.4589
6	medical.embedded.v4	0.4265	0.4580
7	medical.embedded.v5	0.4117	0.4568
8	sts-multilingual-mpnet-base-v2	0.4436	0.4516
9	jina-embeddings-v3	0.4453	0.4453
10	Linq-Embed-Mistral	0.4095	0.4095

Tabla 4.3: Resultados comparativos tras el entrenamiento de los 10 mejores modelos.

4.4. Fase 3: Ranking Fusion

Con el objetivo de explotar la complementariedad entre las diferentes representaciones aprendidas, se seleccionaron los tres modelos con mejor desempeño tras el entrenamiento (*bilingual-embedding-large*, *multilingual-e5-large-instruct* y *gte-multilingual-base*) para constituir un sistema de ensamblado mediante fusión de rankings. Se evaluaron las tres estrategias anteriormente mencionadas.

4.4.1. Análisis comparativo de técnicas de fusión

Reciprocal Rank Fusion (RRF)

Mediante un barrido de parámetros (Figura 4.4), se determinó que el valor óptimo para la constante de suavizado es $k = 5$. Con esta configuración, el sistema alcanzó un MAP de **0.49717**, superando los resultados individuales de los modelos base.




Figura 4.4: Optimización del parámetro k en la técnica RRF. El máximo local se sitúa en $k = 5$.

Mean Normalized Z-score (MNZ)

Tras aplicar una normalización min-max, la fusión mediante MNZ devolvió un MAP de **0.49896**, mostrando una ligera superioridad frente a RRF.

Weighted Sum (WSum)

Finalmente, se evaluó la técnica de **WSum**, asignando pesos específicos a cada modelo basándose en valores obtenidos tras una búsqueda de parámetros derivadas de su rendimiento individual. La combinación de pesos óptima encontrada fue:

- *bilingual-embedding-large*: 0.35
- *multilingual-e5-large-instruct*: 0.38
- *gte-multilingual-base*: 0.27

Esta configuración permitió alcanzar un **MAP** de **0.49953**, constituyendo el mejor resultado obtenido en la fase experimental.

4.4.2. Selección final de arquitectura

Basándonos en los resultados expuestos, a pesar de que todas ellas han mejorado los desempeños individuales de cada uno de los modelos, se ha seleccionado la técnica de **WSum** como estrategia de fusión definitiva para el sistema propuesto. En la Figura 4.5 se muestran los resultados obtenidos con cada una de las técnicas evaluadas.




Figura 4.5: Comparativa de las técnicas de fusión evaluadas en términos de **MAP** con respecto al valor máximo individual alcanzado por los modelos.

Con ello obtenemos un sistema que maximiza la métrica **MAP** mediante la combinación ponderada de las fortalezas individuales de los modelos base.

4.5. Re-Ranking

4.6. Evaluación sobre Test

Capítulo 5

Discusión

Este capítulo analiza y discute en profundidad los resultados obtenidos en la evaluación presentada en el capítulo anterior. La estructura de este capítulo dependerá del tema del trabajo y de la estructura del capítulo anterior.

5.1. Ejemplo sección

5.1.1. Ejemplo subsección

Capítulo 6

Conclusiones y trabajo futuro

Este capítulo recopila las diferentes conclusiones extraídas del trabajo realizado, y propone algunas líneas de trabajo futuro. Las siguientes secciones son las que suelen contener este tipo de capítulos, aunque pueden variar dependiendo del tema del trabajo.

6.1. Conclusiones

6.2. Trabajo futuro

Bibliografía

Bibliografía

- [Barakat et al.2025] Barakat, Rana, Omar Mokhtar, Marwan Torki, y Nagwa Elmakky. 2025. Alexu-nlp at talentclef 2025: curriculum-driven hybrid retrieval for multilingual job title matching. *CLEF (Working Notes)*.
- [Bhangale, Gabhane, y Kumar2025] Bhangale, C, P Gabhane, y MA Kumar. 2025. Fine-tuned sentence transformer for multilingual job title matching. *CLEF (Working Notes)*.
- [Brikman, Sana, y Ruegger2025] Brikman, Adam, Michael Sana, y Holden Ruegger. 2025. Multilingual job title matching with mpnet-based sentence transformers. *CLEF (Working Notes)*.
- [Cormack, Clarke, y Buettcher2009] Cormack, Gordon V, Charles LA Clarke, y Stefan Buettcher. 2009. Reciprocal rank fusion outperforms concordet and individual rank learning methods. En *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, páginas 758–759.
- [De Toledo, Núñez, y Usabiaga2008] De Toledo, Pablo Álvarez, Fernando Núñez, y Carlos Usabiaga. 2008. La función de emparejamiento en el mercado de trabajo español. *Revista de economía aplicada*, 16(48):5–35.
- [de Toledo Saavedr, Hernández, y Ibáñez2017] de Toledo Saavedr, Pablo Álvarez, Fernando Núñez Hernández, y Carlos Usabiaga Ibáñez. 2017. ¿quién se empareja con quién en el mercado laboral español? un análisis cluster basado en la muestra continua de vidas laborales. *Investigación económica*, 76(299):87–124.

- [Decorte, De Lange, y Van Hautte2025] Decorte, Jens-Joris, Matthias De Lange, y Jeroen Van Hautte. 2025. Multilingual jobbert for cross-lingual job title matching. *arXiv preprint arXiv:2507.21609*.
- [Enevoldsen et al.2025] Enevoldsen, Kenneth, Isaac Chung, Imene Kerboua, Márton Kardos, Ashwin Mathur, David Stap, Jay Gala, Wissam Siblini, Dominik Krzemiński, Genta Indra Winata, Saba Sturua, Saiteja Utpala, Mathieu Ciancone, Marion Schaeffer, Gabriel Sequeira, Diganta Misra, Shreeya Dhakal, Jonathan Rystrøm, Roman Solomatin, Ömer Çağatan, Akash Kundu, Martin Bernstorff, Shitao Xiao, Akshita Sukhlecha, Bhavish Pahwa, Rafał Poświata, Kranthi Kiran GV, Shawon Ashraf, Daniel Auras, Björn Plüster, Jan Philipp Harries, Loïc Magne, Isabelle Mohr, Mariya Hendriksen, Dawei Zhu, Hippolyte Gisserot-Boukhlef, Tom Aarsen, Jan Kostkan, Konrad Wojtasik, Taemin Lee, Marek Šuppa, Crystina Zhang, Roberta Rocca, Mohammed Hamdy, Andrianos Michail, John Yang, Manuel Faysse, Aleksei Vatolin, Nandan Thakur, Manan Dey, Dipam Vasani, Pranjal Chitale, Simone Tedeschi, Nguyen Tai, Artem Snegirev, Michael Günther, Mengzhou Xia, Weijia Shi, Xing Han Lù, Jordan Clive, Gayatri Krishnakumar, Anna Maksimova, Silvan Wehrli, Maria Tikhonova, Henil Panchal, Aleksandr Abramov, Malte Ostendorff, Zheng Liu, Simon Clematide, Lester James Miranda, Alena Fenogenova, Guangyu Song, Ruqiya Bin Safi, Wen-Ding Li, Alessia Borghini, Federico Cassano, Hongjin Su, Jimmy Lin, Howard Yen, Lasse Hansen, Sara Hooker, Chenghao Xiao, Vaibhav Adlakha, Orion Weller, Siva Reddy, y Niklas Muennighoff. 2025. Mmteb: Massive multilingual text embedding benchmark. *arXiv preprint arXiv:2502.13595*.
- [Gasco et al.2024] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2024. Motivation — talentclef.github.io. <https://talentclef.github.io/talentclef/docs/talentclef-2025/motivation/>. [Accessed 10-11-2025].
- [Gasco et al.2025a] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2025a. Brief overview of talentclef 2025. *Journal of knowledge management*.
- [Gasco et al.2025b] Gasco, Luis, Hermenegildo Fabregat, Laura García-

- Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2025b. Overview of the talentclef 2025: Skill and job title intelligence for human capital management. En *International Conference of the Cross-Language Evaluation Forum for European Languages*, páginas 464–485. Springer.
- [Guo et al.2025] Guo, Yanzhu, Simone Conia, Zelin Zhou, Min Li, Saloni Potdar, y Henry Xiao. 2025. Do large language models have an english accent? evaluating and improving the naturalness of multilingual llms. En *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, páginas 3823–3838.
- [Hou y Li2023] Hou, Pengyue y Xingyu Li. 2023. Improving contrastive learning of sentence embeddings with focal-infonce. *arXiv preprint arXiv:2310.06918*.
- [Inc.2024] Inc., Hugging Face. 2024. Retrieve & Re-Rank; Sentence Transformers documentation — sbert.net. https://sbert.net/examples/sentence_transformer/applications/retrieve_rerank/README.html. [Accessed 13-11-2025].
- [Jirjees et al.2025] Jirjees, Aram Khasro, Aram M Ahmed, Abdulhady Abas Abdulla, Joan Lu, Ekhlas Mohammed Noori, Rozhgar Nasradeen Kareem, Bryar A Hassan, Hadi Veisi, y Tarik A Rashid. 2025. Machine learning for recruitment: Analyzing job-matching algorithms. *Machine Learning*, 27:1.
- [Karpukhin et al.2020] Karpukhin, Vladimir, Barlas Oguz, Sewon Min, Patrick SH Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, y Wen-tau Yih. 2020. Dense passage retrieval for open-domain question answering. En *EMNLP (1)*, páginas 6769–6781.
- [Liu y others2009] Liu, Tie-Yan y others. 2009. Learning to rank for information retrieval. *Foundations and Trends® in Information Retrieval*, 3(3):225–331.
- [Mamani Rodriguez2022a] Mamani Rodriguez, Zoraida. 2022a. Proceso de machine learning para determinar la demanda social de puestos de empleo de profesionales de ti. *Industrial Data*, 25(2):275–300.

- [Mamani Rodriguez2022b] Mamani Rodriguez, Zoraida Emperatriz. 2022b. Machine learning no supervisado en la detección de similitud de puestos de empleo de profesionales de ti. *Industrial Data*.
- [Mao, Chu, y Kurohashi2024] Mao, Zhuoyuan, Chenhui Chu, y Sadao Kurohashi. 2024. Ems: Efficient and effective massively multilingual sentence embedding learning. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 32:2841–2856.
- [Maslej et al.2025] Maslej, Nestor, Loredana Fattorini, Raymond Perrault, Yolanda Gil, Vanessa Parli, Njenga Kariuki, Emily Capstick, Anka Reuel, Erik Brynjolfsson, John Etchemendy, y others. 2025. Artificial intelligence index report 2025. *arXiv preprint arXiv:2504.07139*.
- [Nga, Tuyen, y Van Thin2025] Nga, Ho Thuy, Ho Thi Thanh Tuyen, y Dang Van Thin. 2025. Nt team at multilingual job title matching task a: job matching via large language model-based description generation and retrieval. *CLEF (Working Notes)*.
- [Nizami et al.2025] Nizami, Muhammad Hasan, Ahtisham Uddin, Muhammad Talha Salani, Ayesha Saeed, Faisal Alvi, y Abdul Samad. 2025. Enhancing human capital management: Ai techniques for candidate matching and skill extraction. *CLEF (Working Notes)*.
- [Nogueira y Cho2019] Nogueira, Rodrigo y Kyunghyun Cho. 2019. Passage re-ranking with bert. *arXiv preprint arXiv:1901.04085*.
- [Novoa et al.2025] Novoa, Melissa Moreno, Juan Carlos Martinez-Santos, Jairo Serrano, y Edwin Puertas. 2025. Verbanex at talentclef2025: Semantic matching of multilingual job titles through a framework integrating esco taxonomy. *CLEF (Working Notes)*.
- [Ordóñez de Pablos y Lytras2008] Ordóñez de Pablos, Patricia y Miltiadis D Lytras. 2008. Competencies and human resource management: implications for organizational competitive advantage. *Journal of knowledge management*, 12(6):48–55.
- [Reimers y Gurevych2019] Reimers, Nils y Iryna Gurevych. 2019. Sentence-bert: Sentence embeddings using siamese bert-networks. *arXiv preprint arXiv:1908.10084*.

- [Robertson, Zaragoza, y others2009] Robertson, Stephen, Hugo Zaragoza, y others. 2009. The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends® in Information Retrieval*, 3(4):333–389.
- [Rodriguez, Perez-de Viñaspre, y Perez2025] Rodriguez, Mar, Olatz Perez-de Viñaspre, y Naiara Perez. 2025. A two-stage multilingual job title matching system: combining expert knowledge and llm-based ranking. *CLEF (Working Notes)*.
- [Rodríguez-Vidal et al.2025] Rodríguez-Vidal, Javier, Ascensión López-Vargas, PM Vígara Gallego, Francisco Javier Del Álamo, y A García-Beltrán. 2025. Udi-upm at talentclef 2025: task a-multilingual job title matching. *CLEF (Working Notes)*.
- [Rojas-Galeano, Posada, y Ordoñez2022] Rojas-Galeano, Sergio, Jorge Posada, y Esteban Ordoñez. 2022. A bibliometric perspective on ai research for job-résumé matching. *The Scientific World Journal*, 2022(1):8002363.
- [Salton, Wong, y Yang1975] Salton, Gerard, Anita Wong, y Chung-Shu Yang. 1975. A vector space model for automatic indexing. *Communications of the ACM*, 18(11):613–620.
- [Solatorio2024] Solatorio, Aivin V. 2024. Gistembed: Guided in-sample selection of training negatives for text embedding fine-tuning. *arXiv preprint arXiv:2402.16829*.
- [Vachharajani2025] Vachharajani, Poojan. 2025. Pjmathematician at talentclef 2025: enhancing job title and skill matching with gistembed and llm-augmented data. *CLEF (Working Notes)*.
- [Vaswani et al.2017] Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, y Illia Polosukhin. 2017. Attention is all you need. *Advances in neural information processing systems*, 30.
- [W3Techs2023] W3Techs, A. 2023. Usage statistics of content languages for websites.

- [Wu, Crestani, y Bi2006] Wu, Shengli, Fabio Crestani, y Yaxin Bi. 2006. Evaluating score normalization methods in data fusion. En *Asia Information Retrieval Symposium*, páginas 642–648. Springer.
- [Xu et al.2025] Xu, Zhichao, Fengran Mo, Zhiqi Huang, Crystina Zhang, Puxuan Yu, Bei Wang, Jimmy Lin, y Vivek Srikumar. 2025. A survey of model architectures in information retrieval. *arXiv preprint arXiv:2502.14822*.
- [Zhang y van der Goot2025] Zhang, Mike y Rob van der Goot. 2025. Nl-pnorth@ talentclef 2025: Comparing discriminative, contrastive, and prompt-based methods for job title and skill matching. *arXiv preprint arXiv:2506.19058*.

Glosario

AI Artificial Intelligence (Inteligencia Artificial). [1](#), [13](#)

AP Average Precision (Precisión Promedio). [27](#)

BCEWithLogitsLoss Binary Cross Entropy with Logits Loss (Pérdida de Entropía Cruzada Binaria con Logits). [26](#)

BM25 Best Matching 25 (Mejor Coincidencia 25). [8](#)

CL aprendizaje contrastivo (contrastive learning). [4](#), [20](#), [26](#)

DL Deep Learning (Aprendizaje Profundo). [9](#)

ESCO European Skills, Competences, Qualifications and Occupations (Habilidades, Competencias, Cualificaciones y Ocupaciones Europeas). [3](#), [15](#), [16](#), [28](#)

HCM Human Capital Management (Gestión del Capital Humano). [1–3](#), [12](#), [13](#)

InfoNCE Information Noise-Contrastive Estimation (Estimación de Contraste de Ruido de Información). [19](#), [20](#)

IR Information Retrieval (Recuperación de Información). [7–10](#), [16](#), [18](#)

ISCO International Standard Classification of Occupations (Clasificación Internacional Uniforme de Ocupaciones). [16](#)

JTM Job Title Matching (Emparejamiento de Titulaciones Profesionales). [12–14](#)

LLM Large Language Model (Modelo de Lenguaje Grande). [15](#), [16](#), [18](#), [19](#)

LTR Learning to Rank (Aprendizaje para Ordenación). [8](#), [9](#)

MAP Mean Average Precision (Precisión Media Promedio). [XI](#), [XIII](#), [3](#), [4](#), [23](#), [27](#), [28](#), [31–35](#), [51](#)

ML Machine Learning (Aprendizaje Automático). [8](#), [13](#)

MNRL Multiple Negatives Ranking Loss (Pérdida de Clasificación con Múltiples Negativos). [26](#), [28](#), [32](#)

MNZ Mean Normalized Z-score (Métrica de Normalización Z-Score). [24](#), [25](#), [34](#)

NLP Natural Language Processing (Procesamiento del Lenguaje Natural). [1](#), [2](#)

RBO Rank Biased Overlap (Superposición Sesgada por Rango). [3](#), [17](#)

RRF Reciprocal Rank Fusion (Fusión Recíproca de Rangos). [XI](#), [24](#), [25](#), [28](#), [34](#)

Tarea A Tarea A: Emparejamiento Multilingüe de Titulaciones Profesionales (Multilingual Job Title Matching) de la campaña de evaluación TalentCLEF 2025. [3](#), [4](#), [14](#), [17](#), [21](#), [27](#), [30](#)

WSum Weighted Sum (Suma Ponderada). [25](#), [28](#), [35](#)

Apéndice A

Tablas

En este apéndice se incluyen las tablas de resultados completas obtenidas durante la evaluación de los modelos, que por razones de espacio no se han podido incluir en el cuerpo principal del documento. Estas tablas proporcionan una visión detallada del desempeño de cada modelo en las diferentes tareas y conjuntos de datos evaluados.

Model Name	MTEB Retrieval (avg)
nvidia/llama-embed-nemotron-8b	68.69
tencent/KaLM-Embedding-Gemma3-12B-2511	75.66
Qwen/Qwen3-Embedding-8B	70.88
Qwen/Qwen3-Embedding-4B	69.60
infly/inf-retriever-v1	66.48
jinaai/jina-embeddings-v4	66.43
Alibaba-NLP/gte-Qwen2-7B-instruct	60.08
Linq-AI-Research/Linq-Embed-Mistral	58.69
Alibaba-NLP/gte-Qwen2-1.5B-instruct	60.78
Qwen/Qwen3-Embedding-0.6B	64.65
nvidia/NV-Embed-v2	56.72
google/embeddinggemma-300m	62.49
infly/inf-retriever-v1-1.5b	62.96
parasail-ai/GritLM-7B-vllm	58.31
Salesforce/SFR-Embedding-Mistral	59.44
GritLM/GritLM-8x7B	57.54
Salesforce/SFR-Embedding-2-R	57.93
NovaSearch/jasper_en_vision_language_v1	55.12
nvidia/NV-Embed-v1	53.98
intfloat/e5-mistral-7b-instruct	55.75
intfloat/multilingual-e5-large-instruct	57.12
Snowflake/snowflake-arctic-embed-l-v2.0	58.36
NovaSearch/stella_en_1.5B_v5	52.84
HIT-TMG/KaLM-embedding-multilingual-mini-v1	54.17
Snowflake/snowflake-arctic-embed-m-v2.0	54.83
OrdalieTech/Solon-embeddings-large-0.1	55.69
HIT-TMG/KaLM-embedding-multilingual-mini-instruct-v1	50.84
Alibaba-NLP/gte-multilingual-base	57.16
Lajavaness/bilingual-embedding-large	55.10
intfloat/multilingual-e5-large	53.67
BAAI/bge-m3	54.60
jinaai/jina-embeddings-v3	55.76
ibm-granite/granite-embedding-278m-multilingual	52.20
WhereIsAI/UAE-Large-V1	41.21
avsolatorio/GIST-large-Embedding-v0	40.41
gandolfi/bge-m3-custom-fr-Q4_K_M-GGUF	53.26
intfloat/multilingual-e5-base	52.72
Snowflake/snowflake-arctic-embed-s	39.84
Snowflake/snowflake-arctic-embed-l-v2.0	39.66
mixedbread-ai/mxbai-embed-large-v1	40.30
NovaSearch/stella_en_400M_v5	42.58
Lajavaness/bilingual-embedding-base	52.96
intfloat/e5-large-v2	40.06
nomic-ai/nomic-embed-text-v1-unsupervised	40.66
nomic-ai/nomic-embed-text-v1-ablated	40.74
ibm-granite/granite-embedding-125m-english	39.26
BAAI/bge-large-en-v1.5	39.00
Snowflake/snowflake-arctic-embed-m-v1.5	38.69
Snowflake/snowflake-arctic-embed-m-long	39.30
Snowflake/snowflake-arctic-embed-m-v1.5	39.33
McGill-NLP/LLM2Vec-Mistral-7B-Instruct-v2-mntp-supervised	43.07
intfloat/e5-base-v2	40.49
Lajavaness/bilingual-embedding-small	49.55
BAAI/bge-base-en-v1.5	38.61
bartowski/granite-embedding-107m-multilingual-GGUF	48.08
avsolatorio/GIST-Embedding-v0	38.45
deepvk/USER-bge-m3	43.30
thenlper/gte-large	38.23
intfloat/multilingual-e5-large	38.50
intfloat/e5-small-v2	39.38
avsolatorio/GIST-small-Embedding-v0	37.22
intfloat/multilingual-e5-small	49.38
avsolatorio/NoInstruct-small-Embedding-v0	37.81
BAAI/bge-small-en-v1.5	36.26
abhinand/MedEmbed-small-v0.1	35.16
ibm-granite/granite-embedding-30m-english	36.43
manu/sentence.croissant.alpha.v0.4	38.35
AIDA-UPM/mstsb-paraphrase-multilingual-mpnet-base-v2	39.76
thenlper/gte-small	35.99
thenlper/gte-base	35.86
manu/sentence.croissant.alpha.v0.3	37.27
intfloat/multilingual-e5-base	37.69
jinaai/jina-embedding-b-en-v1	37.96
nomic-ai/nomic-embed-text-v1.5	37.05
Snowflake/snowflake-arctic-embed-l-v2.0	35.23

Tabla A.2: Muestra de los 75 mejores modelos extraídos del repositorio MTEB, ordenados por media de resultados obtenidos en los benchmarks asociados a la tarea de Retrieval.

ranking	model_name	num_params	map_es_es
1	Lajavaness/bilingual-embedding-large	559890432	0.4493
2	jinaai/jina-embeddings-v3	572310396	0.4453
3	chienpham/sts-multilingual-mpnet-base-v2	278043648	0.4436
4	intfloat/multilingual-e5-large-instruct	559890432	0.4426
5	AIDA-UPM/mstsb-paraphrase-multilingual-mpnet-base-v2	278043648	0.4287
6	shtilev/medical_embedded_v4	278043648	0.4265
7	sentence-transformers/paraphrase-multilingual-mpnet-base-v2	278043648	0.4169
8	Alibaba-NLP/gte-multilingual-base	305368320	0.4155
9	shtilev/medical_embedded_v5	278043648	0.4117
10	Linq-AI-Research/Linq-Embed-Mistral	7110660096	0.4095
11	upskyy/e5-large-korean	559890432	0.4058
12	Lajavaness/bilingual-embedding-small	117653760	0.4053
13	upskyy/gte-base-korean	305368320	0.4018
14	Omartificial-Intelligence-Space/Arabic-all-nli-triplet-Matryoshka	278043648	0.4013
15	upskyy/e5-base-korean	278043648	0.3953
16	ibm-granite/granite-embedding-278m-multilingual	278043648	0.3921
17	OneFly7/bienocoder_ep10_bs64_trans1	278043648	0.3901
18	Omartificial-Intelligence-Space/Arabic-labse-Matryoshka	471517440	0.3888
19	shtilev/medical_embedded_v3	278043648	0.3875
20	OneFly7/bi_bs32_lr2e5_cosine_restart_period2_best	278043648	0.3847
21	jinaai/jina-embeddings-v2-base-es	160850688	0.3841
22	Snowflake/snowflake-arctic-embed-l-v2.0	567754752	0.3833
23	Lajavaness/bilingual-embedding-base	278043648	0.3827
24	sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2	117653760	0.3766
25	tomaarsen/distiluse-base-multilingual-cased-v2	134734080	0.3749
26	Qwen/Qwen3-Embedding-0.6B	595776512	0.3718
27	Omartificial-Intelligence-Space/Arabic-MiniLM-L12-v2-all-nli-triplet	117653760	0.3708
28	HIT-TMG/KaLM-embedding-multilingual-mini-v1	494032768	0.3705
29	OneFly7/bienocoder_ep2_bs32_trans3	278043648	0.3700
30	upskyy/bge-m3-korean	567754752	0.3692
31	lang-uk/ukr-paraphrase-multilingual-mpnet-base	278043648	0.3692
32	HIT-TMG/KaLM-embedding-multilingual-mini-instruct-v1	494032768	0.3681
33	Griffin88/sentence-embedding-LaBSE	471517440	0.3661
34	OneFly7/bienocoder_ep10_bs32_lr2e5_cosine_annealing_hard_neg_2	278043648	0.3642
35	OneFly7/bienocoder_ep10_bs64_trans3	278043648	0.3613
36	hiiamsid/sentence_similarity_spanish_es	109850880	0.3601
37	manu/sentence_croissant_alpha_v0.3	1279887360	0.3601
38	hiiamsid/sentence_similarity_spanish_es	109850880	0.3599
39	OneFly7/bienocoder_ep10_bs64_all	278043648	0.3592
40	OrdalieTech/Solon-embeddings-large-0.1	559890432	0.3577
41	DmitryML/distiluse-base-multilingual-cased-v1	135127808	0.3549
42	upskyy/e5-small-korean	117653760	0.3545
43	intfloat/multilingual-e5-small	117653760	0.3513
44	infly/inf-retriever-v1-1.5b	1543268864	0.3474
45	emersoftware/tulio-chilean-spanish-bert-finetuned-msmarco-qa-es	109850880	0.3471
46	intfloat/multilingual-e5-base	278043648	0.3463
47	OneFly7/bienocoder_ep10_bs32_lr2e5_cosine_annealing_hard_neg_1	278043648	0.3459
48	manu/sentence_croissant_alpha_v0.4	1279887360	0.3436
49	mrm8488/distiluse-base-multilingual-cased-v2-finetuned-stsb_multi_mt-es	134734080	0.3421
50	thenlper/gte-large	335141888	0.3414
51	intfloat/multilingual-e5-large	559890432	0.3381
52	avsolatorio/GIST-large-Embedding-v0	335141888	0.3370
53	symanto/sn-xlm-roberta-base-snli-mnli-anli-xnli	278043648	0.3368
54	h4g3n/multilingual-MiniLM-L12-de-en-es-fr-it-nl-pl-pt	103458048	0.3326
55	mixedbread-ai/mxbai-embed-large-v1	335141888	0.3317
56	WhereIsAI/UAE-Large-V1	335141888	0.3283
57	sdadas/mmlw-e5-large	559890432	0.3280
58	narraticlabs/MiniLM-L6-european-union	107006976	0.3231
59	nomie-ai/nomic-embed-text-v1.5	136731648	0.3225
60	BAAI/bge-large-en-v1.5	335141888	0.3212
61	thenlper/gte-base	109482240	0.3199
62	Maite89/Roberta_finetuning_semantic_similarity_stsb_multi_mt	355356672	0.3187
63	avsolatorio/GIST-Embedding-v0	109482240	0.3170
64	OneFly7/bienocoder_ep10_bs32_trans3	278043648	0.3103
65	sdadas/mmlw-e5-base	278043648	0.3089
66	hackathon-pln-es/paraphrase-spanish-distilroberta	124645632	0.3067
67	somosnlp-hackathon-2022/paraphrase-spanish-distilroberta	124645632	0.3064
68	BAAI/bge-m3	567754752	0.3052
69	manu/sentence_croissant_alpha_v0.2	1279887360	0.3050
70	thenlper/gte-small	33360000	0.3044
71	deepvk/USER-bge-m3	359026688	0.3035
72	chukbert/paraphrase-multilingual-MiniLM-L12-v2-MSRP-Indo-finetuned-2-epoch	117653760	0.3023
73	BAAI/bge-base-en-v1.5	109482240	0.3012
74	Snowflake/snowflake-arctic-embed-m-v1.5	108891648	0.3002
75	intfloat/e5-base-v2	109482240	0.2992

Tabla A.1: Resultados completos de los 75 mejores modelos evaluados sobre la métrica [MAP](#) monolingüe en español en la evaluación zero-shot.

To-do list