
Emparejamiento inteligente de titulaciones
profesionales: una propuesta basada en
Transformers optimizada para el español



Trabajo Fin de Máster

David García Curbelo

Trabajo de investigación para el

Máster en Lenguajes y Sistemas Informáticos

Universidad Nacional de Educación a Distancia

Dirigido por la

Prof. Dra. D. Laura Plaza Morales

3 de febrero de 2026

Agradecimientos

A mi madre.

Resumen

La dinámica actual del mercado laboral, impulsada por la automatización y la inteligencia artificial, exige herramientas precisas para la normalización de competencias y ocupaciones. En este contexto, el emparejamiento automático de títulos de ofertas de empleo con taxonomías estandarizadas, como [ESCO](#), se presenta como un desafío fundamental en el procesamiento del lenguaje natural.

Este trabajo describe el sistema desarrollado para la participación en la tarea de [Job Title Matching](#) de la competición [TalentCLEF](#), donde se pretende abordar únicamente el caso para el dominio del español. Se propone una arquitectura modular en cascada diseñada para maximizar la precisión en la recuperación de candidatos. El sistema integra tres etapas secuenciales: una fase de recuperación densa basada en múltiples modelos bi-encoders optimizados mediante aprendizaje supervisado y funciones de pérdida contrastivas; una etapa de fusión de rankings que combina las predicciones para mejorar la robustez; y una fase final de reordenamiento mediante un modelo cross-encoder para refinar la selección de candidatos.

El desarrollo experimental incluyó un análisis exhaustivo de modelos en escenario *Zero-Shot*, revelando la superioridad de las arquitecturas multilingües sobre las monolingües, incluso para el contexto del idioma español. Los resultados obtenidos validan la eficacia del enfoque propuesto: el sistema alcanzó la tercera posición por participantes en la clasificación general, con una métrica [Precisión Media Promedio \(MAP\)](#) media de 0.521 en los tres idiomas obligatorios a presentar. El análisis posterior discute la discrepancia entre el rendimiento en validación y test, así como la paradoja de obtener mejores resultados en otros idiomas pese a la optimización específica para el español, subrayando la importancia de la diversidad de datos y los sesgos intrínsecos que caracterizan a los modelos preentrenados de forma masiva.

Abstract

The current dynamics of the labor market, driven by automation and artificial intelligence, require precise tools for normalizing competencies and occupations. In this context, automatically matching job titles to standardized taxonomies, such as [ESCO](#), represents a fundamental challenge in Natural Language Processing.

This work describes the system developed to participate in the [Job Title Matching](#) task of the [TalentCLEF](#) competition, focusing specifically on the Spanish domain. A modular cascade architecture designed to maximize candidate retrieval precision is proposed. The system integrates three sequential stages: a dense retrieval phase based on multiple bi-encoder models optimized via supervised learning and contrastive loss functions; a rank fusion stage combining predictions to enhance robustness; and a final re-ranking phase utilizing a cross-encoder model to refine candidate selection.

The experimental process included an exhaustive analysis of models in a *Zero-Shot* scenario, revealing the superiority of multilingual architectures over monolingual ones, even within the context of the Spanish language. The results obtained validate the efficacy of the proposed approach: the system achieved third place among participants in the general ranking, with a mean [MAP](#) score of 0.521 across the three mandatory languages. Subsequent analysis discusses the discrepancy between validation and test performance, as well as the paradox of achieving better results in other languages despite the specific optimization for Spanish, underscoring the importance of data diversity and the intrinsic biases characterizing massively pre-trained models.

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Definición del problema	2
1.3. Propuesta y objetivos	4
1.4. Estructura del documento	5
2. Estado del arte	7
2.1. Fundamentos y evolución de la recuperación de información .	7
2.2. Estrategias de refinamiento	10
2.3. Historia y evolución del emparejamiento de titulaciones . . .	12
2.4. Enfoques y metodologías en TalentCLEF	14
2.4.1. Arquitecturas y espacios semánticos compartidos . . .	14
2.4.2. Paradigmas de entrenamiento y ajuste fino	15
2.4.3. Ingeniería de datos y recursos externos	15
2.4.4. Desafíos del multilingüismo	16
2.4.5. Ética y mitigación del sesgo de género	17
2.5. Transformers para semejanza semántica	17
2.5.1. Fundamentos de la arquitectura transformer	18
2.5.2. Paradigmas arquitectónicos en la recuperación de in- formación	18
2.5.3. Estrategias avanzadas de entrenamiento	19
3. Arquitectura del sistema	21
3.1. Visión general del flujo de trabajo	21
3.2. Descripción detallada de los módulos	22
3.2.1. Retrieval	22
3.2.2. Ranking Fusion	23
3.2.3. Re-ranking	25

3.3. Tecnologías y estrategias de aprendizaje	26
3.3.1. Librerías y entorno	26
3.3.2. Función de pérdida en recuperación	26
3.3.3. Función de evaluación	27
3.4. Flujo de trabajo experimental	28
3.4.1. Fase 1: Zero-shot	28
3.4.2. Fase 2: Entrenamiento de Bi-encoders	28
3.4.3. Fase 3: Optimización de la fusión	28
3.4.4. Fase 4: Implementación del re-ranking	28
4. Evaluación	29
4.1. Entorno de desarrollo y especificaciones	29
4.2. Fase 1: Evaluación Zero-Shot	29
4.2.1. Selección y filtrado de modelos base	30
4.2.2. Resultados preliminares	31
4.3. Fase 2: Fine-Tuning	32
4.3.1. Configuración del entrenamiento	32
4.3.2. Resultados tras el entrenamiento	32
4.4. Fase 3: Ranking Fusion	34
4.4.1. Análisis comparativo de técnicas de fusión	34
4.4.2. Selección final de arquitectura	35
4.5. Fase 4: Re-Ranking	36
4.6. Evaluación sobre test	38
4.6.1. Resultados sobre el español	38
4.6.2. Resultados sobre otros idiomas	39
4.6.3. Capacidad de generalización	40
4.6.4. Rendimiento medio	41
5. Discusión	43
5.1. Selección de modelos base	43
5.1.1. Anglicismos y el sesgo del mercado laboral	43
5.1.2. Redundancia arquitectónica	44
5.1.3. La curva del tamaño óptimo	44
5.1.4. Sesgos en las fuentes de selección	45
5.2. Dinámicas de entrenamiento y adaptación	45
5.2.1. Sobreajuste temprano y limitación de datos	46
5.2.2. Estrategia de selección para el ajuste fino	46

5.3. Análisis de la Arquitectura en Cascada	46
5.3.1. La fusión y el problema de la diversidad	47
5.3.2. Re-ranking	47
5.4. Discrepancia entre validación y test	49
5.4.1. Sobreestimación y cambio de dominio	49
5.4.2. La paradoja del rendimiento por idioma	49
5.5. Conclusión del análisis	49
6. Conclusiones y trabajo futuro	51
6.1. Conclusiones	51
6.2. Trabajo futuro	52
Bibliografía	55
Glosario	62
A. Tablas	63

Índice de Figuras

3.1. Esquema de la arquitectura en cascada del sistema propuesto: Recuperación multi-modelo, Fusión de rankings y Re-ranking semántico.	22
4.1. Dispersión del rendimiento (MAP) en evaluación Zero-Shot. El eje horizontal representa el tamaño del modelo (número de parámetros) en escala logarítmica.	31
4.2. Evolución de la función de pérdida para <i>medical_embedded.v4</i> (izq.) y <i>multilingual-e5-large-instruct</i> (der.). El incremento de la pérdida de validación tras la primera época justifica la decisión de realizar una parada temprana en la primera época. .	32
4.3. Comparativa del rendimiento (MAP) de los 10 mejores modelos antes y después del ajuste fino.	33
4.4. Optimización del parámetro k en la técnica Fusión Recíproca de Rangos (RRF). El máximo local se sitúa en $k = 5$	34
4.5. Comparativa de las técnicas de fusión evaluadas en términos de MAP con respecto al valor máximo individual alcanzado por los modelos.	35
4.6. Distribución de los resultados MAP obtenidos tras el re-ranking con distintos tamaños de listas.	36
4.7. Boxplot de los resultados MAP obtenidos tras el re-ranking con distintos tamaños de listas.	37
4.8. Boxplot de los resultados MAP obtenidos por los 10 mejores modelos tras el re-ranking con distintos tamaños de listas. . .	37
4.9. Rendimiento MAP individual de los 10 mejores modelos tras el re-ranking con distintos tamaños de listas.	38

Índice de Tablas

4.1. Especificaciones técnicas del entorno de evaluación	30
4.2. Top 10 modelos preentrenados en evaluación Zero-Shot orde- nados por MAP.	31
4.3. Resultados comparativos tras el entrenamiento de los 10 me- jores modelos.	33
4.4. Resultados finales obtenidos en el conjunto de test de la Tarea A: Emparejamiento Multilingüe de Titulaciones Profesionales (Multilingual Job Title Matching) para el caso monolingüe español.	39
4.5. Resultados finales obtenidos en el conjunto de test de la Tarea A para el caso monolingüe inglés.	40
4.6. Resultados finales obtenidos en el conjunto de test de la Tarea A para el caso monolingüe alemán.	40
4.7. Resultados finales obtenidos en el conjunto de test de la Tarea A para el caso monolingüe chino.	41
A.1. Resultados completos de los 75 mejores modelos evaluados sobre la métrica MAP monolingüe en español en la evaluación zero-shot.	64
A.2. Muestra de los 75 mejores modelos extraídos del repositorio MTEB, ordenados por media de resultados obtenidos en los benchmarks asociados a la tarea de Retrieval.	65
A.3. Resultados completos de los modelos de reranking evaluados sobre la métrica MAP para distintos órdenes de reordenación.	66
A.4. Resultados completos de los 10 mejores modelos de reranking evaluados sobre la métrica MAP para distintos órdenes de reordenación.	67

A.5. Resultados MAP por participante, ordenados por la media de los resultados en los idiomas inglés, español y alemán.	67
--	----

Capítulo 1

Introducción

1.1. Motivación

El panorama del mercado laboral actual está experimentando una gran transformación impulsada principalmente por la rápida evolución tecnológica y la incorporación de la [Inteligencia Artificial \(AI\)](#) en nuestras vidas. Estudios recientes indicaban que para finales de 2025, aproximadamente 90 millones de puestos de trabajo habrían sido automatizados, y una cantidad similar de ocupaciones que no existían a principios de siglo aparecerían en escena ([Maslej et al., 2025](#)). Esta dinámica de cambio constante, lejos de ser un fenómeno aislado, es consecuencia directa del desarrollo tecnológico, el cual no solo ha automatizado tareas rutinarias y creado roles completamente nuevos, sino que también ha redefinido la naturaleza misma de los puestos de trabajo existentes.

En este contexto de transición, la adaptabilidad se convierte en un factor clave tanto para los profesionales, que enfrentan una incertidumbre creciente sobre las competencias que serán relevantes a corto plazo, como para las organizaciones, que se ven obligadas a identificar talento con estas capacidades emergentes ([Ordóñez de Pablos y Lytras, 2008](#)). Esta necesidad ha fomentado la adopción de tecnologías de [Procesamiento del Lenguaje Natural \(NLP\)](#) en la [Gestión del Capital Humano \(HCM\)](#), con el objetivo de optimizar procesos de adquisición de talento, crear programas de formación personalizados y permitir una planificación estratégica basada en competencias.

Sin embargo, el desarrollo de estos sistemas inteligentes se enfrenta a limitaciones en su eficacia, equidad y generalización. Es precisamente en este

punto donde se sitúa la motivación principal de este trabajo, centrado en la Tarea A del TalentCLEF 2025, la cual pretende abordar el problema del emparejamiento de titulaciones profesionales (Gasco et al., 2025a). Además, si bien el desafío original presenta un escenario multilingüe, existe una necesidad palpable de desarrollar y evaluar soluciones específicamente optimizadas para el español, un idioma con una gran relevancia geográfica y demográfica a nivel global que, no obstante, a menudo no recibe una atención adecuada en el desarrollo de modelos de vanguardia.

Muchos de los modelos multilingües de propósito general, aunque incluyen el español en su entrenamiento, suelen estar optimizados primordialmente para el inglés, lo que suele resultar en un rendimiento menor para otras lenguas menos predominantes¹. Este proyecto se centra en una aproximación especializada, que contemple las particularidades del español y busque mejorar su rendimiento en la tarea en cuestión. Sin embargo, la complejidad añadida de los marcadores de género en las titulaciones profesionales representa un desafío técnico particular que, aunque no será abordado en profundidad en este trabajo, sí se estudiarán las propuestas existentes por parte del resto de participantes de la tarea en la sección 2.4.

Además, la disponibilidad del benchmark público de TalentCLEF, que incluye un corpus en español anotado a partir de datos reales (Gasco et al., 2025b), ofrece una oportunidad única para investigar este problema de forma rigurosa y reproducible. Así, este trabajo no solo busca contribuir al avance de la tecnología en el ámbito de la HCM, sino también ofrecer soluciones prácticas que puedan ser implementadas en entornos reales, facilitando así la adaptación de profesionales y organizaciones a un mercado laboral en constante evolución.

1.2. Definición del problema

Este trabajo se centra en la resolución de la primera tarea de la campaña de evaluación TalentCLEF 2025. TalentCLEF es la primera campaña de evaluación enfocada en la gestión de titulaciones profesionales y habilidades (*Skill and Job Title Intelligence*), diseñada para abordar la escasez

¹Cabe destacar que, en cuanto a presencia en la web, el inglés es el que más presencia tiene con un 49 %. El segundo puesto lo ocupa el español, con un 6 % (W3Techs, 2023). Como consecuencia, la mayoría de los modelos de NLP acaban estando optimizados para el inglés (Guo et al., 2025).

de benchmarks públicos y abiertos en el dominio de la HCM (Gasco et al., 2024).

El problema específico que se aborda es la Tarea A. El objetivo de esta tarea es desarrollar sistemas que, dada una titulación profesional (*query*), identifiquen y generen una lista ordenada (*ranking*) de las titulaciones más similares extraídas de una base de conocimiento (*corpus elements*).

El desafío propuesto por TalentCLEF 2025 es multilingüe y cubre cuatro idiomas: inglés, español, alemán y chino, donde los conjuntos de datos proporcionados se componen de tres particiones: entrenamiento, validación y test, con orígenes marcadamente distintos. Los conjuntos de validación y testeo de la tarea se construyeron a partir de datos reales de solicitudes de empleo, que fueron cuidadosamente anonimizadas y anotadas manualmente. Las *queries* de la tarea se definen como los títulos de las ofertas de trabajo, mientras que los *corpus elements* a clasificar se han extraído de los títulos de los últimos puestos de trabajo de los candidatos que aplicaron a dichas ofertas. Por otro lado, el conjunto de entrenamiento (disponible únicamente para inglés, español y alemán) se generó de forma automática extrayendo pares de titulaciones profesionales relacionadas de la taxonomía ESCO (Habilidades, Competencias, Cualificaciones y Ocupaciones Europeas).

La evaluación oficial de la Tarea A se estructura en cuatro escenarios distintos:

- Una evaluación monolingüe para inglés, español y alemán.
- Una evaluación croslingüe, con queries en inglés contra corpus en español y alemán.
- Una sub-tarea voluntaria para el idioma chino, para el cual no se proporcionaron datos de entrenamiento.
- Una evaluación específica del sesgo de género para español y alemán, también voluntaria.

La métrica de evaluación principal para la clasificación es la Precisión Media Promedio (MAP), mientras que para la evaluación del sesgo se utiliza la Superposición Sesgada por Rango (RBO). La organización de la campaña proporciona una plataforma en Codabench² para la presentación y evaluación automática de las soluciones desarrolladas por los participantes. En ella,

²<https://www.codabench.org/competitions/5842/>

los sistemas son evaluados en el conjunto de testeo oculto, y los resultados se publican en un ranking público basado en la métrica [MAP](#), incluyendo desgloses por idioma y escenario.

Si bien el desafío abarca múltiples idiomas, este trabajo se enfoca particularmente en el desarrollo y evaluación de soluciones optimizadas para el español, aprovechando la disponibilidad del corpus anotado y el benchmark público que ofrece la competición.

1.3. Propuesta y objetivos

Este trabajo está centrado en el desarrollo y evaluación de un sistema optimizado para el emparejamiento de titulaciones profesionales en español dentro del marco establecido por la [Tarea A](#) de TalentCLEF 2025. Este desarrollo estará centrado en la búsqueda, adaptación y evaluación exhaustiva de modelos con arquitectura Transformer que maximicen el rendimiento en la tarea de recuperación de información definida, con especial énfasis en el escenario monolingüe del español.

Los objetivos específicos que se persiguen son los siguientes:

- **Análisis del estado del arte:** Investigar en profundidad las aproximaciones y arquitecturas que han demostrado mayor efectividad en tareas de similitud semántica y recuperación de información multilingüe, prestando especial atención a los modelos que mostraron mejores resultados en la competición original.
- **Selección y adaptación de modelos:** Identificar y seleccionar modelos transformer pre-entrenados multilingües con demostrada eficacia en español, para su posterior adaptación mediante técnicas de fine-tuning específicas para la tarea de ranking definida.
- **Diseño de estrategias de entrenamiento:** Implementar y comparar diferentes estrategias de aprendizaje, con especial atención a las técnicas de [CL \(aprendizaje contrastivo\)](#), que ha demostrado ser particularmente efectivo en tareas de similitud semántica según los resultados reportados en TalentCLEF 2025.
- **Evaluación exhaustiva:** Realizar una evaluación rigurosa tanto en el conjunto de desarrollo local como en la plataforma Codabench, empleando la métrica MAP como indicador principal de rendimiento, y

estableciendo comparativas con los sistemas participantes en la competición original.

- **Análisis de especialización para español:** Evaluar específicamente la efectividad de las soluciones desarrolladas en el contexto del idioma español, analizando si un enfoque especializado permite superar el rendimiento de aproximaciones multilingües generalistas.

1.4. Estructura del documento

Capítulo 1. Introducción. Este capítulo introduce los principales motivos que han llevado a la realización de este trabajo, así como la problemática y los objetivos planteados para abordar el problema en cuestión.

Capítulo 2. Estado del arte. Este capítulo describe en mayor detalle la disciplina que nos ocupa, presentando su origen y su historia hasta el presente. Se muestran las técnicas actuales más utilizadas para resolver las tareas más relevantes del tema abordado.

Capítulo 3. Arquitectura del sistema propuesto. En este capítulo se detalla la arquitectura del sistema desarrollado, describiendo las decisiones tomadas en cuanto a modelos, técnicas de entrenamiento y demás aspectos relevantes para la implementación del sistema.

Capítulo 4. Evaluación. Este capítulo presenta los resultados obtenidos tras la evaluación del sistema propuesto, incluyendo análisis detallados del rendimiento alcanzado.

Capítulo 5. Discusión. En este capítulo se discuten los resultados obtenidos en el capítulo anterior, comparándolos con los de otros sistemas y analizando las fortalezas y debilidades del enfoque propuesto.

Capítulo 6. Conclusiones y trabajo futuro. Finalmente, este capítulo resume las principales conclusiones extraídas del trabajo realizado y propone posibles líneas de investigación futura que podrían derivarse de este proyecto.

Capítulo 2

Estado del arte

2.1. Fundamentos y evolución de la recuperación de información

La disciplina de la [Recuperación de Información \(IR\)](#) constituye uno de los pilares angulares de las ciencias de la computación modernas, respondiendo a la necesidad crítica de acceder, filtrar y organizar datos relevantes dentro de corpus documentales en constante expansión.

Antes de profundizar en las particularidades del dominio que nos ocupa, resulta necesario establecer un marco teórico que analice la trayectoria histórica de la disciplina. Esta evolución no es lineal, sino que representa una transformación de paradigmas: desde los primeros sistemas basados en reglas deterministas y coincidencias exactas, hacia arquitecturas híbridas contemporáneas que integran inferencia estadística y aprendizaje profundo. Comprender este tránsito es fundamental para contextualizar las limitaciones de los enfoques tradicionales y justificar la necesidad de modelos de ranking avanzados.

Del determinismo a la similitud estadística

El origen de los sistemas de [IR](#) se encuentra en los modelos booleanos, predominantes durante las primeras décadas de la computación comercial. Estos sistemas operaban bajo una lógica de conjuntos estricta, fundamentada en el álgebra booleana, donde la satisfacción de una consulta dependía exclusivamente de la presencia o ausencia binaria de términos indexados. En este esquema, un documento era considerado relevante si, y solo si, cumplía

con las condiciones exactas de la consulta. Aunque este enfoque ofrecía una alta predictibilidad y una eficiencia computacional presentaba una incapacidad para establecer una jerarquía de relevancia, además de ser vulnerable a la ambigüedad propia del lenguaje natural.

La verdadera revolución en la IR llegó con la introducción del concepto de “ordenación por relevancia”. Esta se materializó a través del Modelo de Espacio Vectorial, el cual transformó la representación de documentos y consultas en vectores dentro de un espacio multidimensional (Salton, Wong, y Yang, 1975). Esta abstracción algebraica permitió, por primera vez, calcular el grado de similitud entre una consulta y un documento mediante operaciones geométricas, como el coseno del ángulo entre vectores.

Posteriormente, la comunidad científica avanzó hacia marcos teóricos más robustos, dando lugar a los modelos probabilísticos. Estos enfoques se basan en el Principio de Ranking de Probabilidad, que postula que un sistema de recuperación es óptimo si ordena los documentos de manera decreciente según su probabilidad de ser relevantes para el usuario. La culminación de esta familia de modelos es el algoritmo BM25, una función de ranking que refina la ponderación clásica introduciendo normalización por longitud de documento y saturación de frecuencia de términos (Robertson, Zaragoza, y others, 2009). A día de hoy, BM25 permanece como un estándar industrial de facto y una línea base difícil de superar en escenarios de recuperación léxica pura.

Sin embargo, a pesar de la solidez matemática de estos métodos tradicionales, todos comparten una limitación intrínseca: la dependencia exclusiva de la coincidencia léxica exacta. Estos modelos sufren del denominado *vocabulary mismatch*, un fenómeno donde documentos semánticamente relevantes son descartados simplemente porque no contienen los mismos términos que la consulta, fallando en capturar fenómenos lingüísticos complejos como la sinonimia y la polisemia. Esta incapacidad para interpretar el contexto semántico motivó la búsqueda de nuevas aproximaciones que pudieran superar estas barreras, dando lugar a la siguiente gran revolución en la IR.

El papel del aprendizaje automático

La evolución de la IR alcanzó un punto de inflexión con la integración de técnicas de Aprendizaje Automático (ML), dando lugar al marco de trabajo conocido como Aprendizaje para Ordenación (LTR) (Liu y others, 2009).

Esta transición marcó el abandono de las funciones de relevancia estáticas y predefinidas en favor de modelos supervisados capaces de aprender funciones de ranking óptimas a partir de datos de entrenamiento.

La literatura académica clasifica tradicionalmente las aproximaciones de [LTR](#) en tres categorías fundamentales, diferenciadas por su función de pérdida y la estructura de sus datos de entrada:

- **Pointwise:** Trata el problema de la ordenación como una tarea de regresión o clasificación individual. Cada documento se evalúa de forma aislada frente a la consulta, asignándole una puntuación de relevancia absoluta.
- **Pairwise:** Transforma el problema en una clasificación binaria de pares de documentos. El objetivo es predecir, dado un par, cuál de los dos es más relevante para una consulta determinada.
- **Listwise:** Representa la aproximación más sofisticada, abordando la lista completa de documentos como la unidad de optimización. Estas funciones de pérdida intentan optimizar directamente métricas de evaluación de ranking, capturando de manera integral la estructura de la lista recuperada.

A pesar de que el [LTR](#) supuso un avance sustancial en la precisión de los sistemas de búsqueda, estos modelos dependían en gran medida de un ajuste de características manual y costoso. Esta dependencia limitaba su capacidad de generalización, especialmente en dominios caracterizados por una alta variabilidad lingüística o una semántica ambigua, donde las señales léxicas superficiales resultaban insuficientes para capturar la verdadera intención del usuario.

Recuperación neuronal y representaciones densas

La reciente irrupción del [Aprendizaje Profundo \(DL\)](#) y, de manera más específica, la consolidación de las arquitecturas basadas en Transformers, han redefinido por completo los cimientos de la [IR](#) contemporánea. Este nuevo paradigma, denominado Recuperación Neuronal, propone una transición fundamental: el paso de la recuperación dispersa hacia la recuperación densa ([Karpukhin et al., 2020](#)). Mientras que los métodos tradicionales representan documentos como vectores de alta dimensionalidad pero escasamente

poblados (basados en términos exactos), los modelos neuronales proyectan tanto consultas como documentos en un espacio vectorial continuo de baja dimensionalidad, denominado espacio de embeddings.

En este espacio latente, la relevancia se mide por la proximidad geométrica entre vectores en un espacio denso. Esta capacidad de representación se apoya en modelos de lenguaje pre-entrenados que, mediante mecanismos de atención, logran capturar el contexto bidireccional de las palabras.

2.2. Estrategias de refinamiento

El crecimiento exponencial en la escala de los corpus de texto ha acentuado una confrontación técnica fundamental en los sistemas de IR: el compromiso entre exhaustividad y precisión. Si bien los modelos neuronales profundos ofrecen una capacidad superior para capturar matices semánticos, su aplicación directa sobre colecciones de millones de documentos conlleva un coste computacional prohibitivo.

Esta limitación ha motivado la adopción generalizada de arquitecturas en cascada o de múltiples etapas. En este esquema, el objetivo de la fase inicial se desplaza hacia la maximización de la exhaustividad mediante métodos eficientes, delegando la optimización de la precisión a etapas posteriores. A continuación, se detallan las principales estrategias de refinamiento que operan sobre los resultados preliminares para depurar y reordenar el ranking final.

Re-ranking: precisión mediante una interacción profunda

La técnica de re-ranking se fundamenta en la premisa de aplicar modelos de alta intensidad computacional exclusivamente sobre un subconjunto acotado de candidatos prometedores. En una arquitectura típica de *retrieve-and-rerank*, una primera etapa recupera una ventana de documentos candidatos (top- N). Posteriormente, esta selección es procesada por un modelo de re-ranking que, al operar sobre un volumen de datos drásticamente menor, puede emplear arquitecturas mucho más complejas.

La ventaja crítica de esta fase reside en la capacidad de evaluar interacciones semánticas profundas. A diferencia de los modelos de recuperación densa de tipo bi-encoders, que codifican consulta y documento de forma independiente, los modelos de re-ranking suelen ser modelos con arquitecturas

cross-encoders. Esto permite modelar la interacción término a término entre la consulta y el documento, capturando dependencias contextuales sutiles que son computacionalmente inviables durante la búsqueda masiva.¹

Fusión de rankings: robustez y diversidad de señales

De forma complementaria al re-ranking, la Fusión de Rankings aborda la varianza intrínseca y los sesgos particulares de los distintos paradigmas de recuperación. La literatura científica evidencia que diferentes familias de algoritmos tienden a recuperar subconjuntos disjuntos de documentos relevantes; por ejemplo, los métodos léxicos (como BM25) son robustos ante coincidencias exactas de palabras clave, mientras que los métodos semánticos destacan en la captura de similitudes conceptuales y sinonimias.

La motivación subyacente a la fusión es el principio de robustez: la agregación de múltiples listas de resultados provenientes de señales distintas tiende a mitigar los errores individuales y reforzar los aciertos comunes. Existen multitud de enfoques para la fusión de rankings, que van desde métodos simples como la suma o el promedio de posiciones, hasta algoritmos más sofisticados que ponderan las listas según su calidad histórica o su diversidad.

El paradigma de las arquitecturas híbridas

En el panorama actual del estado del arte, la excelencia en tareas de recuperación no se define por la capacidad individual de una única técnica aislada, sino por la organización inteligente de múltiples capas de procesamiento. Se ha producido una transición clara hacia sistemas que integran la recuperación inicial híbrida (léxica y semántica) con fases posteriores de refinamiento mediante re-ranking y consolidación a través de fusión de listas.

Este enfoque modular ha demostrado ser la estrategia más eficaz para abordar la complejidad de las necesidades de información modernas². Históricamente se ha observado que la unión de diversas metodologías ge-

¹Trabajos como el de (Nogueira y Cho, 2019) son un ejemplo de ello, demostrando empíricamente que la incorporación de cross-encoders basados en BERT en la etapa de re-ranking mejora sustancialmente la calidad del ranking final, superando las limitaciones de los métodos puramente léxicos o con arquitecturas bi-encoders.

²Este hecho se ve reflejado en las propuestas de solución planteadas por los distintos participantes en la competición de TalentCLEF, como se detallará más en detalle en la sección 2.4.

nera sistemas significativamente más resilientes que sus componentes individuales. Este marco de trabajo híbrido constituye el fundamento sobre el que se construyen las soluciones de alta precisión actuales, permitiendo una adaptación flexible y robusta a dominios específicos, tal y como se requiere para la resolución de la tarea que nos ocupa.

2.3. Historia y evolución del emparejamiento de titulaciones

Dentro de este marco, el [Emparejamiento de Titulaciones Profesionales \(JTM\)](#) se presenta como una aplicación especializada de estos principios dentro del ámbito de la gestión del talento y la [HCM](#). En su forma básica, el problema consiste en determinar la equivalencia o el grado de compatibilidad entre títulos de puestos de trabajo, a pesar de la enorme variabilidad léxica, la polisemia y las convenciones internas de las organizaciones. Esta variabilidad hace que una misma ocupación pueda aparecer bajo campos muy distintos y, a su vez, que títulos idénticos traduzcan responsabilidades distintas según el contexto organizativo, sectorial o geográfico.

Métodos tradicionales y enfoques económicos

Las investigaciones sobre [JTM](#) han adoptado perspectivas tanto técnicas como económicas. En el campo de la economía laboral española, por ejemplo, existe una persistencia en el proceso de emparejamiento que muestra cómo las fricciones de mercado y la heterogeneidad ocupacional condicionan los resultados del matching laboral ([De Toledo, Núñez, y Usabiaga, 2008](#)). Estos estudios proporcionan un marco para interpretar por qué la normalización de titulaciones no es sólo un problema lingüístico, sino también institucional y estructural: la misma denominación puede implicar distintas funciones y niveles de especialización en diferentes segmentos del mercado laboral ([de Toledo Saavedr, Hernández, y Ibáñez, 2017](#)).

Desde el punto de vista computacional, los primeros abordajes aplicados al dominio laboral siguieron estructuras generales de recuperación de información y clasificación de texto, basadas principalmente en normalización de cadenas y reglas heurísticas. Aunque estas técnicas (y los sistemas basados en reglas) pueden ser útiles en entornos controlados, su coste de mantenimiento y su fragilidad frente a variaciones léxicas, abreviaturas y errores

hacen que resulten insuficientes para datos del mundo real (Jirjees et al., 2025).

Transición hacia técnicas de aprendizaje automático

La llegada y consolidación del ML transformó la investigación y la práctica en JTM. Durante los últimos años, la literatura documenta un amplio abanico de técnicas: desde modelos supervisados clásicos hasta arquitecturas neuronales que aprenden representaciones textuales más ricas y robustas frente al ruido y la variabilidad (Jirjees et al., 2025). Han comenzado a surgir soluciones no supervisadas y semi-supervisadas para detectar patrones, agrupar titulaciones y reducir la dependencia de grandes volúmenes de anotación manual (Mamani Rodriguez, 2022b; Mamani Rodriguez, 2022a).

Específicamente en entornos hispanohablantes, trabajos recientes han explorado procesos de clustering y pipelines de ML no supervisado para identificar la demanda social de puestos y determinar similitudes entre títulos profesionales de sectores específicos. Estas contribuciones muestran que, aunque las técnicas de clustering capturan agrupaciones útiles, su sensibilidad a la representación textual y su capacidad de generalización condiciona fuertemente la calidad del emparejamiento.

En cuanto a los análisis bibliométricos sobre investigación en esta tarea, estos revelan un crecimiento sostenido del interés científico en la intersección entre AI y reclutamiento por parte de la HCM, con aplicaciones que abarcan desde selección automatizada hasta orientación profesional y análisis de brechas de competencias (Rojas-Galeano, Posada, y Ordoñez, 2022). Estas investigaciones también evidencian que, aunque existen esfuerzos notables en sectores como la salud o la tecnología, persiste una desproporción entre la disponibilidad de recursos en inglés y en otras lenguas, lo que limita la comparabilidad y la replicabilidad de soluciones en contextos locales.

Del problema de clasificación a la tarea de *matching* en entornos reales

Una distinción clave que ha emergido en la literatura reciente es la diferencia entre (i) la clasificación contra una taxonomía canónica y (ii) el matching o ranking entre pares de textos libres. Mientras la clasificación se beneficia de puntos de referencia estables, el matching real debe lidiar con ruido, abreviaturas, títulos internos y asimetrías informativas que no

aparecen en las taxonomías que se encuentran disponibles. En consecuencia, las soluciones más robustas tienden a combinar representaciones semánticas aprendidas con estrategias de evaluación y depuración específicas del dominio, integrando tanto medidas globales de similitud como señales estructurales extraídas del mercado laboral (Gasco et al., 2025a).

2.4. Enfoques y metodologías en TalentCLEF

La [Tarea A](#) propuesta en TalentCLEF 2025 surge como una respuesta necesaria ante la compleja evolución del JTM en ecosistemas globales y multilingües. Este escenario atrajo la atención de numerosos equipos de investigación, cuyo objetivo común fue resolver el desafío de la alineación semántica de títulos profesionales entre inglés, español, alemán y, como reto adicional, chino. Si bien la diversidad de enfoques fue notable, el análisis transversal de las memorias presentadas evidencia una hegemonía tecnológica clara: el uso de modelos de lenguaje basados en la arquitectura Transformer. No obstante, la diferenciación entre las propuestas ganadoras radicó en las sutilezas de sus estrategias de implementación, los regímenes de entrenamiento y la integración inteligente de recursos externos.

2.4.1. Arquitecturas y espacios semánticos compartidos

La mayoría de las soluciones giraron en torno a modelos de *Sentence Transformers* multilingües preentrenados, como MPNet (Brikman, Sana, y Ruegger, 2025), JobBERT (Decorte, De Lange, y Van Haute, 2025) o variantes de SBERT (Nizami et al., 2025; Bhangale, Gabhane, y Kumar, 2025). El objetivo común fue la generación de embeddings en un espacio semántico compartido, donde títulos de trabajo equivalentes en diferentes idiomas tuvieran una alta similitud³.

Frente a la tendencia del fine-tuning, algunos equipos optaron por evaluar la capacidad de generalización innata de los modelos. En este sentido, UDII-UPM (Rodríguez-Vidal et al., 2025) exploró un enfoque zero-shot, proponiendo una arquitectura que fusionaba representaciones semánticas provenientes de distintos modelos preentrenados para aumentar la robustez del matching sin necesidad de reentrenamiento específico. Por su parte, el equi-

³La similitud medida en los espacios vectoriales generados fue la similitud coseno, elegida de forma unánime entre todas las propuestas de solución al problema.

po Pjmathematician innovó al incorporar embeddings GIST combinados con datos sintéticos (Vachharajani, 2025).

2.4.2. Paradigmas de entrenamiento y ajuste fino

Más allá de la elección del modelo base, la metodología de entrenamiento resultó ser un factor determinante en el rendimiento. El equipo NLPnorth (Zhang y van der Goot, 2025) aportó uno de los análisis comparativos más valiosos de la competición al contrastar tres paradigmas de entrenamiento:

- **Enfoque Discriminativo:** Reformulación del problema como una tarea de clasificación binaria, determinando si dos títulos coinciden o no mediante la generación de pares negativos estrictos.
- **Aprendizaje Contrastivo:** Entrenamiento orientado a optimizar la estructura del espacio latente, minimizando la distancia entre pares positivos (sinónimos) y maximizándola entre pares negativos.
- **Evaluación basada en Prompts:** Utilización de LLM para inferir la similitud directamente mediante instrucciones en lenguaje natural.

Los resultados empíricos presentados por NLPnorth sugirieron que el aprendizaje contrastivo ofrece la mayor eficacia para este tipo de tareas, superando a los enfoques de clasificación pura y a los métodos basados en prompts directos.

2.4.3. Ingeniería de datos y recursos externos

La calidad y cantidad de los datos de entrenamiento jugaron un rol crítico, llevando a muchos participantes a mirar más allá del set de datos proporcionado por la organización.

Explotación de taxonomías

La taxonomía ESCO trascendió su función habitual de base de conocimiento para convertirse en un motor de generación de datos. El equipo VerbaNex (Novoa et al., 2025) aprovechó la estructura jerárquica de ESCO para inferir relaciones y generar automáticamente pares positivos y negativos adicionales, refinando así el espacio semántico del modelo. Paralelamente,

NLPnorth (Zhang y van der Goot, 2025) también integró datos extraídos de ESCO para enriquecer el entrenamiento⁴.

Una estrategia alternativa fue la propuesta híbrida de TechWolf (Rodríguez, Perez-de Viñaspre, y Perez, 2025), quienes implementaron un sistema de dos etapas retrieve-and-rerank. En la primera fase, utilizaron tanto ESCO como ISCO (Clasificación Internacional Uniforme de Ocupaciones) para una recuperación amplia de candidatos, refinando posteriormente la selección mediante el uso de LLMs.

Generación sintética con LLMs

El uso de LLMs no se limitó al re-ranking. Varios equipos emplearon estos modelos para la generación de datos sintéticos que enriquecieran el contexto de los títulos cortos. El equipo NT (Nga, Tuyen, y Van Thin, 2025) diseñó un sistema que generaba descripciones detalladas de trabajo a partir de los títulos utilizando LLMs, para luego aplicar técnicas de IR. Sin embargo, los resultados indicaron que este enfoque, aunque interesante, ofreció un rendimiento limitado en comparación con los modelos de embeddings densos optimizados.

2.4.4. Desafíos del multilingüismo

La gestión de la barrera idiomática presentó retos específicos, abordados mediante distintas tácticas:

- **Proyección Directa:** La mayoría de los trabajos confiaron en la capacidad de los codificadores multilingües (SBERT, MPNet) para alinear idiomas implícitamente en el espacio vectorial (Brikman, Sana, y Ruegger, 2025; Nizami et al., 2025; Novoa et al., 2025).
- **Estrategia de Pivote:** TechWolf (Rodríguez, Perez-de Viñaspre, y Perez, 2025) investigó explícitamente el uso del inglés como lengua franca, traduciendo los títulos de origen antes de realizar el emparejamiento. Esta técnica demostró ser beneficiosa en ciertos escenarios donde la alineación directa entre idiomas con pocos recursos (o distantes entre sí) era deficiente.

⁴Aunque la organización puso a disposición de los participantes un conjunto de datos de entrenamiento completo, la naturaleza sintética y limitada de este motivó a los participantes a aumentar el corpus para mejorar la capacidad de generalización de los modelos ante ejemplos no vistos.

- **Curriculum Learning:** El equipo AlexU-NLP ([Barakat et al., 2025](#)) introdujo un sistema de recuperación híbrido basado en *curriculum learning*, entrenando al modelo con pares de dificultad progresiva para mejorar su adaptación a las complejidades multilingües.

Mención aparte merece el caso del idioma chino. Al tratarse de una sub-tarea voluntaria y ciega (sin datos de entrenamiento en chino, solo presentes en validación y test), se configuró como una prueba de fuego para la capacidad zero-shot multilingüe de los sistemas. La mayoría de los equipos centraron sus esfuerzos en las lenguas europeas, dejando el chino como un indicador de la robustez arquitectónica frente a idiomas no vistos durante el ajuste fino.

2.4.5. Ética y mitigación del sesgo de género

Finalmente, la [Tarea A](#) incorporó una dimensión ética crucial: la evaluación del sesgo de género. En idiomas con marca gramatical de género (como español y alemán), existía el riesgo de que los modelos perpetuaran estereotipos o fallaran en la alineación de títulos equivalentes con distinto género gramatical.

Para medir esto, la organización incluyó anotaciones ocultas y pares diseñados específicamente para testear la neutralidad de las predicciones. El objetivo era minimizar la disparidad de rendimiento entre grupos de género. A pesar de la importancia de esta métrica, pocos participantes detallaron técnicas explícitas de mitigación de sesgos, priorizando la precisión semántica pura. No obstante, los trabajos de NLPnorth y del grupo Ixa destacaron en este apartado, logrando puntuaciones perfectas en la métrica de [RBO](#), demostrando que es posible alcanzar un alto rendimiento técnico sin sacrificar la igualdad de género.

2.5. Transformers para semejanza semántica

Desde su irrupción, los Transformers se han consolidado como el estándar indiscutible para tareas de comprensión del lenguaje natural, y en el contexto de TalentCLEF 2025, su adopción ha sido universal. Su capacidad para modelar dependencias complejas ha permitido no solo mejoras cuantitativas en la calidad del ranking, sino también el florecimiento de una diversidad

de arquitecturas y estrategias de alineación semántica que se detallan a continuación.

2.5.1. Fundamentos de la arquitectura transformer

En esencia, un Transformer es una arquitectura de red neuronal que rompe con la tradición secuencial de las redes recurrentes y la localidad de las convolucionales, fundamentándose íntegramente en mecanismos de atención. Esta innovación permite que cada token de una secuencia procese información del resto de la secuencia simultáneamente, ponderando la relevancia de cada elemento mediante pesos aprendidos (Vaswani et al., 2017). Esto facilita la captura de relaciones de largo alcance y dependencias contextuales profundas, que son características fundamentales para desambiguar y comparar textos en tareas de IR.

Aunque el diseño original propuesto por Vaswani et al. consiste en una estructura de *encoder-decoder*, la práctica moderna en tareas de matching y recuperación ha derivado en la especialización de la arquitectura: modelos *encoder-only* (como BERT) para la generación de representaciones vectoriales densas, y modelos *decoder-only* (como la familia GPT) para tareas generativas asociadas a los LLM.

2.5.2. Paradigmas arquitectónicos en la recuperación de información

El análisis de las soluciones presentadas en la tarea revela tres patrones de diseño predominantes, cada uno con un compromiso distinto entre precisión semántica y eficiencia computacional:

Bi-encoders y espacios vectoriales

Conocidos también como redes siamesas, esta arquitectura procesa la consulta y el candidato de forma independiente a través del mismo codificador. El objetivo es proyectar ambos textos en un espacio semántico compartido donde la similitud se calcula mediante una métrica de distancia vectorial.

Su principal fortaleza reside en la escalabilidad. Al pre-calcular e indexar los vectores de los candidatos, la recuperación se reduce a una búsqueda de vecinos cercanos, permitiendo latencias extremadamente bajas en infe-

rencia. Sin embargo, la interacción entre los textos es meramente implícita. Esto puede ocasionar una pérdida de matices al intentar comprimir toda la información semántica en un único vector de tamaño fijo.

Cross-encoders y modelado de interacción

A diferencia de los anteriores, un cross-encoder recibe como entrada el par concatenado (*consulta*, *candidato*), permitiendo que el mecanismo de auto-atención cruce información entre ambas secuencias en todas las capas de la red. Esto habilita una comprensión profunda de la relación entre los términos, capturando negaciones, sinónimos contextuales y matices sintácticos que un bi-encoder podría ignorar.

Dado su elevado coste computacional (es necesario procesar cada par posible), es inviable utilizarlos para la búsqueda sobre grandes colecciones. Por ello, se ha consolidado el patrón de diseño *Retrieve-and-Rerank* ([Inc., 2024](#); [Xu et al., 2025](#)): utilizar un bi-encoder para recuperar un conjunto candidato y refinar el ordenamiento final mediante un cross-encoder de alta precisión.

Modelos autoregresivos y generativos

Los LLMs han introducido el paradigma de usar la capacidad de razonamiento para puntuar pares mediante *prompting* o para tareas auxiliares como la generación de descripciones sintéticas, traducción o normalización de títulos. Aunque ofrecen una alta flexibilidad, su uso introduce múltiples desafíos, que se han visto reflejados en los resultados de la competición.

2.5.3. Estrategias avanzadas de entrenamiento

La arquitectura por sí sola no garantiza el éxito; la estrategia de fine-tuning y la elección de la función de pérdida son determinantes para la calidad del ranking final. En TalentCLEF se identificaron varias técnicas clave para optimizar estos modelos:

- **Aprendizaje Contrastivo y Selección de Negativos:** El uso de funciones de pérdida contrastivas, como [Estimación de Contraste de Ruido de Información \(InfoNCE\)](#), busca estructurar el espacio vectorial acercando los pares positivos y alejando los negativos. La literatura

reciente (Solatorio, 2024) demuestra que la clave del éxito en este enfoque no es solo la función de pérdida, sino la minería de “negativos difíciles” (ejemplos semánticamente cercanos pero no equivalentes) para forzar al modelo a discriminar matices finos.

- **Funciones de Pérdida Robustas:** Para mitigar problemas de convergencia en datasets desbalanceados, variantes como focal-InfoNCE (Hou y Li, 2023) parecen tener un mejor funcionamiento. Estas funciones penalizan dinámicamente los errores en ejemplos difíciles, permitiendo que el modelo priorice el aprendizaje de los casos complejos y mejore la posición de los verdaderos positivos en la parte alta del ranking.
- **Curriculum Learning:** Ante la distribución de “long-tail” típica de los títulos de trabajo, estrategias de aprendizaje curricular, donde se comienza el entrenamiento con ejemplos sencillos y se va aumentando progresivamente la dificultad de los pares negativos, demostraron ser eficaces para estabilizar el entrenamiento y evitar el colapso del modelo.
- **Alineación Multilingüe:** Finalmente, para abordar la naturaleza multilingüe de la tarea, se aplicaron técnicas de entrenamiento que balancean la carga por idioma o que utilizan objetivos de CL. Investigaciones recientes (Mao, Chu, y Kurohashi, 2024) sugieren que el entrenamiento simultáneo masivo mejora la transferencia de conocimiento entre pares de idiomas, reduciendo la fragmentación del espacio de embeddings.

Capítulo 3

Arquitectura del sistema

En el presente capítulo se detalla la propuesta metodológica y técnica diseñada para abordar la resolución de la [Tarea A](#). Basándonos en la literatura reciente sobre sistemas de recuperación de información, se propone una arquitectura modular en cascada.

Este diseño arquitectónico busca equilibrar el compromiso entre eficiencia computacional y precisión semántica. Para ello, combina la velocidad de los modelos de recuperación densa en una primera etapa, con la capacidad de generalización de las técnicas de fusión de rankings, y finaliza con la alta precisión de los modelos de cross-encoders en la etapa de re-ranking.

3.1. Visión general del flujo de trabajo

El flujo de procesamiento, desde la recepción de la query hasta la generación del ranking final de candidatos, se estructura en tres etapas secuenciales claramente diferenciadas:

1. **Fase de Retrieval:** Etapa de generación de candidatos. Se emplean tres modelos bi-encoder independientes, previamente ajustados al dominio de la tarea. Su función es proyectar tanto las consultas como los candidatos en un espacio vectorial común y recuperar eficientemente los candidatos más similares para cada modelo y para cada consulta.
2. **Fase de Fusión:** Los rankings preliminares generados por los tres modelos de recuperación se combinan mediante algoritmos de fusión. El objetivo es mitigar los sesgos individuales de cada modelo y generar una lista unificada de candidatos con mayor exhaustividad.

3. **Fase de Re-ranking:** La lista fusionada es procesada por un modelo cross-encoder, el cual evalúa la interacción semántica profunda entre la consulta y cada candidato seleccionado, produciendo la puntuación y el ordenamiento definitivo.

La Figura 3.1 ilustra el diagrama de bloques de la arquitectura propuesta y el flujo de datos a través de los distintos módulos.




Figura 3.1: Esquema de la arquitectura en cascada del sistema propuesto: Recuperación multi-modelo, Fusión de rankings y Re-ranking semántico.

3.2. Descripción detallada de los módulos

A continuación, se describen las especificaciones técnicas y los fundamentos teóricos de cada uno de los componentes que integran el sistema.

3.2.1. Retrieval

El objetivo de esta fase inicial es recuperar un subconjunto relevante de documentos del corpus total con una alta eficiencia computacional. Para maximizar la robustez del sistema y reducir la varianza asociada a una única arquitectura, se ha optado por una estrategia de *ensemble* basada en modelos de Sentence Transformers (Reimers y Gurevych, 2019).

Fundamento teórico: Bi-Encoders

La arquitectura base empleada es la red siamesa de bi-encoders. En este esquema, dada una consulta q y un candidato d , se utilizan dos instancias del mismo modelo preentrenado (con pesos compartidos) para procesar cada entrada de forma independiente y generar sus representaciones vectoriales densas, denotadas como u y v respectivamente.

La similitud semántica $\text{sim}(q, d)$ se calcula mediante la función de similitud coseno entre ambos vectores, lo que permite una recuperación eficiente mediante búsqueda por proximidad:

$$\text{sim}(q, d) = \cos(u, v) = \frac{u \cdot v}{\|u\| \|v\|} \quad (3.1)$$

Estrategia de selección de modelos

Para dotar de diversidad al sistema de recuperación, la arquitectura integra tres modelos bi-encoder distintos. La selección de estos tres modelos se realiza mediante un proceso riguroso de evaluación en dos etapas:

- **Evaluación Zero-Shot:** Selección preliminar sobre modelos del estado del arte disponibles en repositorios abiertos como Hugging Face¹, priorizando aquellos con alto desempeño en benchmarks públicos.
- **Evaluación Post-Training:** Validación tras el ajuste fino con datos de validación.

Los modelos finales son seleccionados basándose en la maximización de la métrica [MAP](#), detallada en la Sección 3.3.3, sobre el conjunto de validación.

3.2.2. Ranking Fusion

La recuperación de información basada en un único modelo bi-encoder puede presentar limitaciones propias de la arquitectura o de los datos de entrenamiento específicos de dicho modelo. La hipótesis subyacente en la arquitectura propuesta es que diferentes modelos capturan matices semánticos distintos, y que la combinación de sus resultados puede conducir a una mejora significativa en la calidad del ranking final.

¹<https://huggingface.co/>

Para mitigar estas limitaciones y mejorar la robustez del sistema, se implementa un módulo de fusión de rankings. Este módulo agrega las listas de documentos candidatos generadas por los 3 mejores modelos en la etapa anterior, para producir así un ranking unificado y reordenado. Se describen a continuación las tres estrategias de fusión consideradas.

Reciprocal Rank Fusion (RRF)

El algoritmo RRF (Cormack, Clarke, y Buettcher, 2009) es una técnica de fusión basada exclusivamente en la posición de los candidatos en el ranking, ignorando las puntuaciones de similitud originales. Esto lo hace especialmente robusto frente a modelos que devuelven puntuaciones en escalas no calibradas o dispares.

Este algoritmo asigna una puntuación a cada candidato d basándose en la inversa de su rango en cada una de las listas recuperadas. La fórmula de agregación es la siguiente:

$$Score_{RRF}(d) = \sum_{r \in R} \frac{1}{k_{rrf} + r(d)} \quad (3.2)$$

Donde:

- R es el conjunto de rankings provenientes de los distintos modelos.
- $r(d)$ es la posición ordinal del candidato d en el ranking r (siendo 1 la mejor posición).
- k_{rrf} es una constante de suavizado que evita que los candidatos en las primeras posiciones dominen excesivamente la puntuación final, mitigando el impacto de los outliers.

Mean Normalized Z-score (MNZ)

A diferencia de RRF, las técnicas basadas en puntuación intentan preservar la información sobre la intensidad de la similitud que el modelo ha asignado a cada documento. Sin embargo, dado que distintos modelos de embedding pueden operar en espacios vectoriales con distribuciones de similitud diferentes, es necesaria una normalización previa.

La estrategia en el cálculo de la Métrica de Normalización Z-Score (MNZ)²

²Una implementación interesante de esta técnica se puede leer en (Wu, Crestani, y Bi, 2006).

es estandarizar las puntuaciones de cada ranking individual antes de la fusión. Para cada candidato d en un ranking i , la puntuación original $S_i(d)$ se transforma:

$$Z_i(d) = \frac{S_i(d) - \mu_i}{\sigma_i} \quad (3.3)$$

Donde μ_i y σ_i son la media y la desviación estándar de las puntuaciones del ranking i . La puntuación final de fusión se calcula como el promedio de las puntuaciones normalizadas, premiando aquellos candidatos que destacan estadísticamente en sus respectivas listas:

$$Score_{MNZ}(d) = \frac{1}{|R|} \sum_{i=1}^{|R|} Z_i(d) \quad (3.4)$$

Weighted Sum (WSum)

Mientras que [RRF](#) y [MNZ](#) tratan a todos los modelos que participan de igual forma (asumiendo una fiabilidad similar), la técnica de [Suma Ponderada \(WSum\)](#) introduce un sesgo explícito basado en la confianza que se tiene en cada modelo. Esta técnica es ideal cuando se conoce a priori que ciertos modelos puedan tener un desempeño distinto en la tarea objetivo.

La puntuación final se obtiene mediante una combinación lineal de las similitudes normalizadas, donde cada modelo i tiene asociado un peso w_i :

$$Score_{WSum}(d) = \sum_{i=1}^{|R|} w_i \cdot S'_i(d) \quad (3.5)$$

Sujeto a la restricción $\sum w_i = 1$. La determinación de los pesos óptimos w_i se realiza mediante búsqueda en rejilla sobre el conjunto de validación, permitiendo potenciar la influencia de los modelos más precisos en la decisión final.

3.2.3. Re-ranking

La lista unificada resultante de la fusión pasa a una etapa final de reordenamiento. A diferencia de los bi-encoders, el cross-encoder recibe como entrada el par concatenado (q, d) y utiliza un mecanismo de autoatención sobre la secuencia conjunta. Esto permite que el modelo capture interacciones no lineales y dependencias sintácticas entre la consulta y el candidato

Debo incluir aquí el fundamento teórico y estrategia de selección?

que son imposibles de representar mediante estructuras computacionales más simples.

Debido a su alto coste computacional, este proceso se aplica únicamente a los candidatos más prometedores resultantes de la etapa anterior.

3.3. Tecnologías y estrategias de aprendizaje

La implementación del sistema se apoya en un conjunto de tecnologías y funciones de pérdida seleccionadas específicamente para maximizar el aprendizaje de similitud semántica.

3.3.1. Librerías y entorno

El desarrollo se lleva a cabo utilizando el lenguaje Python, apoyándose en el ecosistema de Hugging Face y la librería **SentenceTransformers** (Reimers y Gurevych, 2019), que facilita el entrenamiento de los modelos bi-encoders que necesitamos. Para la gestión de tensores y el entrenamiento en GPU, se utiliza **PyTorch**. Se ha seleccionado como entorno de desarrollo Google Colab, aprovechando sus capacidades de cómputo en la nube y acceso a GPUs.

3.3.2. Función de pérdida en recuperación

Para la optimización del espacio vectorial en la etapa de recuperación densa, se emplea exclusivamente la función de pérdida **Pérdida de Clasificación con Múltiples Negativos (MNRL)**. Esta elección se fundamenta en su alta eficiencia para el entrenamiento de modelos bi-encoder cuando se dispone de pares positivos, como es el caso de los datos sintéticos que nos proporciona la competición.

La **MNRL** opera bajo la estrategia de generación de negativos dentro de cada lote. Dado un lote de entrada de tamaño B compuesto por pares positivos $\{(q_i, d_i)\}$, para cada consulta q_i , el sistema considera a su par correspondiente d_i como el único documento positivo, mientras que los restantes $B - 1$ documentos del lote son tratados automáticamente como ejemplos negativos.

Esta aproximación ofrece dos ventajas críticas para el sistema:

- **Eficiencia computacional:** Permite reutilizar los datos para generar un gran número de ejemplos negativos sin coste adicional de inferencia.
- **Mejora de la discriminación:** Al aumentar el tamaño del lote, crece linealmente la cantidad de ejemplos negativos que el modelo debe aprender a evitar, lo que resulta en un espacio de representación más robusto y mejor estructurado sin la necesidad de una minería de negativos explícita.

3.3.3. Función de evaluación

Para monitorizar el rendimiento durante el entrenamiento y la validación, se utiliza la métrica **Precisión Media Promedio (MAP)**, la cual fue propuesta por la organización para la evaluación de la **Tarea A**. A diferencia de métricas que solo contabilizan el volumen de aciertos, **MAP** penaliza que los candidatos relevantes aparezcan en posiciones inferiores de la lista de resultados, otorgando mayor peso a los aciertos en las primeras posiciones.

Sea una consulta q asociada a un conjunto de candidatos relevantes conocidos C_q . La **Precisión Promedio (AP)** se define formalmente como:

$$\text{AP}(q) = \frac{1}{|C_q|} \sum_{k=1}^N P(k) \cdot \mathbb{I}(\text{doc}_k \in C_q),$$

donde:

- $|C_q|$ es el número total de documentos relevantes para la consulta q .
- N es el número de documentos recuperados.
- $P(k)$ es la precisión calculada hasta la posición de corte k .
- $\mathbb{I}(\cdot)$ es una función indicadora que toma el valor 1 si el documento en la posición k es relevante ($\text{doc}_k \in C_q$) y 0 en caso contrario.

Finalmente, el valor de **MAP** se obtiene promediando la **AP** sobre la totalidad del conjunto de consultas Q :

$$\text{MAP} = \frac{1}{|Q|} \sum_{q \in Q} \text{AP}(q).$$

3.4. Flujo de trabajo experimental

Para validar la arquitectura propuesta y alcanzar los objetivos definidos, se plantea un flujo de trabajo iterativo dividido en cuatro fases principales:

3.4.1. Fase 1: Zero-shot

Inicialmente, se evalúa el rendimiento de un conjunto de modelos pre-entrenados seleccionados (multilingües y monolingües) sin realizar ningún tipo de entrenamiento. Esto establece una línea base de rendimiento y permite cuantificar la ganancia obtenida posteriormente mediante el entrenamiento con los datos proporcionados.

3.4.2. Fase 2: Entrenamiento de Bi-encoders

Se procede al ajuste fino de los 10 mejores modelos de recuperación utilizando los datos de entrenamiento proporcionados por la organización de TalentCLEF, consistentes en pares extraídos de [ESCO](#).

En esta fase, se aplica un Early Stopping basado en la función de pérdida [MNRL](#) y se monitoriza el rendimiento en el conjunto de validación utilizando la métrica [MAP](#). Se experimenta también con diferentes configuraciones de tasas de aprendizaje y de tamaños del lote, tratando de optimizar la convergencia y la generalización del modelo.

3.4.3. Fase 3: Optimización de la fusión

Una vez entrenados los modelos individuales, se analiza la estrategia de fusión óptima. Se evalúa el impacto de diferentes combinaciones de modelos y se ajusta el parámetro k del algoritmo [RRF](#) para maximizar la métrica [MAP](#) en el conjunto de validación, así como la búsqueda de pesos óptimos en la técnica de [WSum](#).

3.4.4. Fase 4: Implementación del re-ranking

Finalmente, se integra el cross-encoder. Se analiza el compromiso entre rendimiento y tiempo de cómputo variando la profundidad del re-ranking. El resultado de esta fase constituye el sistema final a evaluar en la competición.

Capítulo 4

Evaluación

En el presente capítulo se detalla la metodología empleada para la validación de la propuesta, así como los resultados obtenidos en las distintas fases del experimento. El proceso de evaluación se ha estructurado en tres etapas consecutivas: una selección inicial de modelos mediante evaluación *Zero-Shot*, un refinamiento mediante aprendizaje supervisado y, finalmente, la aplicación de técnicas de fusión de rankings y re-ranking para maximizar el rendimiento del sistema.

4.1. Entorno de desarrollo y especificaciones

La totalidad de los experimentos presentados se han ejecutado en un entorno virtualizado proporcionado por Google Colab¹. Las características técnicas del hardware empleado se detallan en la Tabla 4.1.

Es importante destacar que las restricciones de memoria y los límites de tiempo de ejecución impuestas por la plataforma condicionaron la selección de los modelos. Se priorizaron aquellas arquitecturas capaces de realizar inferencia y entrenamiento dentro de estos márgenes, descartando modelos con un número de parámetros excesivo que comprometieran la ejecución del sistema propuesto.

4.2. Fase 1: Evaluación Zero-Shot

El objetivo de esta primera fase fue identificar, dentro del vasto estado del arte, aquellos modelos preentrenados con mayor potencial para la tarea

¹<https://colab.research.google.com/>

Componente	Especificación
Memoria RAM	12 GB
GPU	NVIDIA Tesla T4 (15 GB VRAM)
Sistema operativo	Ubuntu 22.04.4 LTS
Intérprete	Python 3.12.12

Tabla 4.1: Especificaciones técnicas del entorno de evaluación

sin haber sido sometidos aún a un ajuste específico con los datos de la [Tarea A](#).

4.2.1. Selección y filtrado de modelos base

Para la conformación del conjunto de candidatos, se evaluaron modelos obtenidos a través de la librería `SentenceTransformers` de Hugging Face², provenientes de dos fuentes de selección principales:

1. **MTEB Leaderboard** ([Enevoldsen et al., 2025](#)): Se seleccionaron los 100 mejores modelos con licencia pública basándose en su desempeño medio en un total de 13 benchmarks de recuperación de información (Retrieval) y similitud semántica³. Entre las tareas de referencia se incluyen *BELEBELE*, *MIRACL Retrieval Hard Negatives*, *TREC CO-VID* y *Wikipedia Retrieval Multilingual*, entre otras⁴.
2. **Hugging Face**: Se complementó la lista anterior mediante una búsqueda automatizada filtrando por arquitecturas Transformer diseñadas para *Sentence Similarity* y que incluyeran explícitamente el idioma español en su entrenamiento.

Tras un proceso de limpieza para descartar configuraciones erróneas y modelos incompatibles con las restricciones de hardware mencionadas en la Sección 4.1, se obtuvo un conjunto final de 190 modelos.

²<https://huggingface.co/>

³Datos tomados a fecha 1 de diciembre de 2025. Los valores medios de referencia se detallan en la Tabla A.2.

⁴El conjunto total de benchmarks asociados a la tarea de recuperación de información pueden ser consultados directamente en su repositorio: <https://huggingface.co/spaces/mteb/leaderboard>.

4.2.2. Resultados preliminares

La Figura 4.1 ilustra el desempeño de los 190 modelos evaluados sobre el conjunto de validación utilizando la métrica [MAP](#).




Figura 4.1: Dispersión del rendimiento ([MAP](#)) en evaluación Zero-Shot. El eje horizontal representa el tamaño del modelo (número de parámetros) en escala logarítmica.

La Tabla 4.2 presenta los 10 modelos con mejor rendimiento en esta fase. Cabe mencionar que en la totalidad de esta lista no se encuentra ningún modelo monolingüe español, lo que subraya la eficacia de los modelos multilingües en la tarea planteada.

Modelo	MAP
Lajavaness/bilingual-embedding-large	0.4493
jinaai/jina-embeddings-v3	0.4453
chienpham/sts-multilingual-mpnet-base-v2	0.4436
intfloat/multilingual-e5-large-instruct	0.4426
AIDA-UPM/mstsb-paraphrase-multilingual-mpnet-base-v2	0.4287
shtilev/medical_embedded_v4	0.4265
sentence-transformers/paraphrase-multilingual-mpnet-base-v2	0.4169
Alibaba-NLP/gte-multilingual-base	0.4155
shtilev/medical_embedded_v5	0.4117

Tabla 4.2: Top 10 modelos preentrenados en evaluación Zero-Shot ordenados por [MAP](#).

4.3. Fase 2: Fine-Tuning

Tomando como base los 10 modelos más prometedores identificados en la fase anterior, se procedió a su ajuste fino supervisado. Para simplificar la notación, en adelante se omitirá el prefijo del autor en el nombre de los modelos (ej. *bilingual-embedding-large* en lugar de *Lajavaness/bilingual-embedding-large*).

4.3.1. Configuración del entrenamiento

El entrenamiento se realizó utilizando el conjunto de datos de entrenamiento descrito en la Sección 1.2, empleando la función de pérdida MNRL descrita en la Sección 3.3.2. Para mitigar el riesgo de sobreajuste, dada la naturaleza de los datos y el tamaño de los modelos, se limitó el entrenamiento a una única época, con una tasa de aprendizaje de 5×10^{-6} y un tamaño de lote de 16.

Como evidencia del rápido sobreajuste observado al extender el entrenamiento, la Figura 4.2 muestra las curvas de pérdida de validación para dos de los modelos, donde se aprecia una degradación del rendimiento a partir de la primera época.




Figura 4.2: Evolución de la función de pérdida para *medical_embedded.v4* (izq.) y *multilingual-e5-large-instruct* (der.). El incremento de la pérdida de validación tras la primera época justifica la decisión de realizar una parada temprana en la primera época.

4.3.2. Resultados tras el entrenamiento

La Tabla 4.3 compara el desempeño de los modelos antes y después del proceso de ajuste fino, ordenados de mayor a menor MAP tras el entrena-

miento. Se observa una mejora media aproximada de 3 puntos porcentuales en la métrica **MAP** para la mayoría de los candidatos, validando la eficacia del entrenamiento supervisado en el dominio específico de la tarea. En la Figura 4.3 se ilustra gráficamente esta mejora.




Figura 4.3: Comparativa del rendimiento (**MAP**) de los 10 mejores modelos antes y después del ajuste fino.

Es necesario puntualizar el caso de los modelos *jina-embeddings-v3* y *Linq-Embed-Mistral*, cuyos valores permanecen inalterados. Esto se debe a que dichas arquitecturas están optimizadas para inferencia y encapsuladas de tal forma que no permiten un reentrenamiento directo bajo las condiciones experimentales establecidas.

	Modelo	MAP Previo	MAP Ajustado
1	bilingual-embedding-large	0.4493	0.4902
2	multilingual-e5-large-instruct	0.4426	0.4902
3	gte-multilingual-base	0.4155	0.4693
4	paraphrase-multilingual-mpnet-base-v2	0.4169	0.4602
5	mstsb-paraphrase-multilingual-mpnet-base-v2	0.4287	0.4589
6	medical.embedded.v4	0.4265	0.4580
7	medical.embedded.v5	0.4117	0.4568
8	sts-multilingual-mpnet-base-v2	0.4436	0.4516
9	jina-embeddings-v3	0.4453	0.4453
10	Linq-Embed-Mistral	0.4095	0.4095

Tabla 4.3: Resultados comparativos tras el entrenamiento de los 10 mejores modelos.

4.4. Fase 3: Ranking Fusion

Con el objetivo de explotar la complementariedad entre las diferentes representaciones aprendidas, se seleccionaron los tres modelos con mejor desempeño tras el entrenamiento (*bilingual-embedding-large*, *multilingual-e5-large-instruct* y *gte-multilingual-base*) para constituir un sistema de ensamblado mediante fusión de rankings. Se evaluaron las tres estrategias anteriormente mencionadas.

4.4.1. Análisis comparativo de técnicas de fusión

Reciprocal Rank Fusion (RRF)

Mediante un barrido de parámetros (Figura 4.4), se determinó que el valor óptimo para la constante de suavizado es $k = 5$. Con esta configuración, el sistema alcanzó un MAP de **0.49717**, superando los resultados individuales de los modelos base.




Figura 4.4: Optimización del parámetro k en la técnica RRF. El máximo local se sitúa en $k = 5$.

Mean Normalized Z-score (MNZ)

Tras aplicar una normalización min-max, la fusión mediante MNZ devolvió un MAP de **0.49896**, mostrando una ligera superioridad frente a RRF.

Weighted Sum (WSum)

Finalmente, se evaluó la técnica de **WSum**, asignando pesos específicos a cada modelo basándose en valores obtenidos tras una búsqueda de parámetros derivadas de su rendimiento individual. La combinación de pesos óptima encontrada fue:

- *bilingual-embedding-large*: 0.35
- *multilingual-e5-large-instruct*: 0.38
- *gte-multilingual-base*: 0.27

Esta configuración permitió alcanzar un **MAP** de **0.49953**, constituyendo el mejor resultado obtenido en la fase experimental.

4.4.2. Selección final de arquitectura

Basándonos en los resultados expuestos, a pesar de que todas ellas han mejorado los desempeños individuales de cada uno de los modelos, se ha seleccionado la técnica de **WSum** como estrategia de fusión definitiva para el sistema propuesto. En la Figura 4.5 se muestran los resultados obtenidos con cada una de las técnicas evaluadas.




Figura 4.5: Comparativa de las técnicas de fusión evaluadas en términos de **MAP** con respecto al valor máximo individual alcanzado por los modelos.

Con ello obtenemos un sistema que maximiza la métrica **MAP** mediante la combinación ponderada de las fortalezas individuales de los modelos base.

4.5. Fase 4: Re-Ranking

Procedemos a continuación con la fase final de re-ranking, cuyo objetivo es refinar aún más el ordenamiento de los mejores candidatos recuperados para cada consulta. Para ello, es necesario seleccionar un modelo cross-encoder adecuado que permita evaluar la relevancia de los pares (q, d) de manera más precisa.

Se obtuvo una lista de 90 modelos cross-encoder multilingües desde la plataforma Hugging Face, de los cuales se pudieron evaluar 72 dentro de las restricciones de compatibilidad y recursos del entorno. Se evaluó la capacidad de estos modelos mediante la reordenación de los 10, 25, 50 y 100 mejores candidatos generados por el sistema de fusión WSum previamente descrito⁵. Las Figuras 4.6 y 4.7 muestran la distribución de los resultados obtenidos en términos de MAP para los distintos tamaños de listas reordenadas.




Figura 4.6: Distribución de los resultados MAP obtenidos tras el re-ranking con distintos tamaños de listas.

Se puede observar que, frente a la asíntota marcada por los resultados obtenidos en la fase de fusión, los que han conseguido superar este han sido los modelos en la reordenación de las 10 y 25 mejores candidaturas. Por ello, tratando de buscar el valor óptimo de mejora, se seleccionaron los 10 mejores modelos en esta primera fase para realizar un análisis más detallado de su comportamiento. La Figura 4.8 muestra la distribución de los resultados obtenidos por estos modelos en función del tamaño de la lista reordenada. De forma individualizada también se puede observar en la Figura 4.9 la

⁵Una tabla completa con los resultados de esta evaluación se puede consultar en la Tabla A.3 del Apéndice A.




Figura 4.7: Boxplot de los resultados **MAP** obtenidos tras el re-ranking con distintos tamaños de listas.

degradación del rendimiento al aumentar el tamaño de la lista a reordenar⁶.




Figura 4.8: Boxplot de los resultados **MAP** obtenidos por los 10 mejores modelos tras el re-ranking con distintos tamaños de listas.

Con la perspectiva de maximizar el rendimiento del sistema, se seleccionó el modelo *Jsevisal/CrossEncoder-ModernBERT-base-qnli* para la fase final de re-ranking, ya que fue el que obtuvo el mejor desempeño al reordenar las 5 mejores candidaturas, alcanzando un **MAP** de **0.541862**. Este resultado representa una mejora significativa respecto al mejor desempeño

⁶Los datos numéricos pueden ser consultados en la Tabla A.4.




Figura 4.9: Rendimiento **MAP** individual de los 10 mejores modelos tras el re-ranking con distintos tamaños de listas.

previo obtenido en la fase de fusión de rankings, mejorando su resultado en más de 4 puntos porcentuales.

4.6. Evaluación sobre test

Finalmente, se procedió a evaluar el sistema completo, incluyendo todas las fases descritas, sobre el conjunto de datos de prueba. Para ello, el ranking producido por el sistema, fue enviado al sistema de evaluación sobre test de Codabench⁷. Los resultados obtenidos son los siguientes⁸.

4.6.1. Resultados sobre el español

Para el caso monolingüe español en el que se ha centrado este estudio, se ha obtenido un valor **MAP** de **0.497**. Este resultado, considerándolo como resultado final de la propuesta presentada, se posiciona en el octavo puesto de la clasificación general de la **Tarea A** para el caso monolingüe de español. En la Tabla 4.4 se muestra el ranking final proporcionado por la plataforma de evaluación.

⁷<https://www.codabench.org/competitions/5842/>

⁸Los datos que se muestran a continuación fueron tomados a fecha 31 de Enero de 2026, pudiendo existir propuestas posteriores que modifiquen los rankings aquí presentados.

Posición	Participante	MAP (es-es)
1	ranabarakat	0.527
2	omokhtar	0.522
3	ranabarakat	0.522
4	ranabarakat	0.521
5	jensjoris	0.519
6	omokhtar	0.516
7	pjmathematician	0.507
8	Propuesta	0.497
9	NLPnorth	0.496
10	pjmathematician	0.479

Tabla 4.4: Resultados finales obtenidos en el conjunto de test de la [Tarea A](#) para el caso monolingüe español.

Destaca aquí la presencia de un decrecimiento de más de 4 puntos porcentuales respecto al resultado obtenido sobre el conjunto de validación. Este hecho refleja la naturaleza distinta del conjunto de test, poniendo de manifiesto la diferencia de rendimiento del sistema frente a escenarios no vistos durante su desarrollo.

4.6.2. Resultados sobre otros idiomas

Aunque el enfoque principal de este trabajo ha sido el desarrollo de un sistema para el idioma español, la [Tarea A](#) también contempla la evaluación en otros idiomas, como el inglés y el alemán. Con el objetivo de analizar la capacidad de generalización del sistema propuesto, se procedió a evaluar el mismo modelo sobre los conjuntos de datos de prueba correspondientes a estos idiomas, sin realizar ningún ajuste adicional. Los resultados obtenidos se muestran en las Tablas [4.5](#) y [4.6](#).

En estos escenarios, el sistema propuesto alcanza la quinta posición en los idiomas inglés y alemán, mientras que para chino se sitúa en la octava posición. Estos resultados ponen de manifiesto la capacidad de generalización del enfoque adoptado, ya que todas las etapas del sistema se apoyan en modelos multilingües. Si bien se aprecia una leve mejora del rendimiento en estos idiomas en comparación con el español, este comportamiento puede atribuirse al uso de modelos preentrenados multilingües como base del sistema.

Posición	Participante	MAP (en-en)
1	pjmathematician	0.563
2	ranabarakat	0.559
3	omokhtar	0.554
4	ranabarakat	0.554
5	Propuesta	0.551
6	omokhtar	0.542
7	jensjoris	0.533
8	akacha	0.523
9	pjmathematician	0.520
10	NLPnorth	0.511

Tabla 4.5: Resultados finales obtenidos en el conjunto de test de la [Tarea A](#) para el caso monolingüe inglés.

Posición	Participante	MAP (de-de)
1	ranabarakat	0.516
2	omokhtar	0.515
3	ranabarakat	0.515
4	ranabarakat	0.515
5	Propuesta	0.508
6	pjmathematician	0.476
7	jensjoris	0.500
8	omokhtar	0.503
9	NLPnorth	0.484
10	pjmathematician	0.508

Tabla 4.6: Resultados finales obtenidos en el conjunto de test de la [Tarea A](#) para el caso monolingüe alemán.

4.6.3. Capacidad de generalización

Si hay tiempo, intentar evaluar los casos cross-lingües y mostrar los resultados aquí, para analizar mejor la generalización.

Para evaluar la capacidad de generalización del sistema propuesto, desde la organización se propusieron de forma voluntaria la evaluación sobre escenarios cross-lingües, así como la evaluación sobre el idioma chino, para el que no se disponía de datos de entrenamiento específicos. Aunque en nuestro caso no se contempló el entrenamiento adicional en ningún idioma que no fuera el español, se procedió a evaluar el sistema completo sobre los conjuntos de datos de prueba correspondientes, para así analizar su capacidad de generalización ante entornos nuevos. Los resultados obtenidos para el caso del chino se muestran en la [Tabla 4.7](#).

Posición	Participante	MAP (zh-zh)
1	pjmathematician	0.516
2	jensjoris	0.510
3	ranabarakat	0.508
4	omokhtar	0.507
5	ranabarakat	0.507
6	ranabarakat	0.506
7	omokhtar	0.505
8	Propuesta	0.502
9	akacha	0.497
10	NLPnorth	0.495

Tabla 4.7: Resultados finales obtenidos en el conjunto de test de la [Tarea A](#) para el caso monolingüe chino.

4.6.4. Rendimiento medio

Para la ordenación general de las propuestas enviadas, la organización se ha basado en el rendimiento medio entre los idiomas español, inglés y alemán sobre la métrica [MAP](#). El sistema aquí presentado ha alcanzado un valor medio de **0.521**, situándose en el sexto puesto de la clasificación general de la [Tarea A](#). Si consideramos únicamente la mejor propuesta de cada equipo, el sistema se posiciona como el tercer mejor equipo participante, lo que resalta la solidez y eficacia del enfoque adoptado en este trabajo. Los resultados completos pueden ser consultados en la [Tabla A.5](#) del apéndice.

Capítulo 5

Discusión

En este capítulo se realiza un análisis crítico y exhaustivo de los resultados experimentales expuestos en el capítulo anterior, así como de las decisiones de diseño tomadas durante la construcción del sistema. A pesar de las restricciones computacionales y temporales impuestas por el entorno de desarrollo, el sistema propuesto ha demostrado ser una solución competitiva, alcanzando la tercera posición por equipos en la clasificación general de la [Tarea A](#).

No obstante, el proceso experimental ha revelado hallazgos significativos sobre la naturaleza de los modelos multilingües, las limitaciones de las estrategias de fusión y la dicotomía entre el rendimiento en validación y en test, que merecen ser discutidos en profundidad para comprender tanto el éxito relativo del sistema como sus márgenes de mejora.

5.1. Selección de modelos base

5.1.1. Anglicismos y el sesgo del mercado laboral

Como se observó en la [Figura 4.1](#), existe una clara predominancia de los modelos multilingües en las puntuaciones altas del rendimiento. Resulta llamativo que modelos entrenados exclusivamente para el español queden relegados a un segundo plano¹. Este fenómeno puede atribuirse a dos factores

¹Cabe destacar que la información de en cuántos lenguajes se había entrenado cada modelo se ha extraído del último entrenamiento realizado, pero muchos de ellos son ajustes finos de modelos más generales, por lo general entrenados en grandes set de datos multilingües, reduciendo aun más la fiabilidad de las etiquetas monolingües que se muestran en la gráfica. Esto no quiere decir que las etiquetas no sean fiables, sino que los casos monolingües es posible que no sean monolingües de base.

principales.

En primer lugar, la naturaleza del mercado laboral actual, especialmente en sectores tecnológicos y corporativos, se caracteriza por una fuerte presencia de anglicismos en los títulos de las ofertas. Esta peculiaridad lingüística favorece a los modelos multilingües, que han procesado estos términos en su contexto original durante el preentrenamiento, frente a modelos monolingües que pueden tratar estos términos como vocabulario fuera de dominio o ruido.

En segundo lugar, existe una disparidad en la calidad de los recursos base. La mayoría de los modelos disponibles en repositorios como Hugging Face suelen ser variantes multilingües optimizadas de arquitecturas mayores². No se ha encontrado en la literatura un modelo de IR denso entrenado exclusivamente en español con una arquitectura y volumen de datos comparables, lo que ha obligado a basar el sistema en arquitecturas generalistas.

5.1.2. Redundancia arquitectónica

Además de la predominancia multilingüe, observamos también en la Figura 4.1 dos peculiaridades en la distribución de los modelos. La primera es la alineación vertical de varios modelos, lo que indica que comparten la misma arquitectura base y, por tanto, es probable que compartan también limitaciones y sesgos similares. Esta falta de diversidad arquitectónica puede haber limitado la capacidad del sistema para capturar diferentes aspectos de la tarea, ya que los modelos con arquitecturas similares tienden a cometer errores similares. Esta limitación se evidenció en la selección de los tres modelos para la fusión, donde dos de ellos compartían la misma arquitectura base (*Lajavaness/bilingual-embedding-large* y *jinaai/jina-embeddings-v3*, ambos basados en *XLM-RoBERTa*).

5.1.3. La curva del tamaño óptimo

La segunda peculiaridad es la existencia de un crecimiento y posterior decrecimiento del rendimiento en función del tamaño del modelo. Coincidiendo con las observaciones reportadas por la organización de TalentCLEF en (Gasco et al., 2025b), nuestros experimentos confirman empíricamente la

²Algunos ejemplos de estas son las familias *E5*, *BGE* o *MPNet*, con las que hemos trabajado en las evaluaciones.

existencia de un “punto dulce” en cuanto al tamaño de los modelos, situado entre los 500 y 1000 millones de parámetros.

Como se analizó en la sección 4.2, los modelos con un número de parámetros superior a este umbral no solo no mostraron mejoras significativas, sino que en varios casos presentaron un rendimiento inferior. Esto sugiere que, para la tarea específica que nos concierne, la capacidad de los grandes modelos del lenguaje no aporta ventajas sobre la capacidad de abstracción semántica de los modelos medianos, y sin embargo, sí penaliza gravemente la eficiencia computacional.

5.1.4. Sesgos en las fuentes de selección

Es necesario reconocer un sesgo metodológico en la selección inicial de los modelos candidatos. La dependencia del *MTEB Leaderboard* (Enevoldsen et al., 2025), aunque estándar en la industria, limita la visión a aquellos modelos que han sido reportados en dicha plataforma. Además, la inconsistencia en el etiquetado de modelos en Hugging Face dificultó la identificación precisa de arquitecturas especializadas, lo que pudo haber excluido candidatos potenciales que no estaban correctamente indexados.

En este sentido, una dificultad latente que persistió durante toda la búsqueda de modelos para la fase de Retrieval fue la falta de etiquetas fiables en Hugging Face sobre la funcionalidad de los modelos. Muchos modelos no estaban correctamente etiquetados como modelos de retrieval, lo que dificultó la identificación precisa de arquitecturas especializadas y pudo haber excluido candidatos potenciales que no estaban correctamente indexados. Esta limitación subraya la necesidad de una mayor estandarización en la documentación y etiquetado de modelos en repositorios públicos para facilitar futuras investigaciones.

5.2. Dinámicas de entrenamiento y adaptación

El proceso de fine-tuning reveló la fragilidad del aprendizaje supervisado cuando se dispone de datos limitados o sintéticos en un dominio altamente específico.

5.2.1. Sobreajuste temprano y limitación de datos

La decisión de detener el entrenamiento tras una única época fue forzada por la rápida degradación de la función de pérdida en el conjunto de validación, tal como se mostró en la Figura 4.2. Este sobreajuste temprano indica dos cosas: primero, que los modelos preentrenados ya poseían una representación semántica robusta; y segundo, que el conjunto de entrenamiento proporcionado no ofrecía suficiente diversidad para permitir una generalización más profunda sin incurrir en memorización.

La mejora marginal obtenida (aproximadamente 3 puntos porcentuales de media) sugiere que se alcanzó el máximo rendimiento posible con los datos disponibles. Una línea de investigación no explorada en este trabajo, pero que podría haber mitigado este colapso, habría sido el aumento de datos mediante fuentes externas o generación sintética, como hicieron otros participantes de la tarea.

5.2.2. Estrategia de selección para el ajuste fino

Se optó por reentrenar únicamente los 10 modelos con mejor desempeño en la sección de *Zero-Shot*. Analizando los resultados a posteriori, esta decisión puede verse como conservadora, pudiendo haber limitado el potencial del sistema. Un ejemplo claro es el modelo *Alibaba-NLP/gte-multilingual-base*, que partiendo del puesto 9 en la evaluación inicial, escaló hasta el top 3 tras el ajuste fino, convirtiéndose en una pieza clave del sistema final.

Esto sugiere que podrían existir un mayor número de modelos con una arquitectura con mejor predisposición al ajuste fino que, aunque inicialmente fueran menos precisos, al poseer una mayor capacidad de adaptación podrían haber aportado una subida en el rendimiento considerable. Haber ampliado el rango de selección podría haber descubierto otros modelos que no fueron considerados y que podrían haber aportado mayor valor tras el entrenamiento.

5.3. Análisis de la Arquitectura en Cascada

La arquitectura propuesta se fundamenta en la hipótesis de que la combinación de modelos diversos mejora la robustez. Sin embargo, el análisis de los componentes individuales revela limitaciones en la diversidad real conseguida.

5.3.1. La fusión y el problema de la diversidad

Aunque la técnica de [WSum](#) logró superar el rendimiento de los modelos individuales, la ganancia fue extremadamente baja frente a los datos de validación. Un análisis detallado de los tres modelos finalistas seleccionados revela, como comentamos anteriormente, un problema de redundancia arquitectónica.

Dos de los modelos base comparten fundamentos arquitectónicos muy similares (basados en variantes de *XLM-RoBERTa* y entrenados con objetivos similares). Esta falta de diversidad arquitectónica implica que los modelos tienden a compartir los mismos sesgos inductivos y a cometer errores similares, reduciendo la eficacia teórica de la fusión. Como se intuía en la alineación vertical de la Figura 4.1, haber forzado la selección de modelos con arquitecturas distintas, incluso sacrificando ligeramente el rendimiento individual, podría haber maximizado la complementariedad y, por ende, el resultado final de la fusión. Sin embargo, la decisión basada en tomar simplemente los mejores modelos individuales puede haber limitado el potencial de esta etapa del sistema.

5.3.2. Re-ranking

La etapa de re-ranking se planteó inicialmente con una metodología análoga a la de recuperación: una evaluación masiva de candidatos para seleccionar empíricamente el mejor modelo. Sin embargo, esta fase se enfrentó a obstáculos significativos relacionados con la disponibilidad y clasificación de los recursos, así como dilemas críticos sobre la estabilidad frente al rendimiento máximo.

Limitaciones en la taxonomía y selección de fuentes

A diferencia de los modelos de recuperación densa, que cuentan con benchmarks como el [Evaluación Masiva de Embeddings de Texto \(MTEB\)](#), no se dispone de un ranking público exhaustivo y actualizado específicamente para modelos *cross-encoder* en tareas de similitud semántica multilingüe. Esto obligó a realizar una búsqueda manual en el repositorio de Hugging Face, revelando una inconsistencia sistemática en el etiquetado de los modelos.

Al igual que con los modelos de retrieval, se observó que una gran can-

tividad de arquitecturas no poseen las etiquetas correctas de metadatos. Esta falta de estandarización generó un sesgo inevitable: la selección se limitó a aquellos modelos correctamente indexados, resultando en un conjunto de evaluación de aproximadamente 90 modelos. Si bien es una cifra considerable, no es representativa de la totalidad del estado del arte, quedando fuera potenciales candidatos mal etiquetados.

Análisis de sensibilidad a la profundidad

Uno de los hallazgos empíricos más relevantes de esta fase fue la relación inversa entre la profundidad de reordenación (k) y la calidad del ranking final. Se evaluó el comportamiento del sistema reordenando listas de candidatos de tamaños $k \in \{5, 10, 25, 50, 100\}$.

Los resultados demostraron que, para esta tarea específica, reordenar un número elevado de candidatos introduce más ruido del que corrige. Como se ilustra en la Figura 4.9, la mayoría de los modelos mostraron una degradación del rendimiento sobre la línea base de fusión cuando $k \geq 20$.

Además, el modelo finalmente seleccionado, *CrossEncoder-ModernBERT*, mostró el mejor desempeño absoluto para un $k = 5$ estricto, maximizando la métrica MAP en el conjunto de validación. Sin embargo, su rendimiento cae rápidamente al aumentar k , indicando una alta sensibilidad al ruido.

Por el contrario, modelos como *posih-reranker-base-mse* mostraron un comportamiento atípico: a pesar de tener un rendimiento inicial pobre en $k = 5$, sufrían la menor degradación al aumentar la profundidad de la lista. Sorprende de igual manera el caso de *mmarco-mMiniLMv2-L12-H384-v1*, que fue el único modelo capaz de mejorar su rendimiento al aumentar k de 5 a 10, manteniendo una curva de degradación muy suave posteriormente. Este comportamiento podría indicar una capacidad superior para generalizar y discriminar correctamente en listas más largas y ruidosas.

Sin embargo, dado que el objetivo principal era maximizar la métrica MAP en validación, se optó por seleccionar el modelo con el mejor rendimiento absoluto para $k = 5$. Esta decisión, aunque justificada desde una perspectiva de optimización de métricas, pudo haber comprometido la estabilidad del sistema frente a variaciones en los datos. En retrospectiva, y a la luz de la caída de rendimiento en el conjunto de test, es muy probable que una opción más conservadora y estable como *mmarco-mMiniLMv2* hubiera ofrecido una mejor generalización ante datos no vistos, sacrificando la

métrica en validación a cambio de de una mayor robustez.

5.4. Discrepancia entre validación y test

5.4.1. Sobreestimación y cambio de dominio

Quizás el punto más crítico de la discusión es la notable caída del rendimiento al evaluar sobre el conjunto de test. Este descenso confirma que los conjuntos de entrenamiento y validación provenían de un mismo dominio, lo que llevó a una sobreestimación de la capacidad real del sistema durante el desarrollo. El conjunto de test, proveniente de una fuente y una distribución de datos distinta, penalizó el sobreajuste del sistema a los datos de [ESCO](#).

5.4.2. La paradoja del rendimiento por idioma

Resulta paradójico que, habiendo optimizado el sistema específicamente para el español, los resultados finales en el conjunto de test fueran superiores para el inglés (0.551), el alemán (0.508) e incluso para el chino (0.502), relegando al español a la peor posición relativa.

Este fenómeno refuerza la hipótesis planteada al inicio de este capítulo: los modelos base multilingües poseen representaciones internas más ricas y robustas para el inglés, idioma dominante en la red y por tanto en datos de entrenamiento. El esfuerzo de especialización en español mediante *fine-tuning* no fue suficiente para compensar la ventaja estructural que estos modelos tienen en otros idiomas de mayores recursos.

A pesar de esto, el sistema demostró una capacidad de generalización notable. Esto valida la robustez de la arquitectura base multilingüe ante idiomas no vistos, aunque también sugiere que la estrategia de especialización monolingüe en sistemas densos es extremadamente difícil si no se cuenta con corpus masivos del idioma objetivo.

5.5. Conclusión del análisis

A pesar de las limitaciones discutidas (la falta de diversidad en la fusión, el sobreajuste a los datos de validación y la dificultad de encontrar modelos puros en español), el sistema ha demostrado ser robusto. Alcanzar el sexto puesto global y ser el tercer mejor participante, superando a propuestas

complejas como las de NLPnorth ([Zhang y van der Goot, 2025](#)) o Pjmathematician ([Vachharajani, 2025](#)) en varios escenarios, valida la arquitectura en cascada propuesta.

El análisis de errores sugiere que el techo de rendimiento no se encuentra tanto en la complejidad de la arquitectura, sino en la calidad y diversidad de los datos de entrenamiento y en una selección más estratégica de modelos complementarios que eviten la redundancia de sesgos y reduzcan el ruido.

Capítulo 6

Conclusiones y trabajo futuro

Este capítulo final sintetiza los hallazgos principales derivados del desarrollo y evaluación del sistema propuesto para la tarea de [JTM](#), y delinea las líneas de investigación que quedan abiertas para futuras iteraciones del proyecto.

6.1. Conclusiones

El desarrollo de este trabajo ha permitido validar la eficacia de una arquitectura modular en cascada para la recuperación de titulaciones profesionales en español. La estrategia implementada, que transita desde una recuperación densa eficiente mediante bi-encoders hacia un refinamiento preciso con cross-encoders, ha demostrado ser altamente competitiva en el marco de la competición TalentCLEF 2025. Los resultados obtenidos confirman que los métodos híbridos son esenciales para equilibrar el compromiso entre exhaustividad y precisión semántica en tareas de [IR](#) aplicadas al dominio de esta tarea.

Uno de los hallazgos más relevantes y contraintuitivos de este estudio ha sido la supremacía de los modelos multilingües sobre las aproximaciones monolingües. A pesar de que la hipótesis inicial sugería una ventaja para los modelos especializados en español, la evaluación experimental evidenció que arquitecturas entrenadas en múltiples idiomas generan representaciones más ricas y robustas. Asimismo, se observó que la etapa de re-ranking mediante cross-encoders aportó la mayor ganancia neta en la métrica [MAP](#), aunque

con una fuerte sensibilidad a la profundidad de la lista de candidatos.

No obstante, el sistema también reveló limitaciones importantes relacionadas con la generalización. La discrepancia observada entre los resultados de validación y test sugiere un sobreajuste temprano, derivado de la naturaleza sintética y limitada de los datos de entrenamiento basados en [ESCO](#). Aunque la arquitectura híbrida debería haber mitigado parcialmente los sesgos individuales de los modelos, la ganancia fue marginal posiblemente debido a las decisiones tomadas en la selección de los modelos base. En general, este estudio establece una referencia interesante en el campo de [HCM](#), demostrando que es viable construir soluciones de alto rendimiento aprovechando modelos preentrenados, siempre que se gestionen adecuadamente las estrategias de adaptación al dominio y la calidad de los datos.

6.2. Trabajo futuro

Partiendo de las limitaciones identificadas y las lecciones aprendidas durante el desarrollo de este trabajo, se abren diversas vías para la evolución del sistema. Una prioridad inmediata debe ser la ingeniería de datos y el aumento sintético del corpus. Para combatir el sobreajuste y mejorar la generalización ante datos reales no vistos, es fundamental enriquecer el entrenamiento generando pares positivos y negativos difíciles, así como incorporar fuentes de datos externas que aporten una mayor variabilidad terminológica más allá de la taxonomía oficial.

Desde una perspectiva arquitectónica, las futuras iteraciones deberían centrarse en una diversificación más estratégica durante la etapa de fusión. En lugar de combinar modelos basándose únicamente en su métrica de rendimiento individual, sería más beneficioso integrar enfoques que maximicen la ortogonalidad de los errores y puedan capturar matices complementarios. Asimismo, dado el coste computacional del sistema propuesto, se plantea viabilizar su implementación para entornos de producción, sin sacrificar significativamente la precisión.

Finalmente, sería interesante abordar la dimensión ética y la transferibilidad del sistema. Sería muy interesante incorporar módulos específicos para la detección y mitigación de sesgos de género en las representaciones vectoriales, asegurando una normalización de competencias equitativa. Del mismo modo, extender la evaluación a dominios adyacentes permitiría veri-

ficar la robustez y versatilidad de la arquitectura propuesta en el ecosistema más amplio de la gestión del talento.

A lo mejor se puede plantear como siguiente paso la participación en TalentCLEF2026, ahora en curso, para ver cómo de extrapolable es la arquitectura planteada.

Bibliografía

Bibliografía

- [Barakat et al.2025] Barakat, Rana, Omar Mokhtar, Marwan Torki, y Nagwa Elmakky. 2025. Alexu-nlp at talentclef 2025: curriculum-driven hybrid retrieval for multilingual job title matching. *CLEF (Working Notes)*.
- [Bhangale, Gabhane, y Kumar2025] Bhangale, C, P Gabhane, y MA Kumar. 2025. Fine-tuned sentence transformer for multilingual job title matching. *CLEF (Working Notes)*.
- [Brikman, Sana, y Ruegger2025] Brikman, Adam, Michael Sana, y Holden Ruegger. 2025. Multilingual job title matching with mpnet-based sentence transformers. *CLEF (Working Notes)*.
- [Cormack, Clarke, y Buettcher2009] Cormack, Gordon V, Charles LA Clarke, y Stefan Buettcher. 2009. Reciprocal rank fusion outperforms concordet and individual rank learning methods. En *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, páginas 758–759.
- [De Toledo, Núñez, y Usabiaga2008] De Toledo, Pablo Álvarez, Fernando Núñez, y Carlos Usabiaga. 2008. La función de emparejamiento en el mercado de trabajo español. *Revista de economía aplicada*, 16(48):5–35.
- [de Toledo Saavedr, Hernández, y Ibáñez2017] de Toledo Saavedr, Pablo Álvarez, Fernando Núñez Hernández, y Carlos Usabiaga Ibáñez. 2017. ¿quién se empareja con quién en el mercado laboral español? un análisis cluster basado en la muestra continua de vidas laborales. *Investigación económica*, 76(299):87–124.

- [Decorte, De Lange, y Van Hautte2025] Decorte, Jens-Joris, Matthias De Lange, y Jeroen Van Hautte. 2025. Multilingual jobbert for cross-lingual job title matching. *arXiv preprint arXiv:2507.21609*.
- [Enevoldsen et al.2025] Enevoldsen, Kenneth, Isaac Chung, Imene Kerboua, Márton Kardos, Ashwin Mathur, David Stap, Jay Gala, Wissam Siblini, Dominik Krzemiński, Genta Indra Winata, Saba Sturua, Saiteja Utpala, Mathieu Ciancone, Marion Schaeffer, Gabriel Sequeira, Diganta Misra, Shreeya Dhakal, Jonathan Rystrøm, Roman Solomatin, Ömer Çağatan, Akash Kundu, Martin Bernstorff, Shitao Xiao, Akshita Sukhlecha, Bhavish Pahwa, Rafał Poświata, Kranthi Kiran GV, Shawon Ashraf, Daniel Auras, Björn Plüster, Jan Philipp Harries, Loïc Magne, Isabelle Mohr, Mariya Hendriksen, Dawei Zhu, Hippolyte Gisserot-Boukhlef, Tom Aarsen, Jan Kostkan, Konrad Wojtasik, Taemin Lee, Marek Šuppa, Crystina Zhang, Roberta Rocca, Mohammed Hamdy, Andrianos Michail, John Yang, Manuel Faysse, Aleksei Vatolin, Nandan Thakur, Manan Dey, Dipam Vasani, Pranjal Chitale, Simone Tedeschi, Nguyen Tai, Artem Snegirev, Michael Günther, Mengzhou Xia, Weijia Shi, Xing Han Lù, Jordan Clive, Gayatri Krishnakumar, Anna Maksimova, Silvan Wehrli, Maria Tikhonova, Henil Panchal, Aleksandr Abramov, Malte Ostendorff, Zheng Liu, Simon Clematide, Lester James Miranda, Alena Fenogenova, Guangyu Song, Ruqiya Bin Safi, Wen-Ding Li, Alessia Borghini, Federico Cassano, Hongjin Su, Jimmy Lin, Howard Yen, Lasse Hansen, Sara Hooker, Chenghao Xiao, Vaibhav Adlakha, Orion Weller, Siva Reddy, y Niklas Muennighoff. 2025. Mmteb: Massive multilingual text embedding benchmark. *arXiv preprint arXiv:2502.13595*.
- [Gasco et al.2024] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2024. Motivation — talentclef.github.io. <https://talentclef.github.io/talentclef/docs/talentclef-2025/motivation/>. [Accessed 10-11-2025].
- [Gasco et al.2025a] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2025a. Brief overview of talentclef 2025. *Journal of knowledge management*.
- [Gasco et al.2025b] Gasco, Luis, Hermenegildo Fabregat, Laura García-

- Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2025b. Overview of the talentclef 2025: Skill and job title intelligence for human capital management. En *International Conference of the Cross-Language Evaluation Forum for European Languages*, páginas 464–485. Springer.
- [Guo et al.2025] Guo, Yanzhu, Simone Conia, Zelin Zhou, Min Li, Saloni Potdar, y Henry Xiao. 2025. Do large language models have an english accent? evaluating and improving the naturalness of multilingual llms. En *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, páginas 3823–3838.
- [Hou y Li2023] Hou, Pengyue y Xingyu Li. 2023. Improving contrastive learning of sentence embeddings with focal-infonce. *arXiv preprint arXiv:2310.06918*.
- [Inc.2024] Inc., Hugging Face. 2024. Retrieve & Re-Rank; Sentence Transformers documentation — sbert.net. https://sbert.net/examples/sentence_transformer/applications/retrieve_rerank/README.html. [Accessed 13-11-2025].
- [Jirjees et al.2025] Jirjees, Aram Khasro, Aram M Ahmed, Abdulhady Abas Abdulla, Joan Lu, Ekhlas Mohammed Noori, Rozhgar Nasradeen Kareem, Bryar A Hassan, Hadi Veisi, y Tarik A Rashid. 2025. Machine learning for recruitment: Analyzing job-matching algorithms. *Machine Learning*, 27:1.
- [Karpukhin et al.2020] Karpukhin, Vladimir, Barlas Oguz, Sewon Min, Patrick SH Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, y Wen-tau Yih. 2020. Dense passage retrieval for open-domain question answering. En *EMNLP (1)*, páginas 6769–6781.
- [Liu y others2009] Liu, Tie-Yan y others. 2009. Learning to rank for information retrieval. *Foundations and Trends® in Information Retrieval*, 3(3):225–331.
- [Mamani Rodriguez2022a] Mamani Rodriguez, Zoraida. 2022a. Proceso de machine learning para determinar la demanda social de puestos de empleo de profesionales de ti. *Industrial Data*, 25(2):275–300.

- [Mamani Rodriguez2022b] Mamani Rodriguez, Zoraida Emperatriz. 2022b. Machine learning no supervisado en la detección de similitud de puestos de empleo de profesionales de ti. *Industrial Data*.
- [Mao, Chu, y Kurohashi2024] Mao, Zhuoyuan, Chenhui Chu, y Sadao Kurohashi. 2024. Ems: Efficient and effective massively multilingual sentence embedding learning. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 32:2841–2856.
- [Maslej et al.2025] Maslej, Nestor, Loredana Fattorini, Raymond Perrault, Yolanda Gil, Vanessa Parli, Njenga Kariuki, Emily Capstick, Anka Reuel, Erik Brynjolfsson, John Etchemendy, y others. 2025. Artificial intelligence index report 2025. *arXiv preprint arXiv:2504.07139*.
- [Nga, Tuyen, y Van Thin2025] Nga, Ho Thuy, Ho Thi Thanh Tuyen, y Dang Van Thin. 2025. Nt team at multilingual job title matching task a: job matching via large language model-based description generation and retrieval. *CLEF (Working Notes)*.
- [Nizami et al.2025] Nizami, Muhammad Hasan, Ahtisham Uddin, Muhammad Talha Salani, Ayesha Saeed, Faisal Alvi, y Abdul Samad. 2025. Enhancing human capital management: Ai techniques for candidate matching and skill extraction. *CLEF (Working Notes)*.
- [Nogueira y Cho2019] Nogueira, Rodrigo y Kyunghyun Cho. 2019. Passage re-ranking with bert. *arXiv preprint arXiv:1901.04085*.
- [Novoa et al.2025] Novoa, Melissa Moreno, Juan Carlos Martinez-Santos, Jairo Serrano, y Edwin Puertas. 2025. Verbanex at talentclef2025: Semantic matching of multilingual job titles through a framework integrating esco taxonomy. *CLEF (Working Notes)*.
- [Ordóñez de Pablos y Lytras2008] Ordóñez de Pablos, Patricia y Miltiadis D Lytras. 2008. Competencies and human resource management: implications for organizational competitive advantage. *Journal of knowledge management*, 12(6):48–55.
- [Reimers y Gurevych2019] Reimers, Nils y Iryna Gurevych. 2019. Sentence-bert: Sentence embeddings using siamese bert-networks. *arXiv preprint arXiv:1908.10084*.

- [Robertson, Zaragoza, y others2009] Robertson, Stephen, Hugo Zaragoza, y others. 2009. The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends® in Information Retrieval*, 3(4):333–389.
- [Rodriguez, Perez-de Viñaspre, y Perez2025] Rodriguez, Mar, Olatz Perez-de Viñaspre, y Naiara Perez. 2025. A two-stage multilingual job title matching system: combining expert knowledge and llm-based ranking. *CLEF (Working Notes)*.
- [Rodríguez-Vidal et al.2025] Rodríguez-Vidal, Javier, Ascensión López-Vargas, PM Vígara Gallego, Francisco Javier Del Álamo, y A García-Beltrán. 2025. Udi-upm at talentclef 2025: task a-multilingual job title matching. *CLEF (Working Notes)*.
- [Rojas-Galeano, Posada, y Ordoñez2022] Rojas-Galeano, Sergio, Jorge Posada, y Esteban Ordoñez. 2022. A bibliometric perspective on ai research for job-résumé matching. *The Scientific World Journal*, 2022(1):8002363.
- [Salton, Wong, y Yang1975] Salton, Gerard, Anita Wong, y Chung-Shu Yang. 1975. A vector space model for automatic indexing. *Communications of the ACM*, 18(11):613–620.
- [Solatorio2024] Solatorio, Aivin V. 2024. Gistembed: Guided in-sample selection of training negatives for text embedding fine-tuning. *arXiv preprint arXiv:2402.16829*.
- [Vachharajani2025] Vachharajani, Poojan. 2025. Pjmathematician at talentclef 2025: enhancing job title and skill matching with gistembed and llm-augmented data. *CLEF (Working Notes)*.
- [Vaswani et al.2017] Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, y Illia Polosukhin. 2017. Attention is all you need. *Advances in neural information processing systems*, 30.
- [W3Techs2023] W3Techs, A. 2023. Usage statistics of content languages for websites.

- [Wu, Crestani, y Bi2006] Wu, Shengli, Fabio Crestani, y Yaxin Bi. 2006. Evaluating score normalization methods in data fusion. En *Asia Information Retrieval Symposium*, páginas 642–648. Springer.
- [Xu et al.2025] Xu, Zhichao, Fengran Mo, Zhiqi Huang, Crystina Zhang, Puxuan Yu, Bei Wang, Jimmy Lin, y Vivek Srikumar. 2025. A survey of model architectures in information retrieval. *arXiv preprint arXiv:2502.14822*.
- [Zhang y van der Goot2025] Zhang, Mike y Rob van der Goot. 2025. Nl-pnorth@ talentclef 2025: Comparing discriminative, contrastive, and prompt-based methods for job title and skill matching. *arXiv preprint arXiv:2506.19058*.

Glosario

AI Artificial Intelligence (Inteligencia Artificial). [1](#), [13](#)

AP Average Precision (Precisión Promedio). [27](#)

BM25 Best Matching 25 (Mejor Coincidencia 25). [8](#)

CL aprendizaje contrastivo (contrastive learning). [4](#), [20](#)

DL Deep Learning (Aprendizaje Profundo). [9](#)

ESCO European Skills, Competences, Qualifications and Occupations (Habilidades, Competencias, Cualificaciones y Ocupaciones Europeas). [v](#), [vii](#), [3](#), [15](#), [16](#), [28](#), [49](#), [52](#)

HCM Human Capital Management (Gestión del Capital Humano). [1–3](#), [12](#), [13](#), [52](#)

InfoNCE Information Noise-Contrastive Estimation (Estimación de Contraste de Ruido de Información). [19](#), [20](#)

IR Information Retrieval (Recuperación de Información). [7–10](#), [16](#), [18](#), [44](#), [51](#)

ISCO International Standard Classification of Occupations (Clasificación Internacional Uniforme de Ocupaciones). [16](#)

JTM Job Title Matching (Emparejamiento de Titulaciones Profesionales). [v](#), [vii](#), [12–14](#), [51](#)

LLM Large Language Model (Modelo de Lenguaje Grande). [15](#), [16](#), [18](#), [19](#)

LTR Learning to Rank (Aprendizaje para Ordenación). [8](#), [9](#)

MAP Mean Average Precision (Precisión Media Promedio). [v](#), [vii](#), [xiii](#), [xv](#), [xvi](#), [3](#), [4](#), [23](#), [27](#), [28](#), [31–38](#), [41](#), [48](#), [51](#), [64](#), [66](#), [67](#)

ML Machine Learning (Aprendizaje Automático). [8](#), [13](#)

MNRL Multiple Negatives Ranking Loss (Pérdida de Clasificación con Múltiples Negativos). [26](#), [28](#), [32](#)

MNZ Mean Normalized Z-score (Métrica de Normalización Z-Score). [24](#), [25](#), [34](#)

MTEB Massive Text Embedding Benchmark (Evaluación Masiva de Embeddings de Texto). [47](#)

NLP Natural Language Processing (Procesamiento del Lenguaje Natural). [1](#), [2](#)

RBO Rank Biased Overlap (Superposición Sesgada por Rango). [3](#), [17](#)

RRF Reciprocal Rank Fusion (Fusión Recíproca de Rangos). [xiii](#), [24](#), [25](#), [28](#), [34](#)

Tarea A Tarea A: Emparejamiento Multilingüe de Titulaciones Profesionales (Multilingual Job Title Matching) de la campaña de evaluación TalentCLEF 2025. [v](#), [vii](#), [xv](#), [3](#), [4](#), [14](#), [17](#), [21](#), [27](#), [30](#), [38–41](#), [43](#)

WSum Weighted Sum (Suma Ponderada). [25](#), [28](#), [35](#), [36](#), [47](#)

Apéndice A

Tablas

En este apéndice se incluyen las tablas de resultados completas obtenidas durante la evaluación de los modelos, que por razones de espacio no se han podido incluir en el cuerpo principal del documento. Estas tablas proporcionan una visión detallada del desempeño de cada modelo en las diferentes tareas y conjuntos de datos evaluados.

ranking	model_name	num_params	map_es_es
1	Lajavaness/bilingual-embedding-large	559890432	0.4493
2	jinaai/jina-embeddings-v3	572310396	0.4453
3	chienpham/sts-multilingual-mpnet-base-v2	278043648	0.4436
4	intfloat/multilingual-e5-large-instruct	559890432	0.4426
5	AIDA-UPM/mstsb-paraphrase-multilingual-mpnet-base-v2	278043648	0.4287
6	shtilev/medical_embedded_v4	278043648	0.4265
7	sentence-transformers/paraphrase-multilingual-mpnet-base-v2	278043648	0.4169
8	Alibaba-NLP/gte-multilingual-base	305368320	0.4155
9	shtilev/medical_embedded_v5	278043648	0.4117
10	Linq-AI-Research/Linq-Embed-Mistral	7110660096	0.4095
11	upskyy/e5-large-korean	559890432	0.4058
12	Lajavaness/bilingual-embedding-small	117653760	0.4053
13	upskyy/gte-base-korean	305368320	0.4018
14	Omartificial-Intelligence-Space/Arabic-all-nli-triplet-Matryoshka	278043648	0.4013
15	upskyy/e5-base-korean	278043648	0.3953
16	ibm-granite/granite-embedding-278m-multilingual	278043648	0.3921
17	OneFly7/biencoder_ep10_bs64_trans1	278043648	0.3901
18	Omartificial-Intelligence-Space/Arabic-labse-Matryoshka	471517440	0.3888
19	shtilev/medical_embedded_v3	278043648	0.3875
20	OneFly7/bi_bs32_lr2e5_cosine_restart_period2_best	278043648	0.3847
21	jinaai/jina-embeddings-v2-base-es	160850688	0.3841
22	Snowflake/snowflake-arctic-embed-l-v2.0	567754752	0.3833
23	Lajavaness/bilingual-embedding-base	278043648	0.3827
24	sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2	117653760	0.3766
25	tomaarsen/distiluse-base-multilingual-cased-v2	134734080	0.3749
26	Qwen/Qwen3-Embedding-0.6B	595776512	0.3718
27	Omartificial-Intelligence-Space/Arabic-MiniLM-L12-v2-all-nli-triplet	117653760	0.3708
28	HIT-TMG/KaLM-embedding-multilingual-mini-v1	494032768	0.3705
29	OneFly7/biencoder_ep2_bs32_trans3	278043648	0.3700
30	upskyy/bge-m3-korean	567754752	0.3692
31	lang-uk/ukr-paraphrase-multilingual-mpnet-base	278043648	0.3692
32	HIT-TMG/KaLM-embedding-multilingual-mini-instruct-v1	494032768	0.3681
33	Griffin88/sentence-embedding-LaBSE	471517440	0.3661
34	OneFly7/biencoder_ep10_bs32_lr2e5_cosine_annealing_hard_neg_2	278043648	0.3642
35	OneFly7/biencoder_ep10_bs64_trans3	278043648	0.3613
36	hiiamsid/sentence_similarity_spanish_es	109850880	0.3601
37	manu/sentence_croissant_alpha_v0.3	1279887360	0.3601
38	hiiamsid/sentence_similarity_spanish_es	109850880	0.3599
39	OneFly7/biencoder_ep10_bs64_all	278043648	0.3592
40	OrdalieTech/Solon-embeddings-large-0.1	559890432	0.3577
41	DmitryML/distiluse-base-multilingual-cased-v1	135127808	0.3549
42	upskyy/e5-small-korean	117653760	0.3545
43	intfloat/multilingual-e5-small	117653760	0.3513
44	infly/inf-retriever-v1-1.5b	1543268864	0.3474
45	emersoftware/tulio-chilean-spanish-bert-finetuned-msmarco-qa-es	109850880	0.3471
46	intfloat/multilingual-e5-base	278043648	0.3463
47	OneFly7/biencoder_ep10_bs32_lr2e5_cosine_annealing_hard_neg_1	278043648	0.3459
48	manu/sentence_croissant_alpha_v0.4	1279887360	0.3436
49	mrm8488/distiluse-base-multilingual-cased-v2-finetuned-stsb_multi_mt-es	134734080	0.3421
50	thenlper/gte-large	335141888	0.3414
51	intfloat/multilingual-e5-large	559890432	0.3381
52	avsolatorio/GIST-large-Embedding-v0	335141888	0.3370
53	symanto/sn-xlm-roberta-base-snli-mnli-anli-xnli	278043648	0.3368
54	h4g3n/multilingual-MiniLM-L12-de-en-es-fr-it-nl-pl-pt	103458048	0.3326
55	mixedbread-ai/mxbai-embed-large-v1	335141888	0.3317
56	WhereIsAI/UAE-Large-V1	335141888	0.3283
57	sdadas/mmlw-e5-large	559890432	0.3280
58	narraticlabs/MiniLM-L6-european-union	107006976	0.3231
59	nomic-ai/nomic-embed-text-v1.5	136731648	0.3225
60	BAAI/bge-large-en-v1.5	335141888	0.3212
61	thenlper/gte-base	109482240	0.3199
62	Maite89/Roberta_finetuning_semantic_similarity_stsb_multi_mt	355356672	0.3187
63	avsolatorio/GIST-Embedding-v0	109482240	0.3170
64	OneFly7/biencoder_ep10_bs32_trans3	278043648	0.3103
65	sdadas/mmlw-e5-base	278043648	0.3089
66	hackathon-pln-es/paraphrase-spanish-distilroberta	124645632	0.3067
67	somosnlp-hackathon-2022/paraphrase-spanish-distilroberta	124645632	0.3064
68	BAAI/bge-m3	567754752	0.3052
69	manu/sentence_croissant_alpha_v0.2	1279887360	0.3050
70	thenlper/gte-small	33360000	0.3044
71	deepvk/USER-bge-m3	359026688	0.3035
72	chukbert/paraphrase-multilingual-MiniLM-L12-v2-MSRP-Indo-finetuned-2-epoch	117653760	0.3023
73	BAAI/bge-base-en-v1.5	109482240	0.3012
74	Snowflake/snowflake-arctic-embed-m-v1.5	108891648	0.3002
75	intfloat/e5-base-v2	109482240	0.2992

Tabla A.1: Resultados completos de los 75 mejores modelos evaluados sobre la métrica [MAP](#) monolingüe en español en la evaluación zero-shot.

Model Name	MTEB Retrieval (avg)
nvidia/llama-embed-nemotron-8b	68.69
tencent/KaLM-Embedding-Gemma3-12B-2511	75.66
Qwen/Qwen3-Embedding-8B	70.88
Qwen/Qwen3-Embedding-4B	69.60
infly/inf-retriever-v1	66.48
jinaai/jina-embeddings-v4	66.43
Alibaba-NLP/gte-Qwen2-7B-instruct	60.08
Linq-AI-Research/Linq-Embed-Mistral	58.69
Alibaba-NLP/gte-Qwen2-1.5B-instruct	60.78
Qwen/Qwen3-Embedding-0.6B	64.65
nvidia/NV-Embed-v2	56.72
google/embeddinggemma-300m	62.49
infly/inf-retriever-v1-1.5b	62.96
parasail-ai/GritLM-7B-vllm	58.31
Salesforce/SFR-Embedding-Mistral	59.44
GritLM/GritLM-8x7B	57.54
Salesforce/SFR-Embedding-2_L	57.93
NovaSearch/jasper_en_vision_language_v1	55.12
nvidia/NV-Embed-v1	53.98
intfloat/e5-mistral-7b-instruct	55.75
intfloat/multilingual-e5-large-instruct	57.12
Snowflake/snowflake-arctic-embed-l-v2.0	58.36
NovaSearch/stella_en_1.5B_v5	52.84
HIT-TMG/KaLM-embedding-multilingual-mini-v1	54.17
Snowflake/snowflake-arctic-embed-m-v2.0	54.83
OrdalieTech/Solon-embeddings-large-0.1	55.69
HIT-TMG/KaLM-embedding-multilingual-mini-instruct-v1	50.84
Alibaba-NLP/gte-multilingual-base	57.16
Lajavaness/bilingual-embedding-large	55.10
intfloat/multilingual-e5-large	53.67
BAAI/bge-m3	54.60
jinaai/jina-embeddings-v3	55.76
ibm-granite/granite-embedding-278m-multilingual	52.20
WhereIsAI/UAE-Large-V1	41.21
avsolatorio/GIST-large-Embedding-v0	40.41
gandolfi/bge-m3-custom-fr-Q4_K_M-GGUF	53.26
intfloat/multilingual-e5-base	52.72
Snowflake/snowflake-arctic-embed-s	39.84
Snowflake/snowflake-arctic-embed-l-v2.0	39.66
mixedbread-ai/mxbai-embed-large-v1	40.30
NovaSearch/stella_en_400M_v5	42.58
Lajavaness/bilingual-embedding-base	52.96
intfloat/e5-large-v2	40.06
nomic-ai/nomic-embed-text-v1-unsupervised	40.66
nomic-ai/nomic-embed-text-v1-ablated	40.74
ibm-granite/granite-embedding-125m-english	39.26
BAAI/bge-large-en-v1.5	39.00
Snowflake/snowflake-arctic-embed-m-v1.5	38.69
Snowflake/snowflake-arctic-embed-m-long	39.30
Snowflake/snowflake-arctic-embed-m-v1.5	39.33
McGill-NLP/LLM2Vec-Mistral-7B-Instruct-v2-mntp-supervised	43.07
intfloat/e5-base-v2	40.49
Lajavaness/bilingual-embedding-small	49.55
BAAI/bge-base-en-v1.5	38.61
bartowski/granite-embedding-107m-multilingual-GGUF	48.08
avsolatorio/GIST-Embedding-v0	38.45
deepvk/USER-bge-m3	43.30
thenlper/gte-large	38.23
intfloat/multilingual-e5-large	38.50
intfloat/e5-small-v2	39.38
avsolatorio/GIST-small-Embedding-v0	37.22
intfloat/multilingual-e5-small	49.38
avsolatorio/NoInstruct-small-Embedding-v0	37.81
BAAI/bge-small-en-v1.5	36.26
abhinand/MedEmbed-small-v0.1	35.16
ibm-granite/granite-embedding-30m-english	36.43
manu/sentence.croissant.alpha.v0.4	38.35
AIDA-UPM/mstsb-paraphrase-multilingual-mpnet-base-v2	39.76
thenlper/gte-small	35.99
thenlper/gte-base	35.86
manu/sentence.croissant.alpha.v0.3	37.27
intfloat/multilingual-e5-base	37.69
jinaai/jina-embedding-b-en-v1	37.96
nomic-ai/nomic-embed-text-v1.5	37.05
Snowflake/snowflake-arctic-embed-l-v2.0	35.23

Tabla A.2: Muestra de los 75 mejores modelos extraídos del repositorio MTEB, ordenados por media de resultados obtenidos en los benchmarks asociados a la tarea de Retrieval.

Si hay tiempo, intentar formatar estas tablas como longtable, para poder mostrar todos los resultados.

Model Name	Size	k=10	k=25	k=50	k=100
cross-encoder/ms-marco-TinyBERT-L2-v2	4386561	0.4935	0.4781	0.4506	0.4104
cross-encoder/ms-marco-TinyBERT-L2	4386561	0.5064	0.4935	0.4687	0.4238
cross-encoder/stsb-TinyBERT-L4	14351073	0.4964	0.4844	0.4628	0.4197
cross-encoder/ms-marco-TinyBERT-L4	14351073	0.4962	0.4790	0.4495	0.4067
cross-encoder/ms-marco-MiniLM-L2-v2	15616257	0.4930	0.4748	0.4479	0.4070
cross-encoder/ms-marco-MiniLM-L4-v2	19165185	0.4962	0.4810	0.4582	0.4179
hutuhehe/finretriever-cross-reranker	22713601	0.4916	0.4735	0.4435	0.3962
Adarsh921/cross-encoder	22713601	0.5043	0.4906	0.4672	0.4279
cross-encoder/ms-marco-MiniLM-L6-v2	22714113	0.5043	0.4906	0.4672	0.4279
denis-gordeev/reranker_dialog_items_crossencoder_rubert-tiny-turbo	29194081	0.5033	0.4391	0.3652	0.2623
jinaai/jina-reranker-v1-tiny-en	33046273	0.4961	0.4808	0.4513	0.4089
Pongsasit/mod-th-cross-encoder-minilm	33360385	0.5031	0.4813	0.4486	0.4012
cross-encoder/ms-marco-MiniLM-L12-v2	33360897	0.4950	0.4803	0.4588	0.4202
jinaai/jina-reranker-v1-turbo-en	37771777	0.4924	0.4747	0.4448	0.4017
cross-encoder/ms-marco-TinyBERT-L6	66956289	0.4940	0.4786	0.4495	0.4102
inthedarkness/klue-roberta-small-cross-encoder	68091649	0.5026	0.4379	0.3526	0.2471
mixedbread-ai/mxbai-rerank-xsmall-v1	70830337	0.4929	0.4685	0.4327	0.3773
PotatoOff/mxbai-rerank-xsmall-v1-safetensors	70830337	0.4929	0.4685	0.4327	0.3773
Pongsasit/mod-th-cross-encoder	82119169	0.4916	0.4657	0.4321	0.3833
cross-encoder/stsb-distilroberta-base	82119683	0.4936	0.4791	0.4565	0.4191
cross-encoder/qnli-distilroberta-base	82119683	0.5341	0.4848	0.4212	0.3472
cross-encoder/quora-distilroberta-base	82119683	0.4959	0.4789	0.4455	0.3873
Turbo-AI/jina-reranker-v0-base-multilingual__trimm_vocab	99074305	0.4955	0.4806	0.4573	0.4222
Turbo-AI/jina-reranker-v2-base-multilingual__trim_vocab	99074305	0.5063	0.4949	0.4760	0.4447
cross-encoder/msmarco-MiniLM-L6-en-de-v1	107007873	0.5092	0.4880	0.4493	0.3909
compnet-renard/bert-base-cased-NER-reranker	108312322	0.5323	0.4648	0.3852	0.2760
cross-encoder/qnli-electra-base	109483521	0.5051	0.4306	0.3483	0.2447
cross-encoder/ms-marco-electra-base	109483521	0.4958	0.4800	0.4493	0.4048
cross-encoder/mmarco-mMiniLMv2-L12-H384-v1	117641603	0.5296	0.5149	0.4892	0.4480
cross-encoder/msmarco-MiniLM-L12-en-de-v1	117654657	0.5106	0.4945	0.4685	0.4261
NetherlandsForensicInstitute/robbert-2023-dutch-base-cross-encoder	124442881	0.4974	0.4801	0.4528	0.4045
sdadas/polish-reranker-base-ranknet	124443649	0.5042	0.4892	0.4676	0.4266
sdadas/polish-reranker-base-mse	124443649	0.5150	0.4997	0.4737	0.4266
cross-encoder/quora-roberta-base	124646915	0.4942	0.4755	0.4459	0.3971
cross-encoder/stsb-roberta-base	124646915	0.4972	0.4842	0.4684	0.4351
NAMAA-Space/GATE-Reranker-V1	135194113	0.4983	0.4691	0.4179	0.3517
NAMAA-Space/Namaa-Reranker-v1	135194113	0.4974	0.4684	0.4138	0.3506
sdiazlor/modernbert-embed-base-crossencoder-human-rights	149605633	0.4848	0.4044	0.3124	0.1992
Alibaba-NLP/gte-reranker-modernbert-base	149605633	0.5038	0.4856	0.4569	0.4116
ibm-granite/granite-embedding-reranker-english-r2	149605633	0.4941	0.4820	0.4603	0.4283
Jsevisal/CrossEncoder-ModernBERT-base-qnli	149606402	0.5340	0.4818	0.4025	0.3081
malaysia-ai/malaysian-llm2vec-reranker-191M-16384	166160640	0.5283	0.4751	0.3912	0.2942
DiTy/cross-encoder-russian-msmarco	177854209	0.5117	0.4963	0.4650	0.4132
mixedbread-ai/mxbai-rerank-base-v1	184422913	0.4983	0.4807	0.4532	0.4042
jinaai/jina-reranker-v2-base-multilingual	278437633	0.4965	0.4818	0.4623	0.4310
Alibaba-NLP/gte-multilingual-reranker-base	305959681	0.4998	0.4792	0.4588	0.4306
ByteDance/ListConRanker	325522432	0.4957	0.4796	0.4556	0.3970
cross-encoder/quora-roberta-large	355361283	0.4967	0.4826	0.4557	0.4122
cross-encoder/stsb-roberta-large	355361283	0.4965	0.4841	0.4671	0.4370
qilowoq/bge-reranker-v2-m3-en-ru	374930433	0.4920	0.4684	0.4387	0.4002
sdadas/polish-reranker-large-ranknet	434962433	0.5006	0.4882	0.4650	0.4215
radlab/polish-cross-encoder	434962433	0.4947	0.4767	0.4491	0.4040
sdadas/polish-reranker-roberta-v2	434962433	0.5008	0.4908	0.4700	0.4332
sdadas/polish-reranker-large-mse	434962433	0.5148	0.5021	0.4750	0.4314
mixedbread-ai/mxbai-rerank-large-v1	435062785	0.5070	0.4848	0.4596	0.4209
GbrlOl/finetune-mxbai-cross-encoder-geotechnical-test-v5	435062785	0.5043	0.4827	0.4530	0.4073
vicky4s4s/embedding-v1	435062785	0.5070	0.4848	0.4596	0.4209
sdadas/polish-reranker-roberta-v3	442891265	0.5052	0.4948	0.4736	0.4366
michaelfeil/mxbai-rerank-base-v2-seq	494034560	0.5220	0.4756	0.3943	0.2982
upskyy/ko-reranker	559891457	0.4943	0.4756	0.4479	0.4156
netandrus/bge-reranker-v2-m3	567755777	0.4922	0.4676	0.4379	0.4003
NAMAA-Space/Namaa-ARA-Reranker-V1	567755777	0.4871	0.4474	0.4004	0.3435
sdadas/polish-reranker-bge-v2	567755777	0.4922	0.4683	0.4414	0.4059
upskyy/ko-reranker-8k	567755777	0.4915	0.4715	0.4437	0.4072
Omartificial-Intelligence-Space/ARA-Reranker-V1	567755777	0.4871	0.4474	0.4004	0.3435
kamilkaczmarek97/polish-reranker-prod	567755777	0.4922	0.4683	0.4414	0.4059
nooop9527/Qwen3-Reranker-0.6B-seq-cls-STv6	595777536	0.5190	0.4543	0.3628	0.2667
XingTuLab/BinSeek-Reranker	595777536	0.5083	0.4542	0.3854	0.2943
tomaarsen/Qwen3-Reranker-0.6B-seq-cls	595777536	0.5190	0.4543	0.3628	0.2667
openbmb/MiniCPM-Reranker-Light	1360247808	0.5008	0.4695	0.4198	0.3392
AhmedMostafa/bge-reranker-v2-gemma-saudi-achi10	2506176512	0.5198	0.4497	0.3583	0.2607
tomaarsen/Qwen3-Reranker-4B-seq-cls	4021787136	0.5109	0.4453	0.4368	0.3607

Tabla A.3: Resultados completos de los modelos de reranking evaluados sobre la métrica MAP para distintos órdenes de reordenación.

Model Name	k=5	k=10	k=15	k=20	k=25
cross-encoder/qnli-distilroberta-base	0.537850	0.534084	0.517852	0.499150	0.484769
Jsevisal/CrossEncoder-ModernBERT-base-qnli	0.541862	0.533972	0.515450	0.496327	0.481821
compnet-renard/bert-base-cased-NER-reranker	0.539573	0.532343	0.505345	0.484331	0.464817
cross-encoder/mmarco-mMiniLMv2-L12-H384-v1	0.529290	0.529559	0.521539	0.518483	0.514911
malaysia-ai/malaysian-llm2vec-reranker-191M-16384	0.537819	0.528334	0.509493	0.490568	0.475086
michaelfeil/mxbai-rerank-base-v2-seq	0.531293	0.521993	0.505255	0.488043	0.475593
AhmedMostafa/bge-reranker-v2-gemma-saudi-achi10	0.534460	0.519805	0.494083	0.468784	0.449699
nooooo9527/Qwen3-Reranker-0.6B-seq-cls-STv6	0.522598	0.519043	0.495333	0.473498	0.454282
tomaarsen/Qwen3-Reranker-0.6B-seq-cls	0.522598	0.519043	0.495333	0.473498	0.454282
sdadas/polish-reranker-base-mse	0.517989	0.515049	0.509071	0.503298	0.499746

Tabla A.4: Resultados completos de los 10 mejores modelos de reranking evaluados sobre la métrica **MAP** para distintos órdenes de reordenación.

#	Participant	Avg.MAP(en,es,de)	MAP(en-en)	MAP(es-es)	MAP(de-de)	MAP(zh-zh)
1	ranabarakat	0.53	0.559	0.527	0.516	0.508
2	omokhtar	0.53	0.554	0.522	0.515	0.507
3	ranabarakat	0.53	0.554	0.522	0.515	0.507
4	ranabarakat	0.53	0.553	0.521	0.515	0.506
5	omokhtar	0.52	0.542	0.516	0.503	0.505
6	Propuesta	0.52	0.551	0.497	0.508	0.502
7	jensjoris	0.52	0.533	0.519	0.500	0.510
8	pjmathematician	0.52	0.563	0.507	0.476	0.516
9	NLPnorth	0.49	0.537	0.496	0.442	0.495
10	NLPnorth	0.48	0.511	0.446	0.484	0.477
11	pjmathematician	0.48	0.496	0.479	0.458	0.427
12	pjmathematician	0.48	0.520	0.462	0.449	0.447
13	NLPnorth	0.47	0.489	0.467	0.466	0.487
14	NLPnorth	0.47	0.509	0.471	0.424	0.427
15	akacha	0.46	0.523	0.466	0.404	0.497
16	phanduchung03	0.46	0.477	0.439	0.464	0.473
17	napatnick	0.45	0.463	0.438	0.445	0.451
18	team_scalar	0.45	0.473	0.438	0.427	n/a
19	hallucinators	0.44	0.469	0.445	0.417	0.469
20	NLPnorth	0.44	0.490	0.421	0.406	0.444
21	napatnick	0.42	0.443	0.413	0.418	0.436
22	omokhtar	0.42	0.468	0.421	0.377	0.251
23	napatnick	0.42	0.430	0.414	0.423	0.434
24	srtej	0.42	0.479	0.420	0.360	0.415
25	srtej	0.42	0.479	0.420	0.360	0.350
26	udii-upm	0.41	0.448	0.415	0.377	0.451
27	pjmathematician	0.41	0.508	0.387	0.340	0.142
28	pjmathematician	0.41	0.441	0.398	0.380	0.448
29	adambrikman	0.40	0.440	0.402	0.355	0.421
30	srtej	0.39	0.478	0.352	0.345	0.433
31	Beamery Edge	0.37	0.354	0.372	0.373	0.367
32	melissamoreno	0.36	0.408	0.348	0.324	n/a
33	adambrikman	0.36	0.408	0.348	0.324	0.380
34	TalentCLEF	0.36	0.408	0.348	0.324	0.380
35	napatnick	0.36	0.408	0.348	0.324	0.380
36	VerbaNex AI	0.36	0.386	0.354	0.338	n/a
37	ayeshasaeed	0.35	0.355	0.360	0.347	0.412
38	srtej	0.18	0.188	0.188	0.177	0.170
39	srtej	0.18	0.194	0.184	0.172	0.168
40	Ixa	0.18	0.199	0.173	0.169	n/a
41	Ixa	0.18	0.200	0.166	0.168	n/a
42	Ixa	0.15	0.159	0.150	0.150	n/a
43	Ixa	0.14	0.199	0.122	0.110	n/a
44	Ixa	0.14	0.200	0.115	0.106	n/a
45	gabrielrsilva	0.08	0.125	0.078	0.037	n/a
46	adambrikman	0.00	0.000	0.000	0.000	0.000
47	adambrikman	0.00	0.000	0.000	0.000	0.000
48	adambrikman	0.00	0.000	0.000	0.000	0.000
49	adambrikman	0.00	0.000	0.000	0.000	0.000

Tabla A.5: Resultados **MAP** por participante, ordenados por la media de los resultados en los idiomas inglés, español y alemán.

To-do list

- 26, Debo incluir aquí el fundamento teórico y estrategia de selección?
Si hay tiempo, intentar evaluar los casos crosslingues y mostrar los resultados aquí, para analizar mejor la generalización.
- 40, A lo mejor se puede plantear como siguiente paso la participación en TalentCLEF2026, ahora en curso, para ver cómo de extrapolable es la arquitectura planteada.
- 53, Si hay tiempo, intentar formatear estas tablas como longtable, para poder mostrar todos los resultados.
- 65,