
Trabajo Fin de Máster: Title!!!



Trabajo Fin de Máster

David García Curbelo

Trabajo de investigación para el
Máster en Lenguajes y Sistemas Informáticos
Universidad Nacional de Educación a Distancia

Dirigido por la

Prof. Dra. D. Laura Plaza Morales

23 de diciembre de 2025

Agradecimientos

Equipo de TalentCLEF por facilitar el acceso a los datos y el desarrollo de una plataforma para la evaluación a posteriori de la tarea.

Resumen

Resumen.

Abstract

Resumen en inglés.

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Definición del problema	2
1.3. Propuesta y objetivos	4
1.4. Estructura del documento	5
2. Estado del arte	7
2.1. Fundamentos y Evolución de la Recuperación de Información	7
2.1.1. Modelos Clásicos: Del Determinismo a la Similitud Estadística	7
2.1.2. El Papel del Aprendizaje Automático	8
2.1.3. Recuperación Neuronal y Representaciones Densas . .	8
2.1.4. Estrategias de Refinamiento	8
2.1.5. El Paradigma de las Arquitecturas Híbridas	9
2.2. Historia y Evolución del Emparejamiento de Titulaciones . .	10
2.2.1. Métodos tradicionales y enfoques económicos	10
2.2.2. Transición hacia técnicas de aprendizaje automático .	11
2.2.3. Del problema de clasificación a la tarea de <i>matching</i> en entornos reales	11
2.3. Enfoques abordados en TalentCLEF	12
2.3.1. Estrategias Dominantes	12
2.3.2. El Rol Crítico de Recursos Externos	13
2.3.3. Gestión de Escenarios Multilingües y Cross-Lingües .	14
2.3.4. Consideraciones Específicas: Chino y Sesgo de Género	14
2.4. Transformers para Semejanza Semántica	15
2.4.1. Definición y características	15
2.4.2. Su utilización en la tarea	16

2.4.3. Técnicas de entrenamiento específicas para mejorar la calidad del ranking	17
3. Arquitectura del sistema	19
3.1. Arquitectura general	19
3.2. Módulos del sistema	19
3.2.1. Retrieval	20
3.2.2. Rank Fusion	21
3.2.3. Re-ranking	21
3.3. Tecnologías y Estrategias de Aprendizaje	22
3.3.1. Librerías y Entorno	22
3.3.2. Funciones de Pérdida (Loss Functions)	22
3.3.3. Función de evaluación	22
3.4. Flujo de Trabajo Experimental	23
3.4.1. Fase 1: Zero-shot	23
3.4.2. Fase 2: Entrenamiento de Bi-encoders	23
3.4.3. Fase 3: Optimización de la Fusión	24
3.4.4. Fase 4: Implementación del Re-ranking	24
4. Evaluación	25
4.1. Metodología de evaluación	25
4.2. Métricas de evaluación	25
4.3. Colecciones de evaluación	25
4.4. Resultados	25
5. Discusión	27
5.1. Ejemplo sección	27
5.1.1. Ejemplo subsección	27
6. Conclusiones y trabajo futuro	29
6.1. Conclusiones	29
6.2. Trabajo futuro	29
Bibliografía	31
Glosario	38

Índice de Figuras

3.1. Diagrama de la arquitectura del sistema propuesto: Retrieval, Fusión y Re-ranking.	20
--	----

Índice de Tablas

Capítulo 1

Introducción

1.1. Motivación

El panorama del mercado laboral actual está experimentando una gran transformación impulsada principalmente por la rápida evolución tecnológica y la incorporación de la [Inteligencia Artificial \(AI\)](#) en nuestras vidas. Estudios recientes indicaban que para finales de 2025, aproximadamente 90 millones de puestos de trabajo habrán sido automatizados, y una cantidad similar de ocupaciones que no existían a principios de siglo aparecerán en escena ([Maslej et al., 2025](#)). Esta dinámica de cambio constante, lejos de ser un fenómeno aislado, es consecuencia directa del desarrollo tecnológico, el cual no solo ha automatizado tareas rutinarias y creado roles completamente nuevos, sino que también ha redefinido la naturaleza misma de los puestos de trabajo existentes.

En este contexto de transición, la adaptabilidad se convierte en un factor clave tanto para los profesionales, que enfrentan una incertidumbre creciente sobre las competencias que serán relevantes a corto plazo, como para las organizaciones, que se ven obligadas a identificar talento con estas capacidades emergentes ([Ordóñez de Pablos y Lytras, 2008](#)). Esta necesidad ha fomentado la adopción de tecnologías de [Procesamiento del Lenguaje Natural \(NLP\)](#) en la [Gestión del Capital Humano \(HCM\)](#), con el objetivo de optimizar procesos de adquisición de talento, crear programas de formación personalizados y permitir una planificación estratégica basada en competencias.

Sin embargo, el desarrollo de estos sistemas inteligentes se enfrenta a importantes desafíos que limitan su eficacia, equidad y generalización. Es

precisamente en este punto donde se sitúa la motivación principal de este trabajo, centrado en la Tarea A del TalentCLEF 2025, la cual pretende abordar el problema del emparejamiento de titulaciones profesionales (Gasco et al., 2025a). Además, si bien el desafío original presenta un escenario multilingüe, existe una necesidad palpable de desarrollar y evaluar soluciones específicamente optimizadas para el español, un idioma con una gran relevancia geográfica y demográfica a nivel global que, no obstante, a menudo no recibe una atención adecuada en el desarrollo de modelos.

Muchos de los modelos multilingües de propósito general, aunque incluyen el español en su entrenamiento, suelen estar optimizados primordialmente para el inglés¹, lo que suele resultar en un rendimiento menor para otras lenguas menos predominantes. Este proyecto se centra en una aproximación especializada, que contemple las particularidades del español y busque mejorar su rendimiento en la tarea en cuestión. Sin embargo, la complejidad añadida de los marcadores de género en los títulos profesionales representa un desafío técnico particular que, aunque no será abordado en profundidad en este trabajo, sí se estudiarán las propuestas existentes por parte del resto de participantes de la tarea.

Además, la disponibilidad del benchmark público de TalentCLEF, que incluye un corpus en español anotado a partir de datos reales (Gasco et al., 2025b), ofrece una oportunidad única para investigar este problema de forma rigurosa y reproducible. Así, este trabajo no solo busca contribuir al avance de la tecnología en el ámbito de la HCM, sino también ofrecer soluciones prácticas que puedan ser implementadas en entornos reales, facilitando así la adaptación de profesionales y organizaciones a un mercado laboral en constante evolución.

Me suena rara la conexión entre el benchmark y la conclusión de la sección. Tengo que pulirla.

1.2. Definición del problema

Este trabajo se centra en la resolución de la primera tarea de la campaña de evaluación TalentCLEF 2025. TalentCLEF es la primera campaña de evaluación enfocada en la gestión de titulaciones profesionales y habilidades (*Skill and Job Title Intelligence*), diseñada para abordar la escasez de benchmarks

¹Cabe destacar que, en cuanto a presencia en la web, el inglés es el que más presencia tiene, con un 49 %, y el segundo es el español, con un 6 % (W3Techs, 2023). Como consecuencia, la mayoría de los modelos de NLP están optimizados para el inglés (Guo et al., 2025).

públicos y abiertos en el dominio de la HCM (Gasco et al., 2024).

El problema específico que se aborda es la **Tarea A: Emparejamiento Multilingüe de Titulaciones Profesionales** (Multilingual Job Title Matching). El objetivo de esta tarea es desarrollar sistemas que, dada una titulación profesional (*query*), identifiquen y generen una lista ordenada (*ranking*) de las titulaciones más similares extraídas de una base de conocimiento (*corpus elements*).

El desafío propuesto por TalentCLEF 2025 es multilingüe y cubre cuatro idiomas: inglés, español, alemán y chino, donde los conjuntos de datos proporcionados se componen de tres particiones: entrenamiento, validación y test, con orígenes marcadamente distintos. Los conjuntos de validación y testeo de la tarea se construyeron a partir de datos reales de solicitudes de empleo, que fueron cuidadosamente anonimizadas y anotadas manualmente. Las *queries* de la tarea se definen como los títulos de las ofertas de trabajo, mientras que los *corpus elements* a clasificar se han extraído de los títulos de los últimos puestos de trabajo de los candidatos que aplicaron a dichas ofertas. Por otro lado, el conjunto de entrenamiento (disponible únicamente para inglés, español y alemán) se generó de forma automática extrayendo pares de titulaciones profesionales relacionadas de la taxonomía ESCO (Habilidades, Competencias, Cualificaciones y Ocupaciones Europeas).

La evaluación oficial de la **Tarea A** se estructura en cuatro escenarios distintos:

- Una evaluación monolingüe para inglés, español y alemán.
- Una evaluación multilingüe, con consultas en inglés contra corpus en español y alemán.
- Una sub-tarea voluntaria para el idioma chino, para el cual no se proporcionaron datos de entrenamiento.
- Una evaluación específica del sesgo de género para español y alemán, también voluntaria.

La métrica de evaluación principal para la clasificación es la **Precisión Media Promedio (MAP)**, mientras que para la evaluación del sesgo se utiliza la **Superposición Sesgada por Rango (RBO)**.

Si bien el desafío abarca múltiples idiomas, este trabajo se enfoca particularmente en el desarrollo y evaluación de soluciones optimizadas para el

Incluir aquí información sobre Codabench y los métodos oficiales de evaluación

español, aprovechando la disponibilidad del corpus anotado y el benchmark público que ofrece la competición.

1.3. Propuesta y objetivos

Este trabajo está centrado en el desarrollo y evaluación de un sistema optimizado para el emparejamiento de titulaciones profesionales en español dentro del marco establecido por la [Tarea A](#) de TalentCLEF 2025. La propuesta principal consiste en la búsqueda, adaptación y evaluación exhaustiva de modelos transformer que maximicen el rendimiento en la tarea de recuperación de información definida, con especial énfasis en el escenario monolingüe del español.

Los objetivos específicos que se persiguen son los siguientes:

- **Análisis del estado del arte:** Investigar en profundidad las aproximaciones y arquitecturas que han demostrado mayor efectividad en tareas de similitud semántica y recuperación de información multilingüe, prestando especial atención a los modelos que mostraron mejores resultados en la competición original.
- **Selección y adaptación de modelos:** Identificar y seleccionar modelos transformer pre-entrenados multilingües con demostrada eficacia en español, para su posterior adaptación mediante técnicas de fine-tuning específicas para la tarea de ranking definida.
- **Diseño de estrategias de entrenamiento:** Implementar y comparar diferentes estrategias de aprendizaje, con especial atención a las técnicas de aprendizaje contrastivo, que ha demostrado ser particularmente efectivo en tareas de similitud semántica según los resultados reportados en TalentCLEF 2025.
- **Evaluación exhaustiva:** Realizar una evaluación rigurosa tanto en el conjunto de desarrollo local como en la plataforma Codabench, empleando la métrica MAP como indicador principal de rendimiento, y estableciendo comparativas con los sistemas participantes en la competición original.
- **Análisis de especialización para español:** Evaluar específicamente la efectividad de las soluciones desarrolladas en el contexto del idio-

ma español, analizando si un enfoque especializado permite superar el rendimiento de aproximaciones multilingües generalistas.

Resumen de resultados.

1.4. Estructura del documento

Capítulo 1. Introducción. Este capítulo introduce los principales motivos que han llevado a la realización de este trabajo, así como la problemática y los objetivos planteados para abordar el problema en cuestión.

Capítulo 2. Estado del arte. Este capítulo describe en mayor detalle la disciplina que nos ocupa, presentando su origen y su historia hasta el presente. Se muestran las técnicas actuales más utilizadas para resolver las tareas más relevantes del tema abordado.

Capítulo 3. Sistema/Método/Caso de Estudio propuesto. —

Capítulo 4. Evaluación. —

Capítulo 5. Discusión. —

Capítulo 6. Conclusiones y trabajo futuro. —

Capítulo 2

Estado del arte

2.1. Fundamentos y Evolución de la Recuperación de Información

La capacidad de identificar y organizar información relevante dentro de grandes volúmenes de datos ha sido uno de los pilares fundamentales de las ciencias de la computación. Antes de abordar el estudio específico del emparejamiento de ocupaciones, es imperativo analizar la evolución de la [Recuperación de Información \(IR\)](#) y cómo los paradigmas de ordenación han transitado desde reglas deterministas hacia arquitecturas híbridas de alta complejidad.

2.1.1. Modelos Clásicos: Del Determinismo a la Similitud Estadística

En sus orígenes, los sistemas de [IR](#) operaban bajo modelos booleanos que buscaban la coincidencia exacta entre términos. En este esquema, la recuperación se limitaba a una lógica binaria donde un documento era relevante únicamente si contenía los términos precisos de la consulta. Si bien este enfoque garantizaba precisión terminológica, carecía de una noción de relevancia gradual, lo que resultaba insuficiente para gestionar la ambigüedad y sinonimia del lenguaje natural.

La transición hacia el Modelo de Espacio Vectorial y el uso de métricas de ponderación como [Frecuencia de Término-Frecuencia Inversa de Documento \(TF-IDF\)](#) supuso un cambio de paradigma. Por primera vez, los elementos no solo se recuperaban, sino que se ordenaban mediante el cálculo de medidas

de similitud (Salton, Wong, y Yang, 1975). Posteriormente, el desarrollo de modelos probabilísticos como Mejor Coincidencia 25 (BM25) perfeccionó esta aproximación, estableciendo un estándar de robustez léxica que sigue vigente hoy en día (Robertson, Zaragoza, y others, 2009). No obstante, estos métodos tradicionales se encuentran limitados por el denominado *vocabulary mismatch*, al ser incapaces de interpretar el contexto o la semántica profunda más allá de la presencia explícita de términos.

2.1.2. El Papel del Aprendizaje Automático

La llegada del Aprendizaje Automático (ML) permitió que la disciplina evolucionara hacia el Aprendizaje para Ordenación (LTR) definido ampliamente en (Liu y others, 2009). En lugar de depender de funciones de relevancia estáticas, los sistemas comienzan a emplear modelos supervisados capaces de combinar múltiples señales (características léxicas, metadatos, popularidad, etc.) para optimizar funciones de pérdida específicas.

Este periodo consolidó aproximaciones fundamentales para la ordenación de resultados: los enfoques *pointwise* (evaluación individual), *pairwise* (comparación de pares) y *listwise* (optimización de la lista completa). Aunque el LTR mejoró significativamente la precisión, su dependencia de un ajuste de características manual limitaba su capacidad de generalización en dominios con alta variabilidad lingüística.

2.1.3. Recuperación Neuronal y Representaciones Densas

La irrupción del Aprendizaje Profundo (DL) y los modelos basados en *Transformers* han redefinido la IR contemporánea. El cambio fundamental reside en el paso de la recuperación dispersa, basada en palabras clave, a la recuperación densa, basada en embeddings (Karpukhin et al., 2020). Mediante el uso de modelos de lenguaje, es posible proyectar consultas y documentos en un espacio vectorial continuo donde la cercanía geométrica representa similitud semántica, permitiendo capturar conceptos incluso en ausencia de coincidencias léxicas exactas.

2.1.4. Estrategias de Refinamiento

A medida que los corpus documentales han ganado en escala, ha surgido una tensión técnica entre dos objetivos contrapuestos: la exhaustividad y la

precisión. La imposibilidad de aplicar modelos de máxima complejidad sobre millones de documentos en tiempo real ha motivado la aparición de estrategias de modificación del ranking original, con la intención de optimizar la calidad de los resultados presentados.

Re-ranking: Precisión mediante Interacción Profunda

La técnica de *re-ranking* surge de la necesidad de aplicar modelos de alta intensidad computacional sobre un subconjunto reducido de candidatos. Para ello, tras una recuperación rápida basada en métodos léxicos o vectoriales aproximados, se selecciona una “ventana” de resultados para ser analizada por un modelo más costoso. Esta fase permite evaluar interacciones semánticas finas que son computacionalmente inviables en la fase de búsqueda masiva, garantizando que los elementos en las posiciones superiores sean los de mayor relevancia real. Un ejemplo claro es el mostrado en (Nogueira y Cho, 2019), donde demuestran que el uso de cross-encoders en la etapa de re-ranking mejora sustancialmente la calidad del ranking final.

Fusión de Rankings: Robustez y Diversidad de Señales

Paralelamente, la Fusión de Rankings (*Rank Fusion*) aborda la varianza intrínseca entre diferentes modelos. La evidencia en la literatura científica demuestra que distintos algoritmos de recuperación suelen identificar diferentes subconjuntos de elementos relevantes. La motivación de la fusión reside en el principio de robustez: combinar múltiples listas de resultados permite mitigar los sesgos de modelos individuales. Algoritmos como Fusión Recíproca de Rangos (RRF) desarrollado en (Cormack, Clarke, y Buettcher, 2009) se han convertido en estándares debido a su capacidad para integrar fuentes heterogéneas basándose en la posición relativa, mejorando la estabilidad del sistema sin necesidad de normalizar puntuaciones dispares.

2.1.5. El Paradigma de las Arquitecturas Híbridas

En la actualidad, el estado del arte no se define por el uso de una única técnica, sino por la integración de múltiples capas de procesamiento. La transición hacia sistemas que combinan la recuperación inicial con fases posteriores de refinamiento y consolidación de resultados ha demostrado

ser el enfoque más eficaz¹.

Históricamente, se ha evidenciado que la unión de diversas metodologías genera sistemas significativamente más estables y precisos. Este marco de trabajo híbrido constituye el fundamento sobre el que se desarrollan las soluciones modernas de alta precisión, permitiendo una adaptación flexible a problemas de dominio específico como el que se aborda en este trabajo.

2.2. Historia y Evolución del Emparejamiento de Titulaciones

Dentro de este marco, el [Emparejamiento de Titulaciones Profesionales \(JTM\)](#) se presenta como una aplicación especializada de estos principios dentro del ámbito de la gestión del talento y la [HCM](#). En su forma básica, el problema consiste en determinar la equivalencia o el grado de compatibilidad entre títulos de puestos de trabajo, a pesar de la enorme variabilidad léxica, la polisemia y las convenciones internas de las organizaciones. Esta variabilidad hace que una misma ocupación pueda aparecer bajo campos muy distintos y, a su vez, que títulos idénticos traduzcan responsabilidades distintas según el contexto organizativo, sectorial o geográfico.

2.2.1. Métodos tradicionales y enfoques económicos

Históricamente, las investigaciones sobre [JTM](#) han adoptado perspectivas tanto técnicas como económicas. En el campo de la economía laboral española, por ejemplo, existe una persistencia en el proceso de emparejamiento que muestra cómo las fricciones de mercado y la heterogeneidad ocupacional condicionan los resultados del matching laboral ([De Toledo, Núñez, y Usabiaga, 2008](#)). Estos estudios clásicos proporcionan un marco para interpretar por qué la normalización de titulaciones no es sólo un problema lingüístico, sino también institucional y estructural: la misma denominación puede implicar distintas funciones y niveles de especialización en diferentes segmentos del mercado laboral ([de Toledo Saavedra, Hernández, y Ibáñez, 2017](#)).

Desde el punto de vista computacional, los primeros abordajes aplicados al dominio laboral siguieron estructuras generales de recuperación de infor-

¹Este hecho se ve reflejado en las propuestas de solución planteadas por los distintos participantes en la competición de TalentCLEF, como se detallará más en detalle en la sección [2.3](#).

mación y clasificación de texto, basadas principalmente en normalización de cadenas y reglas heurísticas. Aunque estas técnicas (y los sistemas basados en reglas) pueden ser útiles en entornos controlados, su coste de mantenimiento y su fragilidad frente a sinónimos, abreviaturas y errores hacen que resulten insuficientes para datos del mundo real (Jirjees et al., 2025).

2.2.2. Transición hacia técnicas de aprendizaje automático

La llegada y consolidación del ML transformó la investigación y la práctica en JTM. Durante los últimos años, la literatura documenta un amplio abanico de técnicas: desde modelos supervisados clásicos hasta arquitecturas neuronales que aprenden representaciones textuales más ricas y robustas frente al ruido y la variabilidad (Jirjees et al., 2025). Han comenzado a surgir soluciones no supervisadas y semi-supervisadas para detectar patrones, agrupar titulaciones y reducir la dependencia de grandes volúmenes de anotación manual (Mamani Rodriguez, 2022b; Mamani Rodriguez, 2022a).

Específicamente en entornos hispanohablantes, trabajos recientes han explorado procesos de clustering y pipelines de ML no supervisado para identificar la demanda social de puestos y determinar similitudes entre títulos profesionales de sectores específicos. Estas contribuciones muestran que, aunque las técnicas de clustering capturan agrupaciones útiles, su sensibilidad a la representación textual y su capacidad de generalización condiciona fuertemente la calidad del emparejamiento.

En cuanto a los análisis bibliométricos sobre investigación en esta tarea, estos revelan un crecimiento sostenido del interés científico en la intersección entre AI y reclutamiento por parte de la HCM, con aplicaciones que abarcan desde selección automatizada hasta orientación profesional y análisis de brechas de competencias (Rojas-Galeano, Posada, y Ordoñez, 2022). Dichos trabajos también evidencian que, aunque existen esfuerzos notables en sectores como la salud o la tecnología, persiste una desproporción entre la disponibilidad de recursos en inglés y en otras lenguas, lo que limita la comparabilidad y la replicabilidad de soluciones en contextos locales.

2.2.3. Del problema de clasificación a la tarea de *matching* en entornos reales

Una distinción clave que ha emergido en la literatura reciente es la diferencia entre (i) la clasificación contra una taxonomía canónica y (ii) el

matching o ranking entre pares de textos libres (oferta vs. perfil solicitante). Mientras la clasificación se beneficia de puntos de referencia estables, el matching real debe lidiar con ruido, abreviaturas, títulos internos y asimetrías informativas que no aparecen en las taxonomías que se encuentran disponibles. En consecuencia, las soluciones más robustas tienden a combinar representaciones semánticas aprendidas con estrategias de evaluación y depuración específicas del dominio, integrando tanto medidas globales de similitud como señales estructurales extraídas del mercado laboral (Gasco et al., 2025a).

2.3. Enfoques abordados en TalentCLEF

La Tarea A de TalentCLEF 2025, centrada en el Multilingual JTM, atrajo una variedad de enfoques que buscaron resolver el desafío de alinear semánticamente títulos de trabajo en inglés, español, alemán y, opcionalmente, chino. El análisis de las soluciones presentadas por los participantes revela una fuerte tendencia hacia el uso de modelos de lenguaje basados en Transformers, aunque las estrategias de implementación, entrenamiento y uso de recursos externos variaron significativamente.

2.3.1. Estrategias Dominantes

La mayoría de las soluciones giraron en torno a modelos de *Sentence Transformers* multilingües preentrenados, como MPNet (Brikman, Sana, y Ruegger, 2025), JobBERT (Decorte, De Lange, y Van Hautte, 2025) o variantes de SBERT (Nizami et al., 2025; Bhangale, Gabhane, y Kumar, 2025). El objetivo común fue la generación de embeddings en un espacio semántico compartido, donde títulos de trabajo equivalentes en diferentes idiomas tuvieran una alta similitud².

Un hallazgo clave, destacado por el equipo NLPnorth (Zhang y van der Goot, 2025), fue la comparación directa de tres métodos de ajuste fino:

- **Discriminativo (Clasificación):** Reformular la tarea como una clasificación binaria (si dos títulos coinciden o no), generando para ello pares negativos.

²La similitud medida en los espacios vectoriales generados fue la similitud coseno, elegida de forma unánime entre todas las propuestas de solución al problema.

- **Contrastivo:** Entrenar el modelo para acercar las representaciones de pares positivos y alejar las de pares negativos.
- **Basado en Prompts:** Utilizar LLMs para evaluar la similitud.

Los resultados de NLPnorth sugirieron que el aprendizaje contrastivo fue su estrategia más efectiva.

Otros equipos, como UDII-UPM (Rodríguez-Vidal et al., 2025), exploraron el rendimiento de modelos preentrenados sin ajuste fino, aplicando un enfoque *zero-shot*, proponiendo una fusión de representaciones semánticas de diferentes modelos para robustecer el matching.

Por otro lado, el equipo Pjmathematician utilizó embeddings GIST e incorporó datos generados mediante LLMs (Vachharajani, 2025).

2.3.2. El Rol Crítico de Recursos Externos

Uso de ESCO

La taxonomía ESCO no solo sirvió como base de conocimiento, sino también como fuente de datos de entrenamiento. El equipo VerbaNex (Novoa et al., 2025) utilizó las relaciones jerárquicas de ESCO para generar automáticamente pares adicionales positivos y negativos, ajustando su modelo para crear un espacio semántico alineado con la taxonomía. De manera similar, NLPnorth (Zhang y van der Goot, 2025) también extrajo datos adicionales de ESCO para su entrenamiento³.

Otros equipos adoptaron un enfoque híbrido. El sistema de dos etapas de TechWolf (Rodríguez, Perez-de Viñaspre, y Perez, 2025) utilizó tanto ESCO como ISCO (Clasificación Internacional Uniforme de Ocupaciones) en un primer sistema de recuperación de candidatos, para luego refinar la lista de candidatos mediante un LLM en una etapa de *re-ranking*.

Uso de LLMs

Además del *re-ranking* mencionado, varios equipos utilizaron algún LLM para la generación de datos. El equipo NT (Nga, Tuyen, y Van Thin, 2025)

³Cabe destacar que el conjunto de datos de entrenamiento ya habían sido generado por la organización y se encontraba a disposición de los participantes. Sin embargo, conociendo la procedencia y método de producción de este set de datos, algunos participantes decidieron aumentar dicho set para una mejor generalización de los modelos en el aprendizaje.

propuso un sistema basado en la generación de descripciones de trabajo mediante LLMs, seguida de un sistema de IR. Sin embargo, su rendimiento fue bastante limitado en comparación con otros enfoques basados en Transformers.

2.3.3. Gestión de Escenarios Multilingües y Cross-Lingües

El desafío principal de la tarea era la correcta alineación semántica entre idiomas.

- **Espacio Semántico Compartido:** La estrategia dominante fue el uso de codificadores multilingües (SBERT, MPNet) ajustados para proyectar todos los idiomas en un único espacio vectorial (Brikman, Sana, y Ruegger, 2025; Nizami et al., 2025; Novoa et al., 2025).
- **Inglés como Lengua Pivote:** El equipo de TechWolf (Rodriguez, Perez-de Viñaspre, y Perez, 2025) investigó explícitamente el uso del inglés como idioma pivote, traduciendo los títulos de otros idiomas al inglés antes de la comparación, una estrategia que demostró mejorar el rendimiento en algunos escenarios cross-lingües.
- **Recuperación Híbrida:** El equipo AlexU-NLP (Barakat et al., 2025) propuso un sistema de recuperación híbrido con un enfoque de *curriculum learning*, diseñado para gestionar la dificultad progresiva de los pares multilingües.

2.3.4. Consideraciones Específicas: Chino y Sesgo de Género

Aunque la mayoría de los participantes se centraron en inglés, español y alemán, la tarea incluía dos consideraciones importantes: el idioma chino y la evaluación del sesgo de género.

El Caso del Chino

El idioma chino (en pares *zh-zh* y *en-zh*) fue una subtask voluntaria dentro de la Tarea A. Sin embargo, la mayoría de los trabajos centraron sus esfuerzos en los idiomas europeos, debido a que el chino no se encontraba dentro de los datos de entrenamiento, sino únicamente en validación y testeo. Este enfoque fue tomado por la organización con la intención de evaluar la capacidad multilingüe de las distintas propuestas.

Evaluación del Sesgo de Género

Una componente clave de la tarea fue la medición del sesgo de género. En idiomas como el español y el alemán, donde los títulos de trabajo pueden tener marcas explícitas de género, se evaluó cómo las distintas soluciones manejaban estas diferencias, para evaluar si los sistemas perpetuaban o mitigaban sesgos de género en sus predicciones. Los datos de la competición incluían anotaciones ocultas de género y expresiones con marcas de género para permitir este análisis. La organización proponía buscar un sistema que minimizara las diferencias de rendimiento entre títulos de trabajo asociados a diferentes grupos de género.

A pesar de que esta evaluación fue central, pocos trabajos de los participantes detallaron explícitamente las técnicas de mitigación del sesgo que aplicaron. La mayoría de los sistemas se centraron en la precisión del matching semántico. Los trabajos de NLPnorth y de Ixa evaluaron este tema con detenimiento, consiguiendo una puntuación perfecta en la métrica de [RBO](#).

2.4. Transformers para Semejanza Semántica

Los transformers han sido la palanca tecnológica dominante en las tareas de comprensión y comparación semántica de textos desde su aparición. En el contexto de la tarea, su adopción no sólo ha permitido avances significativos en calidad de ranking, sino que ha generado un conjunto diverso de arquitecturas y estrategias de uso que conviene desglosar.

2.4.1. Definición y características

Un transformer es una arquitectura de red neuronal basada principalmente en mecanismos de atención que procesan secuencias sin recurrir a operaciones recurrentes o convolucionales. La atención permite que cada posición de entrada sintetice información de todas las demás posiciones mediante pesos aprendidos; esto facilita la captura de relaciones de largo alcance, la paralelización durante el entrenamiento y la construcción de representaciones contextualizadas de tokens y oraciones ([Vaswani et al., 2017](#)). Aunque el diseño original incluye bloques de encoder y decoder, la práctica moderna para tareas de recuperación y matching usa variantes sólo-encoder

(para embeddings), encoder-decoder y modelos sólo-decoder (para [LLM](#)) según el uso concreto.

2.4.2. Su utilización en la tarea

En la práctica aparecen tres patrones arquitectónicos generales, con variantes muy interesantes:

Bi-encoders

Cada query se codifica por separado con el mismo encoder para producir vectores en un espacio semántico compartido, y usa la similitud entre vectores para ordenar candidatos. Este esquema es ideal cuando se requiere recuperar a escala, porque la indexación de vectores y la búsqueda aproximada permiten latencias bajas. Su principal fortaleza es la eficiencia en la fase de inferencia; su principal limitación es que la interacción entre consulta y candidato es sólo implícita en el espacio vectorial, por lo que puede fallar a la hora de resolver matices finos.

Cross-encoders

Un cross-encoder toma la pareja (**consulta**, **candidato**) y las procesa juntas, produciendo una puntuación que refleja la compatibilidad tras un proceso de atención en ambas direcciones. Proporciona decisiones más precisas porque permite interacciones finas entre las dos secuencias, capturando coincidencias léxicas localizadas, supresiones y dependencias sintácticas que un bi-encoder puede pasar por alto. Sin embargo, el coste computacional es mucho más alto. Con esta técnica no es viable aplicar cross-encoders exhaustivamente sobre grandes conjuntos sin una fase previa de filtrado. Por ello se emplean habitualmente como re-rankers sobre un conjunto reducido (top-k) obtenido con otros métodos menos costosos. La práctica de combinar un retrieval rápido y re-ranking posterior ha quedado consolidada como patrón de diseño en sistemas de [IR](#) modernos ([Inc., 2024](#); [Xu et al., 2025](#)).

Modelos autoregresivos

Los modelos autoregresivos se han usado de forma complementaria: para generar descripciones adicionales de un título, traducir o normalizar textos, crear negativos/positivos sintéticos, o para puntuar directamente parejas

mediante prompting. Ofrecen flexibilidad y poder de razonamiento, pero también son muy propensos a la generación de ruido. Requieren de un control cuidadoso y suelen tener costes computacionales y de infraestructura elevados.

2.4.3. Técnicas de entrenamiento específicas para mejorar la calidad del ranking

El rendimiento de los transformers depende tanto de la arquitectura como de la estrategia de entrenamiento y de la calidad de los datos usados. En la tarea se observan varias técnicas que marcan la diferencia:

- **Entrenamiento contrastivo:** las técnicas contrastivas, como por ejemplo [Estimación de Contraste de Ruido de Información \(InfoNCE\)](#), acercan los pares positivos de vectores y separan los negativos. Una selección inteligente de negativos mejora la discriminación del espacio semántico y reduce falsos positivos en los rankings. Técnicas recientes que centran su foco en la selección de negativos han mostrado ganancias notables en el fine-tuning de embeddings ([Solatorio, 2024](#)).
- **Variantes de las técnicas contrastivas:** existen algunas modificaciones, como focal-[InfoNCE](#), que tratan de penalizar más los errores en ejemplos difíciles y estabilizar el aprendizaje cuando existe un desbalance fuerte entre positivos y negativos. Con ello consiguen mejorar la capacidad de priorizar los verdaderos positivos en los primeros puestos del ranking ([Hou y Li, 2023](#)).
- **Curriculum learning:** comenzar con negativos fáciles y evolucionar hacia negativos más difíciles (o introducir negativos guiados por similitud léxica/semántica) puede estabilizar el entrenamiento y evitar que el modelo colapse ante una distribución “long-tail” de títulos.
- **Fine-tuning multilingüe:** ajustar modelos multilingües con datos balanceados por idioma puede ayudar a alinear representaciones cross-lingües y a reducir la fragmentación de la representación del embedding. Algunos métodos modernos de entrenamiento masivo multilingüe han demostrado que el aprendizaje dirigido para varios idiomas simultáneamente mejora la transferencia entre pares idiomáticos ([Mao, Chu, y Kurohashi, 2024](#)).

Capítulo 3

Arquitectura del sistema

3.1. Arquitectura general

El flujo de procesamiento de una query (título de una oferta de empleo) hasta la obtención del ranking final de candidatos se ha estructurado en tres etapas secuenciales:

1. **Retrieval:** Utilización de tres modelos bi-encoder independientes, a los que se les ha aplicado *fine-tuning* con los datos de entrenamiento para la tarea, proyectando tanto las consultas como los candidatos en un espacio vectorial común. Cada modelo genera un ranking preliminar de los candidatos más similares.
2. **Rank Fusion:** Agregación de los resultados de los tres modelos de recuperación mediante algoritmos de rank fusion, generando una lista unificada y más robusta que mitiga los sesgos individuales de cada modelo.
3. **Re-ranking:** Refinamiento de la lista fusionada mediante un modelo cross-encoder, que evalúa la interacción semántica profunda entre la consulta y los candidatos seleccionados para producir el ranking final.

La Figura 3.1 ilustra el flujo de datos a través de estos módulos.

3.2. Módulos del sistema

A continuación, se describen en detalle los componentes técnicos de cada una de las etapas mencionadas.




Figura 3.1: Diagrama de la arquitectura del sistema propuesto: Retrieval, Fusión y Re-ranking.

3.2.1. Retrieval

El objetivo de esta fase es reducir el sesgo que cada uno de los modelos por separado pueda tener para reducir la varianza en los resultados. Para ello, se emplean modelos *Sentence Transformers* bajo una red siamesa de modelos bi-encoders (Reimers y Gurevych, 2019).

Dada una consulta q y un candidato d , el bi-encoder procesa cada texto de forma independiente para generar sus representaciones vectoriales u y v . La similitud se calcula mediante la similitud coseno:

$$\text{sim}(q, d) = \cos(u, v) = \frac{u \cdot v}{\|u\| \|v\|} \quad (3.1)$$

Para aumentar la robustez del sistema, se entrenarán tres modelos distintos que aporten diversidad al conjunto. Esta búsqueda de modelos estará guiada por los resultados obtenidos sobre una evaluación en los datos de validación, que serán realizadas tanto antes del fine-tuning (zero-shot) como posterior al mismo. Los resultados obtenidos se ordenarán según la métrica MAP detallada en la sección 3.3.3.

La fuente principal de obtención de modelos será el repositorio de Hugging Face (huggingface,), priorizando aquellos que hayan demostrado buen rendimiento en tareas de recuperación de información multilingüe o en es-

pañol.

3.2.2. Rank Fusion

Dado que cada modelo bi-encoder puede destacar en diferentes tipos de consultas (e.g., uno maneja mejor anglicismos y otro mejor la terminología local), combinarlos se espera que mejore el rendimiento general. Se empleará el algoritmo **RRF** (Cormack, Clarke, y Buettcher, 2009) para fusionar los tres rankings individuales generados en la etapa de recuperación.

RRF asigna una puntuación a cada candidato del corpus c basándose en su posición en los rankings individuales, penalizando aquellos que aparecen en posiciones bajas y premiando el consenso entre modelos. La fórmula utilizada es la siguiente:

$$RRFscore(c \in C) = \sum_{r \in R} \frac{1}{k_{rrf} + r(c)} \quad (3.2)$$

Donde C es el conjunto de candidatos, R es el conjunto de rankings provenientes de los tres bi-encoders, $r(c)$ es el rango del documento en un ranking específico, y k_{rrf} es una constante de suavizado que mitiga la influencia de documentos con rangos muy altos, para evitar así la presencia de outliers.

3.2.3. Re-ranking

La lista unificada resultante de la fusión pasa a una etapa final de reordenamiento. A diferencia de los bi-encoders, el cross-encoder recibe como entrada el par concatenado (q, c) y utiliza un mecanismo de *full self-attention* sobre la secuencia conjunta.

Esto permite que el modelo capture interacciones no lineales y dependencias sintácticas entre la consulta y el candidato que son imposibles de representar mediante estructuras computacionales más simples. Debido a su alto coste computacional, este proceso se aplica únicamente a los candidatos más prometedores resultantes de la etapa anterior. El modelo emitirá un *logit* que representará la puntuación de relevancia final utilizada para ordenar la lista definitiva.

3.3. Tecnologías y Estrategias de Aprendizaje

La implementación del sistema se apoya en un conjunto de tecnologías y funciones de pérdida seleccionadas específicamente para maximizar el aprendizaje de similitud semántica.

3.3.1. Librerías y Entorno

El desarrollo se llevará a cabo utilizando el lenguaje Python, apoyándose en el ecosistema de **Hugging Face** y la librería **SentenceTransformers** (Reimers y Gurevych, 2019), que facilita el entrenamiento de los modelos bi-encoders que necesitamos. Para la gestión de tensores y el entrenamiento en GPU, se utilizará **PyTorch**.

3.3.2. Funciones de Pérdida (Loss Functions)

El entrenamiento de los modelos de recuperación es crítico. Se utilizarán estrategias de aprendizaje contrastivo para optimizar el espacio vectorial:

- **Retrieval: Pérdida de Clasificación con Múltiples Negativos (MNRL)** será la función de pérdida principal utilizada para el entrenamiento de los modelos bi-encoder. **MNRL** trata cada par (query, candidato) como un ejemplo positivo y considera todos los demás documentos del lote como negativos. Esto permite un entrenamiento altamente eficiente sin necesidad de definir negativos explícitos, aprovechando una gran cantidad de negativos en cada iteración y mejorando la discriminación en el espacio de representación.
- **GISTEmbedLoss:** Para la etapa de *re-ranking*, se empleará una función de pérdida de clasificación binaria (*BCEWithLogitsLoss*), tratando el problema como uno de decisión sobre pares (relacionado / no relacionado).

3.3.3. Función de evaluación

Para monitorizar el rendimiento durante el entrenamiento y la validación, se utilizará la métrica **Mean Average Precision (MAP)**, la cual es la que propuso la organización para la evaluación de la **Tarea A**. A diferencia de métricas que solo contabilizan el volumen de aciertos, el **MAP** penaliza que

los documentos relevantes aparezcan en posiciones inferiores de la lista de resultados, otorgando mayor peso a los aciertos en las primeras posiciones.

Sea una consulta q asociada a un conjunto de candidatos relevantes conocidos C_q . La **Precisión Promedio (AP)** se define formalmente como:

$$\text{AP}(q) = \frac{1}{|C_q|} \sum_{k=1}^N P(k) \cdot \mathbb{I}(\text{doc}_k \in C_q),$$

donde:

- $|C_q|$ es el número total de documentos relevantes para la consulta q .
- N es el número de documentos recuperados.
- $P(k)$ es la precisión calculada hasta la posición de corte k .
- $\mathbb{I}(\cdot)$ es una función indicadora que toma el valor 1 si el documento en la posición k es relevante ($\text{doc}_k \in C_q$) y 0 en caso contrario.

Finalmente, el valor de **MAP** se obtiene promediando la **AP** sobre la totalidad del conjunto de consultas Q :

$$\text{MAP} = \frac{1}{|Q|} \sum_{q \in Q} \text{AP}(q).$$

3.4. Flujo de Trabajo Experimental

Para validar la arquitectura propuesta y alcanzar los objetivos definidos, se plantea un flujo de trabajo iterativo dividido en cuatro fases principales:

3.4.1. Fase 1: Zero-shot

Inicialmente, se evaluará el rendimiento de un conjunto de modelos pre-entrenados seleccionados (multilingües y monolingües) sin realizar ningún tipo de entrenamiento. Esto establecerá una línea base de rendimiento y permitirá cuantificar la ganancia obtenida posteriormente mediante el entrenamiento con los datos proporcionados.

3.4.2. Fase 2: Entrenamiento de Bi-encoders

Se procederá al fine-tuning de los 10 mejores modelos de recuperación utilizando los datos de entrenamiento proporcionados por la organización de

TalentCLEF, consistentes en pares extraídos de ESCO.

En esta fase, se aplicará un Early Stopping basado en la función de pérdida [MNRL](#) y se monitorizará el rendimiento en el conjunto de validación utilizando la métrica [MAP](#). Se experimentará con diferentes configuraciones de tasas de aprendizaje y de tamaños del lote, tratando de optimizar la convergencia y la generalización del modelo.

3.4.3. Fase 3: Optimización de la Fusión

Una vez entrenados los modelos individuales, se experimentará con la estrategia de fusión. Se evaluará el impacto de diferentes combinaciones de modelos y se ajustará el parámetro k del algoritmo [RRF](#) para maximizar la métrica [MAP](#) en el conjunto de validación.

3.4.4. Fase 4: Implementación del Re-ranking

Finalmente, se integrará el cross-encoder. Se analizará el compromiso entre rendimiento y tiempo de cómputo variando la profundidad del re-ranking. El resultado de esta fase constituirá el sistema final a evaluar en la competición.

Capítulo 4

Evaluación

Este capítulo describe la metodología utilizada para evaluar el sistema/método o caso de estudio propuesto, a la vez que presenta los resultados obtenidos en la evaluación de las diferentes tareas y sobre colecciones de evaluación de distintos dominios. Algunos ejemplos de secciones pueden ser estos:

4.1. Metodología de evaluación

4.2. Métricas de evaluación

4.3. Colecciones de evaluación

4.4. Resultados

Capítulo 5

Discusión

Este capítulo analiza y discute en profundidad los resultados obtenidos en la evaluación presentada en el capítulo anterior. La estructura de este capítulo dependerá del tema del trabajo y de la estructura del capítulo anterior.

5.1. Ejemplo sección

5.1.1. Ejemplo subsección

Capítulo 6

Conclusiones y trabajo futuro

Este capítulo recopila las diferentes conclusiones extraídas del trabajo realizado, y propone algunas líneas de trabajo futuro. Las siguientes secciones son las que suelen contener este tipo de capítulos, aunque pueden variar dependiendo del tema del trabajo.

6.1. Conclusiones

6.2. Trabajo futuro

Bibliografía

Bibliografía

- [Barakat et al.2025] Barakat, Rana, Omar Mokhtar, Marwan Torki, y Nagwa Elmakky. 2025. Alexu-nlp at talentclef 2025: curriculum-driven hybrid retrieval for multilingual job title matching. *CLEF (Working Notes)*.
- [Bhangale, Gabhane, y Kumar2025] Bhangale, C, P Gabhane, y MA Kumar. 2025. Fine-tuned sentence transformer for multilingual job title matching. *CLEF (Working Notes)*.
- [Brikman, Sana, y Ruegger2025] Brikman, Adam, Michael Sana, y Holden Ruegger. 2025. Multilingual job title matching with mpnet-based sentence transformers. *CLEF (Working Notes)*.
- [Cormack, Clarke, y Buettcher2009] Cormack, Gordon V, Charles LA Clarke, y Stefan Buettcher. 2009. Reciprocal rank fusion outperforms concordet and individual rank learning methods. En *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, páginas 758–759.
- [De Toledo, Núñez, y Usabiaga2008] De Toledo, Pablo Álvarez, Fernando Núñez, y Carlos Usabiaga. 2008. La función de emparejamiento en el mercado de trabajo español. *Revista de economía aplicada*, 16(48):5–35.
- [de Toledo Saavedr, Hernández, y Ibáñez2017] de Toledo Saavedr, Pablo Álvarez, Fernando Núñez Hernández, y Carlos Usabiaga Ibáñez. 2017. ¿quién se empareja con quién en el mercado laboral español? un análisis cluster basado en la muestra continua de vidas laborales. *Investigación económica*, 76(299):87–124.

- [Decorte, De Lange, y Van Hautte2025] Decorte, Jens-Joris, Matthias De Lange, y Jeroen Van Hautte. 2025. Multilingual jobbert for cross-lingual job title matching. *arXiv preprint arXiv:2507.21609*.
- [Gasco et al.2024] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2024. Motivation — talentclef.github.io. <https://talentclef.github.io/talentclef/docs/talentclef-2025/motivation/>. [Accessed 10-11-2025].
- [Gasco et al.2025a] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2025a. Brief overview of talentclef 2025. *Journal of knowledge management*.
- [Gasco et al.2025b] Gasco, Luis, Hermenegildo Fabregat, Laura García-Sardiña, Paula Estrella, Daniel Deniz, Alvaro Rodrigo, y Rabih Zbib. 2025b. Overview of the talentclef 2025: Skill and job title intelligence for human capital management. En *International Conference of the Cross-Language Evaluation Forum for European Languages*, páginas 464–485. Springer.
- [Guo et al.2025] Guo, Yanzhu, Simone Conia, Zelin Zhou, Min Li, Saloni Potdar, y Henry Xiao. 2025. Do large language models have an english accent? evaluating and improving the naturalness of multilingual llms. En *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, páginas 3823–3838.
- [Hou y Li2023] Hou, Pengyue y Xingyu Li. 2023. Improving contrastive learning of sentence embeddings with focal-infonce. *arXiv preprint arXiv:2310.06918*.
- [huggingface] huggingface. Hugging Face - The AI community building the future. — huggingface.co. <https://huggingface.co/>. [Accessed 06-12-2025].
- [Inc.2024] Inc., Hugging Face. 2024. Retrieve & Re-Rank; Sentence Transformers documentation — sbert.net. https://sbert.net/examples/sentence_transformer/applications/retrieve_rerank/README.html. [Accessed 13-11-2025].

- [Jirjees et al.2025] Jirjees, Aram Khasro, Aram M Ahmed, Abdulhady Abas Abdulla, Joan Lu, Ekhlas Mohammed Noori, Rozhgar Nasradeen Kareem, Bryar A Hassan, Hadi Veisi, y Tarik A Rashid. 2025. Machine learning for recruitment: Analyzing job-matching algorithms. *Machine Learning*, 27:1.
- [Karpukhin et al.2020] Karpukhin, Vladimir, Barlas Oguz, Sewon Min, Patrick SH Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, y Wen-tau Yih. 2020. Dense passage retrieval for open-domain question answering. En *EMNLP (1)*, páginas 6769–6781.
- [Liu y others2009] Liu, Tie-Yan y others. 2009. Learning to rank for information retrieval. *Foundations and Trends® in Information Retrieval*, 3(3):225–331.
- [Mamani Rodriguez2022a] Mamani Rodriguez, Zoraida. 2022a. Proceso de machine learning para determinar la demanda social de puestos de empleo de profesionales de ti. *Industrial Data*, 25(2):275–300.
- [Mamani Rodriguez2022b] Mamani Rodriguez, Zoraida Emperatriz. 2022b. Machine learning no supervisado en la detección de similitud de puestos de empleo de profesionales de ti. *Industrial Data*.
- [Mao, Chu, y Kurohashi2024] Mao, Zhuoyuan, Chenhui Chu, y Sadao Kurohashi. 2024. Ems: Efficient and effective massively multilingual sentence embedding learning. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 32:2841–2856.
- [Maslej et al.2025] Maslej, Nestor, Loredana Fattorini, Raymond Perrault, Yolanda Gil, Vanessa Parli, Njenga Kariuki, Emily Capstick, Anka Reuel, Erik Brynjolfsson, John Etchemendy, y others. 2025. Artificial intelligence index report 2025. *arXiv preprint arXiv:2504.07139*.
- [Nga, Tuyen, y Van Thin2025] Nga, Ho Thuy, Ho Thi Thanh Tuyen, y Dang Van Thin. 2025. Nt team at multilingual job title matching task a: job matching via large language model-based description generation and retrieval. *CLEF (Working Notes)*.
- [Nizami et al.2025] Nizami, Muhammad Hasan, Ahtisham Uddin, Muhammad Talha Salani, Ayesha Saeed, Faisal Alvi, y Abdul Samad. 2025.

- Enhancing human capital management: Ai techniques for candidate matching and skill extraction. *CLEF (Working Notes)*.
- [Nogueira y Cho2019] Nogueira, Rodrigo y Kyunghyun Cho. 2019. Passage re-ranking with bert. *arXiv preprint arXiv:1901.04085*.
- [Novoa et al.2025] Novoa, Melissa Moreno, Juan Carlos Martinez-Santos, Jairo Serrano, y Edwin Puertas. 2025. Verbanex at talentclef2025: Semantic matching of multilingual job titles through a framework integrating esco taxonomy. *CLEF (Working Notes)*.
- [Ordóñez de Pablos y Lytras2008] Ordóñez de Pablos, Patricia y Miltiadis D Lytras. 2008. Competencies and human resource management: implications for organizational competitive advantage. *Journal of knowledge management*, 12(6):48–55.
- [Reimers y Gurevych2019] Reimers, Nils y Iryna Gurevych. 2019. Sentencebert: Sentence embeddings using siamese bert-networks. *arXiv preprint arXiv:1908.10084*.
- [Robertson, Zaragoza, y others2009] Robertson, Stephen, Hugo Zaragoza, y others. 2009. The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends® in Information Retrieval*, 3(4):333–389.
- [Rodriguez, Perez-de Viñaspre, y Perez2025] Rodriguez, Mar, Olatz Perez-de Viñaspre, y Naiara Perez. 2025. A two-stage multilingual job title matching system: combining expert knowledge and llm-based ranking. *CLEF (Working Notes)*.
- [Rodríguez-Vidal et al.2025] Rodríguez-Vidal, Javier, Ascensión López-Vargas, PM Vigara Gallego, Francisco Javier Del Álamo, y A García-Beltrán. 2025. Udi-upm at talentclef 2025: task a-multilingual job title matching. *CLEF (Working Notes)*.
- [Rojas-Galeano, Posada, y Ordoñez2022] Rojas-Galeano, Sergio, Jorge Posada, y Esteban Ordoñez. 2022. A bibliometric perspective on ai research for job-résumé matching. *The Scientific World Journal*, 2022(1):8002363.

- [Salton, Wong, y Yang1975] Salton, Gerard, Anita Wong, y Chung-Shu Yang. 1975. A vector space model for automatic indexing. *Communications of the ACM*, 18(11):613–620.
- [Solatorio2024] Solatorio, Aivin V. 2024. Gistembed: Guided in-sample selection of training negatives for text embedding fine-tuning. *arXiv preprint arXiv:2402.16829*.
- [Vachharajani2025] Vachharajani, Poojan. 2025. Pjmathematician at talentclef 2025: enhancing job title and skill matching with gistembed and llm-augmented data. *CLEF (Working Notes)*.
- [Vaswani et al.2017] Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, y Illia Polosukhin. 2017. Attention is all you need. *Advances in neural information processing systems*, 30.
- [W3Techs2023] W3Techs, A. 2023. Usage statistics of content languages for websites.
- [Xu et al.2025] Xu, Zhichao, Fengran Mo, Zhiqi Huang, Crystina Zhang, Puxuan Yu, Bei Wang, Jimmy Lin, y Vivek Srikumar. 2025. A survey of model architectures in information retrieval. *arXiv preprint arXiv:2502.14822*.
- [Zhang y van der Goot2025] Zhang, Mike y Rob van der Goot. 2025. Nl-pnorth@ talentclef 2025: Comparing discriminative, contrastive, and prompt-based methods for job title and skill matching. *arXiv preprint arXiv:2506.19058*.

Glosario

AI Artificial Intelligence (Inteligencia Artificial). [1](#), [11](#)

AP Average Precision (Precisión Promedio). [23](#)

BM25 Best Matching 25 (Mejor Coincidencia 25). [8](#)

DL Deep Learning (Aprendizaje Profundo). [8](#)

ESCO European Skills, Competences, Qualifications and Occupations (Habilidades, Competencias, Cualificaciones y Ocupaciones Europeas). [3](#), [13](#)

HCM Human Capital Management (Gestión del Capital Humano). [1-3](#), [10](#), [11](#)

InfoNCE Information Noise-Contrastive Estimation (Estimación de Contraste de Ruido de Información). [17](#)

IR Information Retrieval (Recuperación de Información). [7](#), [8](#), [14](#), [16](#)

ISCO International Standard Classification of Occupations (Clasificación Internacional Uniforme de Ocupaciones). [13](#)

JTM Job Title Matching (Emparejamiento de Titulaciones Profesionales). [10-12](#)

LLM Large Language Model (Modelo de Lenguaje Grande). [13](#), [14](#), [16](#)

LTR Learning to Rank (Aprendizaje para Ordenación). [8](#)

MAP Mean Average Precision (Precisión Media Promedio). [3](#), [22](#), [24](#)

ML Machine Learning (Aprendizaje Automático). [8](#), [11](#)

MNRL Multiple Negatives Ranking Loss (Pérdida de Clasificación con Múltiples Negativos). [22](#), [24](#)

NLP Natural Language Processing (Procesamiento del Lenguaje Natural). [1](#), [2](#)

RBO Rank Biased Overlap (Superposición Sesgada por Rango). [3](#), [15](#)

RRF Reciprocal Rank Fusion (Fusión Recíproca de Rangos). [9](#), [21](#), [24](#)

Tarea A Tarea A: Emparejamiento Multilingüe de Titulaciones Profesionales (Multilingual Job Title Matching) de la campaña de evaluación TalentCLEF 2025. [3](#), [4](#), [12](#), [14](#), [22](#)

TF-IDF Term Frequency-Inverse Document Frequency (Frecuencia de Término-Frecuencia Inversa de Documento). [7](#)

To-do list

- 2, Me suena rara la conexión entre el benchmark y la conclusión de la sección. Tengo que pulirla.
- 3, Incluir aquí información sobre Codabench y los métodos oficiales de evaluación